

CENTRALE LYON

Rapport de stage de fin d'études

Machine Learning et modèles réduits appliqués aux processus de fabrication

Élèves :
Taha Zaoui

Enseignants :
Dr. Céline Hartweg
Helbert

Tuteurs :
M. Raphael Meunier
Mme. Amina Chorfi

Remerciements

Je tiens à exprimer ma sincère gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet de fin d'études.

Mes remerciements s'adressent en premier lieu à mes tuteurs **M. Raphael MEUNIER** et **Mme. Amina CHORFI**, ingénieurs numériciens au sein du **service simulation**, pour leur encadrement rigoureux, leur disponibilité et la confiance qu'il m'ont accordée tout au long de ces six mois. Leurs conseils techniques et leur suivi attentif ont été déterminants dans la conduite de ce projet.

Je remercie également ma tutrice pédagogique **Mme Céline HELBERT**, maîtresse de conférences en mathématiques appliquées à l'École Centrale de Lyon et l'Institut Camille Jordan, pour son accompagnement académique, ses retours éclairés sur ce rapport et son soutien tout au long de cette dernière année de formation.

Je souhaite exprimer notamment ma reconnaissance à l'ensemble de l'équipe **Data science** ainsi qu'aux collaborateurs et stagiaires de Michelin que j'ai eu la chance de côtoyer au cours de toute la durée du stage. Leur bienveillance, leur disponibilité et leur aide précieuse ont grandement facilité mon intégration et enrichi cette expérience professionnelle.

Je remercie enfin **ma famille**, dont le soutien indéfectible a été une source de motivation constante, ainsi que mes professeurs et camarades qui ont contribué à forger les compétences et la rigueur que j'ai pu mettre en œuvre durant ce stage.

Ce projet est l'aboutissement d'un parcours collectif, et c'est avec beaucoup de reconnaissance que j'en arrive aujourd'hui à cette étape.

Résumé

Ce projet de fin d'études a été réalisé au sein de la Direction Opérationnelle de la Recherche et du Développement (DORD) de Michelin, au centre de R&D de Ladoux, à Clermont-Ferrand, au sein de l'équipe Data science.

Le calandrage est un procédé industriel majeur dans la fabrication des pneumatiques. Au cours de ce procédé, la matière première est soumise à différents phénomènes multiphysiques, tels que l'échauffement, les gradients de vitesse ou encore les variations de pression. Lorsque les conditions physiques deviennent trop sévères, le produit final peut présenter des défauts. Il est donc essentiel de disposer d'outils permettant de modéliser et de simuler numériquement ce procédé afin de prédire les conditions auxquelles la matière est soumise et, à terme, de mieux les maîtriser.

Un outil de simulation numérique par éléments finis est déjà disponible au sein de l'entreprise. Cependant, son coût de calcul élevé limite son utilisation dans les applications nécessitant un grand nombre de simulations. L'objectif de ce projet est ainsi de développer un modèle de substitution fondé sur des méthodes d'apprentissage statistique, capable d'approximer les solutions fournies par le modèle physique tout en réduisant significativement le coût computationnel.

Le modèle de substitution étudié dans ce travail est le **Mesh Morphing Gaussian Process** (MMGP). Cette approche, fondée sur la régression par processus gaussiens, est dédiée à l'apprentissage de solutions d'équations aux dérivées partielles définies sur des maillages numériques. La méthodologie repose sur plusieurs étapes complémentaires, notamment le traitement et la standardisation des maillages, la réduction de dimension des données ainsi que l'apprentissage des représentations obtenues par des modèles de régression. Le développement de la solution a ainsi nécessité l'étude et la comparaison de différentes méthodes à chacune de ces étapes afin d'identifier la configuration la plus adaptée au problème considéré.

La solution finalement retenue permet de reproduire de manière satisfaisante les tendances globales de plusieurs champs physiques. Elle présente néanmoins des limites dans la restitution de phénomènes fortement localisés. En particulier, l'apprentissage de champs caractérisés par des variations spatiales très concentrées reste difficile avec la formulation considérée. un nombre d'approches ont été explorées afin de limiter cette faiblesse, notamment au niveau de la représentation et de la réduction de dimension des champs. Ces développements ont permis d'améliorer la qualité des prédictions, sans toutefois atteindre pleinement le niveau de précision recherché dans le cadre de ce travail.

Abstract

This final-year project was carried out within Michelin's Operational Research and Development Division (DORD), at the Ladoux R&D center in Clermont-Ferrand, as part of the Data science team.

The calandring is a major industrial process involved in tire manufacturing. During this process, the raw material is subjected to several multiphysics phenomena, such as heating, velocity gradients, and pressure variations. When the physical conditions become too severe, the final product may exhibit defects. It is therefore essential to develop tools capable of modeling and numerically simulating this process in order to predict the conditions experienced by the material and, ultimately, to better control them.

A finite-element numerical simulation tool is already available within the company. However, its high computational cost limits its use in applications requiring a large number of simulations. The objective of this project is therefore to develop a surrogate model based on statistical learning methods, capable of approximating the solutions provided by the physical model while significantly reducing the computational cost.

The surrogate model investigated in this work is the **Mesh Morphing Gaussian Process** (MMGP). This approach, based on Gaussian Process regression, is designed to learn solutions of partial differential equations defined on numerical meshes. The methodology relies on several complementary steps, including mesh processing and standardization, data dimensionality reduction, and the learning of the resulting representations using regression models. The development of the final solution therefore required the study and comparison of different methods at each of these stages in order to identify the most suitable configuration for the problem under consideration.

The final solution is able to reproduce the global trends of several physical fields with satisfactory accuracy. However, it still shows limitations in capturing strongly localized phenomena. In particular, learning physical fields characterized by highly concentrated spatial variations remains challenging with the considered formulation. Several approaches were investigated in order to mitigate this limitation, especially at the level of field representation and dimensionality reduction. These developments improved the quality of the predictions, although the level of accuracy targeted in this work was not fully achieved.

Table des matières

1 Présentation de l'entreprise **9**

2 Problématique du projet **10**
2.1 Contexte 10
2.2 Mission du stage 12

3 Choix de la solution **13**
3.1 Contraintes inhérentes au projet 13
3.2 Sélection du modèle 13

4 Préliminaire **15**
4.1 Réduction de dimension par POD (Proper Orthogonal Decomposition) [15] 15
4.1.1 Cadre théorique 15
4.1.2 Application à un cas jouet 17
4.2 Méthode MMGP (Mesh Morphing Gaussian Process) [3] 22

5 Etapes suivies dans l'implémentation de la solution **26**
5.1 Définition des variables et leurs plages de variations 26
5.2 Construction du plan d'expériences 26
5.3 Calcul des solutions éléments finis et visualisation des données 28
5.4 Mesh Morphing 30
5.4.1 Méthodes testées 30
5.4.2 Comparaison des méthodes 30
5.5 Transport des champs physiques vers le maillage de référence 38
5.6 Réduction de dimension par POD 38
5.7 Inspection de la corrélation 40
5.8 Implémentation du modèle 42
5.9 Résultats obtenus 43
5.9.1 Prédiction de la température 43
5.9.2 Prédiction de la pression 44
5.9.3 Prédiction de la vitesse 45
5.10 Comparaison des performances des modèles : 46
5.11 Analyse SHAP pour le modèle MMGP classique 48
5.11.1 Analyse de l'importance des variables. 48
5.11.2 Sélection progressive des coordonnées réduites 50
5.12 Diagnostic : évaluation de la qualité de l'encodage de l'information par POD 52
5.13 Réduction de dimension non linéaire avec l'autoencodeur : 55
5.14 Première étude et choix de la fonction d'activation 57
5.15 Prise en compte des erreurs locales 58
5.15.1 Résultats de l'encodage 60
5.15.2 Évaluation des performances du nouveau modèle 61

A Retour d'expérience **65**

B Régression par processus gaussiens **66**

C Analyse SHAP pour la sélection des variables **70**

D Autoencodeurs pour la réduction de dimension **71**

E Mesh Morphing avec l'algorithme de Tutte. **71**

F Mesh Morphing par fonctions à base radiale (RBF) **72**

Table des figures

1 Site de Ladoux . . . 10
2 Calandre . . . 10
3 Exemple de maillage éléments finis avec les conditions limites imposées au bord . . . 11
4 Exemple de calcul éléments finis (EF) de la température au niveau du bourrelet . . . 12
5 Tracé de la solution de l'équation (1) à différents instants . . . 17
6 Visualisation de la décomposition POD de la solution de l'équation (1) . . . 18
7 Résultat du code de calcul POD et de la sélection des modes . . . 19
8 Tracé de l'apprentissage du deuxième mode avec les différents modèles dans les deux configurations . . . 20
9 Comparaison des différents modèles d'apprentissage testés . . . 21
10 Reconstruction de la solution de l'équation de la chaleur par régression à processus gaussiens sur les contributions modales de la POD . . . 21
11 Algorithme MMGP [3] . . . 25
12 Plan d'expériences utilisé . . . 27
13 Distribution de chaque variable dans l'ensemble d'entraînement et de test . . . 28
14 Tracé des champs physiques dans quelques points d'observation . . . 29
15 Distribution des domaines d'étude et repérage des domaines pris comme référence et les domaines testés . . . 31
16 Exemple du Mesh Morphing RBF appliqué à un maillage de la base l'entraînement . . . 32
17 Comparaison des domaines de référence en se basant sur des métriques quantitatives . . . 33
18 Champs physiques obtenus par transport vers les domaines de références comparés . . . 34
19 Comparaison de la qualité de transport des champs vers le maillage circulaire et le maillage médian . . . 35
20 Comparaison des erreurs moyennes RRMSE de la réduction de dimension par POD pour les deux types de Mesh Morphing, pour l'ensemble d'entraînement et de test . . . 36
21 Champs de température T, de pression P et de vitesse (U, V) avant et après le transport et l'interpolation . . . 38
22 Sélection des modes de la POD par le critère du taux de variance expliqué pour les champs des abscisses x, des ordonnées y et de la température T . . . 39
23 Évolution de l'erreur RRMSE en fonction du nombre de modes retenus pour les champs de coordonnées **en échelle logarithmique** . . . 40
24 Matrices de la corrélation . . . 41
25 Résultats de prédiction des champs de température . . . 43
26 Résultats de prédiction des champs de pression . . . 44
27 Résultats de prédiction des champs de vitesse . . . 45
28 Comparaison des performances des deux modèles . . . 47
29 Analyse SHAP moyennée sur tous les modes pour chaque champ physique 49
30 Importance des variables pour les trois premiers modes de la température . 49
31 Classement des variables en fonction de leur importance globale . . . 50

32 Évolution de la qualité de prédiction en fonction du nombre de variables d'entrée conservées pour les trois champs physiques cibles 50
33 Évolution de la qualité de l'encodage POD en fonction du nombre de modes pour les trois champs physiques étudiés : température, pression et vitesse. . 53
34 Exemple d'évaluation de la reconstruction POD pour une simulation 54
35 Schéma explicatif confrontant la réduction de dimension par POD et par autoencodeur, mettant en évidence la complexité et la non linéarité éventuelle de l'autoencodeur [13] 55
36 Influence de la fonction d'activation sur les performances de l'autoencodeur. 57
37 Visualisation de l'erreur locale pour les différentes configurations testées . . 58
38 Entraînement du meilleur autoencodeur avec la fonction de coût hybride $\mathcal{L}_{loss}$ 59
39 Comparaison de la distribution des maximum de résidus pour l'encodage linéaire et non linéaire des champs 60
40 Exemple d'évaluation de la reconstruction POD pour une simulation 61
41 Comparaison des trois modèles 62

Introduction

Les processus de fabrication utilisés par Michelin impliquent souvent des phénomènes couplés multi-physiques tels que l'écoulement des fluides et le transfert thermique. La modélisation numérique de ces phénomènes repose généralement sur la résolution d'un ensemble d'équations complexes. Lorsque ces équations sont résolues par des méthodes numériques précises, comme la méthode des éléments finis (EF), la fidélité des solutions est élevée, mais au prix d'un coût de calcul significatif. Ce coût devient particulièrement contraignant pour des applications nécessitant un grand nombre d'évaluations du modèle, telles que l'optimisation de procédés, l'identification de paramètres, le contrôle en temps réel ou l'analyse d'incertitude.

Face à ce constat, l'équipe **Data science** cherche à développer une méthode pour réduire le temps de simulation tout en conservant une précision acceptable pour l'usage industriel. Les modèles dits **substitution** basés sur l'apprentissage automatique (surrogate ou data-driven) constituent une voie prometteuse pour accélérer les prédictions numériques. Cependant, construire des modèles surrogate fiables pour des systèmes couplés présente plusieurs défis, notamment la complexité non linéaire et les couplages entre les variables des modèles physiques utilisés, qui complexifie considérablement la généralisation du modèle surrogate à des conditions de fonctionnement variées rencontrées en production. C'est dans ce cadre que s'inscrit le projet de ce stage, dont la mission est de développer, évaluer, optimiser et comparer des approches data-driven pour construire des modèles surrogate capables d'approximer les solutions des modèles thermo-mécaniques utilisés par Michelin.

Ce rapport s'ouvre sur la présentation du contexte et de la problématique du projet, afin de situer les enjeux de la mission du stage. Il analyse ensuite les solutions développées, avant de décrire en détail la conception et la réalisation de la solution technique. Le rapport se clôt par une synthèse des différentes approches adoptées au cours de la mission, des résultats obtenus et de l'apport du projet sur les plans technique et personnel.

1 Présentation de l'entreprise

Fondée en 1889 à Clermont-Ferrand par les frères André et Édouard Michelin, la Compagnie Générale des Établissements Michelin s'est imposée comme l'un des leaders mondiaux de l'industrie du pneumatique. Le groupe est aujourd'hui présent dans plus de 170 pays et emploie près de 132 000 collaborateurs à travers le monde, répartis sur plus de 120 sites de production. Cette présence internationale s'articule autour de trois grandes zones géographiques qui structurent la répartition du chiffre d'affaires : l'Europe (environ 40%), l'Amérique du Nord (environ 36%) et les autres régions du monde (environ 25%) [10].

Sur le plan financier, le groupe a enregistré en 2024 un chiffre d'affaires de 27,2 milliards d'euros, contre 28,3 milliards en 2023, reflétant une légère contraction liée notamment au recul des ventes de pneumatiques en première monte — c'est-à-dire les pneus équipant les véhicules neufs sortant d'usine. Malgré cette baisse conjoncturelle, le résultat opérationnel s'est maintenu à 3,37 milliards d'euros, témoignant de la solidité du modèle économique du groupe. Michelin commercialise ses produits sous plusieurs marques, dont BFGoodrich, Uniroyal et Kleber, en plus de sa marque éponyme positionnée sur le segment premium [10].

L'activité du groupe ne se limite pas aux pneumatiques au sens strict. Michelin a engagé une stratégie de diversification vers les Polymer Composite Solutions, regroupant des activités dans les matériaux composites, les courroies industrielles et les joints d'étanchéité, notamment à la suite de l'acquisition en 2023 de Flex Composite pour 700 millions d'euros. Par ailleurs, le groupe publie le célèbre Guide Michelin, référence internationale dans la gastronomie, illustrant une identité de marque qui dépasse largement le seul secteur du pneumatique. L'engagement environnemental constitue également un axe stratégique fort : en 2024, 31% des matériaux utilisés dans la fabrication des pneumatiques étaient d'origine renouvelable ou recyclée, contre 28% l'année précédente [9].

Distinguée par sa forte culture d'innovation et un investissement important en recherche et développement (R&D), Michelin possède trois sites Recherche et Développement dans trois continents, mobilisant plusieurs milliers d'ingénieurs et chercheurs à travers le monde, en en cite par exemple :

1. Site de Ladoux, Clermont-Ferrand, France.
2. Site de Greenville, South Carolina, États Unis d'Amérique.
3. Site de Pune, Maharashtra, Inde, etc.

La capacité d'innovation du groupe Michelin se manifeste également par la grande diversité des métiers présents au sein de la R&D. Mathématiciens et spécialistes des matériaux et physiciens, entre autres, contribuent à une activité de recherche et d'innovation qui couvre aujourd'hui plus de 350 domaines d'expertise.

Le site de Ladoux, situé à proximité de Clermont-Ferrand, constitue le principal centre de recherche et développement du groupe en Europe et l'un des plus importants au niveau mondial. Il regroupe environ la moitié des équipes R&D de Michelin et emploie environ 5000 employés, représentant ainsi un pôle stratégique d'innovation pour l'entreprise [9].



FIGURE 1 – Site de Ladoux

2 Problématique du projet

2.1 Contexte

La fabrication d'un pneumatique suit une succession d'étapes au cours desquelles les matières premières sont transformées et assemblées pour produire le produit fini. Une étape clé de ce processus est le **calandrage**. Ce procédé industriel consiste à faire passer du caoutchouc entre plusieurs rouleaux (les calandres) afin d'obtenir des feuilles de caoutchouc de faible épaisseur et de qualité contrôlée. Le calandrage permet d'appliquer et de lier solidement des renforts — nappes textiles (par exemple polyester, nylon) ou fils métalliques (câbles d'acier) — au sein du mélange de caoutchouc, en garantissant une épaisseur uniforme et une bonne adhérence caoutchouc–renfort. Cette opération contribue ainsi à l'étanchéité et aux performances mécaniques du pneumatique en assurant la continuité et la résistance des couches composantes.

Le procédé est effectué par une machine appelée **calandre**, composée de plusieurs cylindres en rotation, un schéma de la machine est présenté dans la figure (2) :

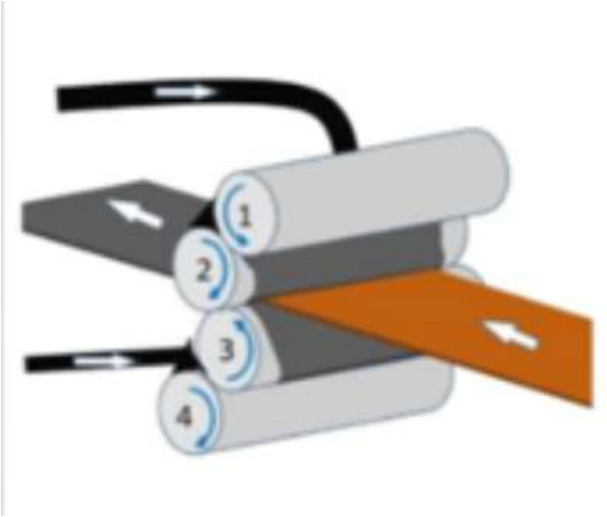


FIGURE 2 – Calandre

Le comportement de la gomme sur la ligne de calandrage implique des phénomènes multi-physiques de la mécanique des fluides et du transfert thermique, par exemple : un réchauffement local, l'apparition d'une couche limite, une compression du mélange, etc. Ces phénomènes font intervenir un nombre de grandeurs physiques auxquelles est sensible le mélange de caoutchouc résultant à la sortie de la calandre. On en identifie principalement la température, la pression et la vitesse d'écoulement, qu'on cherche à calculer via un modèle physique. Cet intérêt s'explique par l'importance du contrôle des conditions physiques auxquelles est soumis le mélange de caoutchouc, pour garantir la qualité du produit final. En effet, lorsque la gomme est chauffée ou compressée excessivement, des parties du mélange risquent d'être cuites, c'est ce qu'on appelle **le gratonnage**. Par conséquent, des défauts risquent d'apparaître dans le pneu à la fin du procédé de fabrication. Le modèle physique adopté par Michelin est formulé mathématiquement par un ensemble d'équations aux dérivées partielles non linéaires, de la forme de l'équation de Navier-Stokes et de convection-diffusion. On ne connaît pas de solution analytique pour ces équations, mais un intérêt majeur est porté à leur résolution numérique pour connaître les conditions physiques auxquelles est soumis le caoutchouc au cours du calandrage. La résolution numérique se fait par la méthode des éléments finis.

En réalité, le problème étudié est tridimensionnel, mais pour des raisons de simplicité il est réduit en un problème bidimensionnel. Le domaine d'étude correspond à l'espace situé au niveau de l'intersection entre les cylindres de la calandre, appelé **bourrelet**. Dans le modèle physique adopté par l'entreprise, un ensemble de conditions limites de type Neumann et Dirichlet est imposé au bords de ce domaine. Ce dernier est discrétisé en un maillage triangulaire via le générateur de maillages *gmsh*. La figure (3) présente un exemple de maillage construit sur le domaine d'étude, ainsi que les conditions aux limites définies sur son bord :

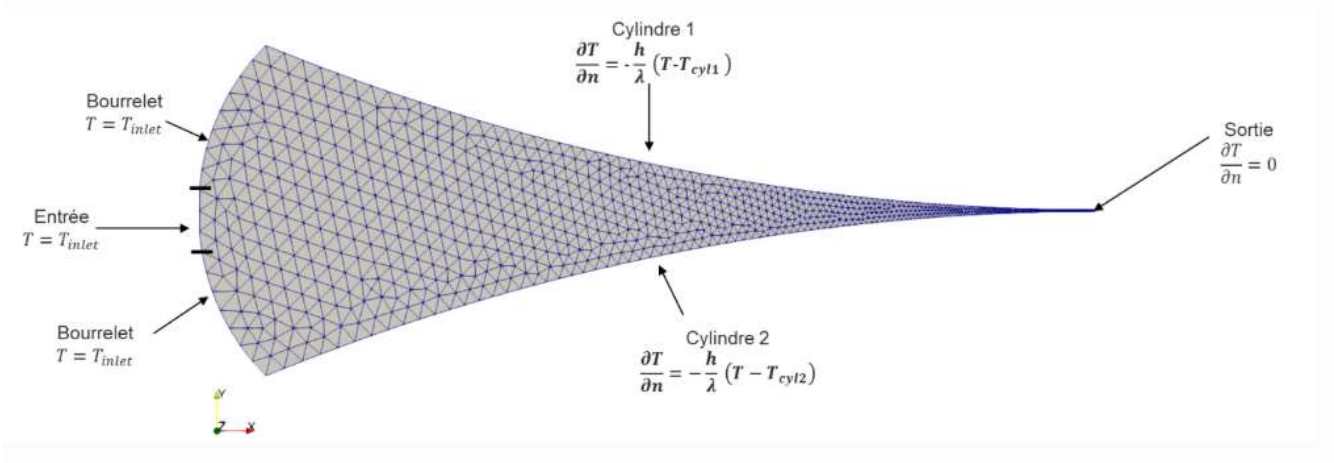


FIGURE 3 – Exemple de maillage éléments finis avec les conditions limites imposées au bord

Les équations du modèle physique utilisé par l'entreprise dépendent d'un ensemble de paramètres qu'on peut répartir en deux classes :

— des **paramètres physiques** qui contrôlent l'écoulement de la gomme à travers le passage au fin de la calandre, qui sont principalement des grandeurs physiques caractéristiques du mélange étudié, par exemple : sa masse volumique, sa chaleur massique, etc.

— des **paramètres géométriques**, qui paramétrisent les domaines géométriques sur lesquels on fait la résolution du problème, ainsi que permettent de mailler la géométrie de passage au fin considérée.

A l'issue du calcul, on obtient la distribution des champs de la vitesse, de la pression et de la température au sein du domaine étudié. Ces résultats permettent de caractériser les sollicitations thermiques et hydrodynamiques auxquelles le mélange de caoutchouc est soumis au cours du procédé et constituent un outil d'analyse et d'optimisation des conditions de fabrication. La figure (4) présente l'exemple d'un champ de température issu de ce calcul :

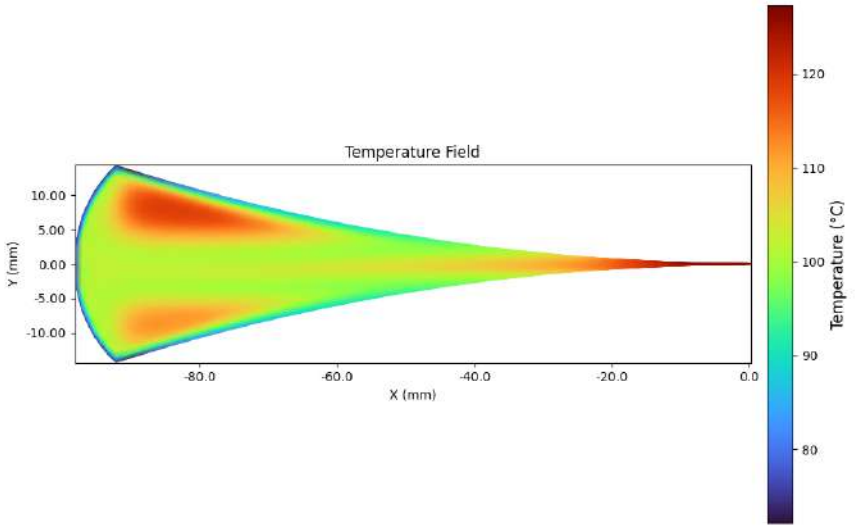


FIGURE 4 – Exemple de calcul éléments finis (EF) de la température au niveau du bourrelet

2.2 Mission du stage

Comme expliqué dans la section précédente, la simulation par éléments finis (EF) du processus de calandrage est de grande importance pour assurer la qualité des pneus ; vu qu'elle est utilisée pour optimiser les conditions réelles en usine sous lesquelles passe le mélange de caoutchouc constituant la base du produit final. Mais, le calcul EF présente un défaut majeur : la simulation est coûteuse en ressources de calcul, exigeante en mémoire et nécessite des temps de calcul importants [3, 7]. Ces contraintes limitent voire empêchent les experts de faire les traitements nécessitant un grand nombre de simulations, par exemple : l'optimisation bayésienne. Pour cette raison, l'équipe Data science cherche à développer un modèle de substitution basé sur l'apprentissage statistique, permettant de réduire le temps de simulation tout en conservant une précision acceptable pour l'usage industriel. Ce but est exactement l'objectif de ce stage que j'ai eu l'opportunité de faire à Michelin. Le fil conducteur de ce travail est la simulation du procédé de calandrage (voir section 2.1), qui permet de répondre directement à la problématique du projet. Les résultats obtenus constituent une base pour les travaux futurs des chercheurs de l'équipe. Ils pourront notamment être exploités afin de prédire l'apparition ou non du gratonnage pour différentes conditions d'entrée, ainsi que pour déterminer les conditions opératoires optimales permettant de satisfaire un ensemble de contraintes imposées au produit final.

Ce sujet est utile à deux niveaux : d'abord, au plan industriel, il sert de raccourci pour l'entreprise pour assurer la qualité de son produit. Ensuite, au niveau académique, ce stage fait appel à un ensemble diversifié de notions et de techniques mathématiques, m'offrant ainsi une belle opportunité pour améliorer mes compétences dans mon domaine d'intérêt.

3 Choix de la solution

3.1 Contraintes inhérentes au projet

Le choix de la solution repose sur un cahier de charges qu'on cherche à satisfaire. On fait l'inventaire des contraintes auxquelles le modèle retenu doit répondre :

1. Les solutions du modèle physique qu'on cherche à simuler sont des champs de température, de pression et de vitesse. Ils sont d'une certaine régularité : continus et infiniment dérivables. Par conséquent, si le modèle va commettre inévitablement des erreurs de prédiction sur chaque noeud du maillage, ces erreurs ne doivent pas être décorrélées d'un noeud à un autre, sinon la régularité des champs risque d'être perdue
2. Les champs obtenus par EF, qu'on cherche à prédire sont non bruitées. Autrement dit, pour une valeur d'entrée fixée, on obtient toujours la même sortie. Ce constat laisse penser à utiliser un **interpolateur exact**.
3. Un autre point à prendre en considération, c'est que les solutions qu'on cherche à prédire sont calculées sur des maillages de grande taille (ordre de 10 000 noeuds). La solution choisie doit donc passer par une réduction de dimension afin de réduire le coût computationnel et la durée de calcul.
4. Les simulations éléments finis étant très coûteuses. La base de données qui sera utilisée pour l'entraînement et l'évaluation du modèle est censée être la plus petite possible pour réduire le coût de calcul autant que possible. Alors, le modèle doit avoir besoin d'une base de données de petite taille pour l'apprentissage.

3.2 Sélection du modèle

Plusieurs approches de substitution fondées sur l'apprentissage automatique ont été proposées pour pallier le coût computationnel élevé de la résolution des équations aux dérivées partielles (EDP). Ces méthodes visent à apprendre une approximation de l'opérateur solution reliant les paramètres d'entrée du problème aux champs physiques recherchés. Elles s'inscrivent notamment dans le cadre de la modélisation d'ordre réduit [8, 15], des modèles de substitution supervisés [2, 3, 4]. Un exemple simple de modèle d'apprentissage qui peut être utilisé est la régression linéaire. Par contre, malgré sa simplicité et son faible coût de calcul, elle ne sera pas utilisée dans ce problème. En effet, les EDP considérées sont non linéaires ; on ne s'attend donc pas à ce que leurs solutions puissent être correctement représentées par un modèle linéaire. Dans la littérature, un intérêt particulier a été prêté aux modèles à base de réseaux de neurones, par exemple les réseaux de neurones convolutionnels [7], ou graphiques [6, 16]. Le choix de ces modèles est particulièrement limité par plusieurs difficultés, notamment en raison de la complexité de leur passage à l'échelle vis-à-vis du nombre de nœuds à traiter, ainsi que du phénomène de sur-lissage

(oversmoothing) induit par les opérations de convolution sur les graphes [16]. En plus qu'ils ne sont généralement pas des interpolateurs exacts, et qu'ils nécessitent de vastes jeux de données ainsi que des ressources de calcul importantes [3]. Par contre, la régression à processus gaussiens [12] et à fonctions de base radiale [4] sont des interpolateurs exacts. Cependant, un atout majeur des processus gaussiens est qu'ils fournissent, en plus de la prédiction moyenne, une estimation de l'incertitude associée [12]. Cela permet de construire des intervalles de confiance, de quantifier l'erreur d'interpolation et d'évaluer la fiabilité des prédictions.

Le choix du modèle d'apprentissage doit tenir compte de la nature particulière des données considérées. Dans notre cas, les quantités à prédire sont des champs physiques solutions d'équations aux dérivées partielles (EDP), définis sur des maillages EF. Or, ces maillages peuvent varier d'une configuration à l'autre, aussi bien par leur nombre de nœuds que par leur géométrie et leur domaine de définition. Les champs associés ne peuvent donc pas être utilisés directement comme sorties d'un modèle d'apprentissage supervisé, parce qu'ils ne sont pas représentés dans un espace commun et ne possèdent pas nécessairement la même dimension. Il faut alors trouver une solution pour ramener l'ensemble des configurations sur un domaine de référence et sur une discrétisation commune. Plusieurs méthodes peuvent être mobilisées dans ce contexte, notamment l'algorithme de Tutte [14] (voir annexe E), ainsi que les techniques de RBF Mesh Morphing [11] (voir l'annexe F), basées sur les fonctions à base radiale, qui permettent de déformer un maillage de référence tout en préservant sa connectivité. Ces traitements rendent les différentes solutions comparables et permettent leur exploitation dans un cadre d'apprentissage statistique.

Comme évoqué dans la section (3.1), les champs qu'on cherche à prédire sont de grande taille (ordre de 10 000 degrés de libertés). La solution qu'on propose doit donc passer par une réduction de dimension consistant à représenter chaque champ par un nombre restreint de variables latentes tout en conservant l'essentiel de l'information physique qu'il contient. Parmi les approches possibles, la Proper Orthogonal Decomposition (POD) (voir le préliminaire 5.6) fournit une représentation linéaire compacte fondée sur les modes dominants du champ, tandis que les autoencodeurs (voir l'annexe D) permettent d'obtenir une représentation non linéaire potentiellement mieux adaptée à des structures complexes.

La recherche bibliographique emmène vers un modèle à base de processus gaussiens, englobant tous les critères évoqués précédemment, dédié à l'apprentissage des solutions d'EDPs par éléments finis. Ce modèle s'appelle **Mesh Morphing Gaussian Process (MMGP)** (voir section 4.2), et fait appel à un ensemble de notions de réduction de dimension et de traitement des maillages. A la base, MMGP est utilisé pour prédire les solutions sur des maillages EF non paramétrés, c'est-à-dire, dont on ne dispose d'aucun paramètre qui contrôle la taille du domaine d'étude. Par contre, comme indiqué dans la section (2.1), on dispose d'un ensemble de paramètres géométriques qui contrôlent les dimensions des maillages utilisés. Mais cela n'empêche pas de développer le modèle d'origine pour l'adapter au problème étudié, et ainsi vérifier l'influence ou non des paramètres.

L'élaboration de ce modèle commence par l'étude d'un nombre de notions et de techniques mathématiques auxquelles ce modèle fait appel. Un préliminaire dans la section (4) explique toutes les bases nécessaires pour la compréhension du modèle.

4 Préliminaire

4.1 Réduction de dimension par POD (Proper Orthogonal Decomposition) [15]

4.1.1 Cadre théorique

La POD est une méthode de réduction de dimension largement utilisée pour approximer des champs physiques de grande dimension à l'aide d'une base réduite optimale. Soit $u(t,x)$ un champ physique défini pour la variable x appartenant à un domaine spatial $\Omega \in \mathbb{R}^d$ et t un champ de paramètres dans $\mathbb{R}^p$, où $p, d \in \mathbb{N}$. Et soit $\mathbb{U} \in \mathbb{R}^{m\times n}$ une matrice de réalisations de la fonction u appelées snapshots, où chaque ligne correspond à un état du système discrétisé sur n degrés de liberté.

$$\mathbb{U} = \begin{pmatrix} u(t_1,x_1) & u(t_1,x_2) & \cdots & u(t_1,x_n) \\ u(t_2,x_1) & u(t_2,x_2) & \cdots & u(t_2,x_n) \\ \vdots & \vdots & \ddots & \vdots \\ u(t_m,x_1) & u(t_m,x_2) & \cdots & u(t_m,x_n) \end{pmatrix}$$

Le principe de la POD consiste à extraire les structures dominantes qui capturent la variabilité des données. On appelle matrice de covariance la matrice définie par :

$$\mathbb{C} = \frac{1}{m-1}\mathbb{U}^\top\mathbb{U}$$

La matrice $\mathbb{C}$ étant symétrique réelle semi-définie positive alors elle est diagonalisable, ses vecteurs propres $\phi_1, \phi_2, \ldots, \phi_n$ forment une base orthogonale de $\mathbb{R}^n$, que l'on peut normaliser pour qu'elle soit orthonormée :

$$\phi_i^\top \phi_j = \delta_{ij}.$$

Ainsi, tout vecteur $v \in \mathbb{R}^n$ peut se décomposer sur cette base :

$$v = \sum_{k=1}^{n} a_k\, \phi_k, \text{ avec } a_k = \phi_k^\top v$$

Et il est de même pour la matrice des snapshots $\mathbb{U} \in \mathbb{R}^{m\times n}$, il suffit de raisonner sur la transposée de chaque ligne :

$$u^{(j)} = \sum_{k=1}^{n} a_k^{(j)}\, \phi_k^\top, \quad \text{avec} \quad a_k^{(j)} = u^{(j)}\, \phi_k$$

En regroupant ces décompositions et en posant $a_k = (a_k^{(1)}, \ldots, a_k^{(m)})^\top$ on obtient :

$$\mathbb{U} = \sum_{k=1}^{n} a_k\, \phi_k^\top = \sum_{k=1}^{n} \tilde{\mathbb{U}}_k$$

où chaque matrice $\tilde{\mathbb{U}}_k$ représente la contribution du k-ième mode. Les coefficients $a_k^{(j)}$ représentent les contributions modales, et dépendent uniquement des paramètres du système associés à chaque réalisation. Vu que la base $(\phi_k)_k$ est orthonormée, les vecteurs a_k sont calculés par la relation :

$$a_k = \mathbb{U}\,\phi_k$$

Soient $\lambda_1, \lambda_2, \ldots, \lambda_n$ les valeurs propres de la matrice de covariance $\mathbb{C}$, associées respectivement aux vecteurs propres $\phi_1, \phi_2, \ldots, \phi_n$. Quitte à ré-indexer les valeurs propres, on suppose qu'elles sont ordonnées par ordre décroissant $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$. Les r premiers modes propres, c'est-à-dire $\phi_1, \phi_2, \ldots, \phi_r$, sont ceux qui maximisent la variance expliquée par la matrice $\mathbb{C}$. La variance totale expliquée par ces r premiers modes est donnée par :

$$\frac{\sum_{i=1}^{r} \lambda_i}{\sum_{i=1}^{n} \lambda_i}$$

Les vecteurs propres associés aux plus grandes valeurs propres définissent une base orthonormée dans laquelle la projection des données maximise la variance capturée. En pratique, un nombre $r \ll m$ de modes dominants est conservé, ce qui permet d'obtenir une approximation de rang réduit des champs sous la forme

$$\mathbb{U} \approx \sum_{k=1}^{r} a_k\, \phi_k^{\top}$$

Cette représentation permet de réduire la dimension du problème tout en conservant l'information essentielle. Le choix du nombre de modes r est généralement effectué en fonction de l'énergie cumulée capturée, définie comme la somme des valeurs propres retenues rapportée à la somme totale.

Généralement, la décomposition POD est utilisée pour construire une base réduite orthonormale permettant de représenter les champs solutions des équations aux dérivées partielles (EDP). Dans une approche dite POD **intrusive**, les équations gouvernantes sont projetées sur cette base réduite, afin d'obtenir un système d'équations de dimension réduite, dont la résolution est significativement moins coûteuse que celle du problème initial [15].

Dans le cadre de ce stage, une approche POD **non intrusive** est adoptée. Contrairement à l'approche intrusive, la base POD n'est pas directement introduite dans les équations gouvernantes. Elle est utilisée pour représenter les champs de sortie dans un espace de dimension réduite [15]. Le modèle d'apprentissage est alors entraîné à prédire les coefficients associés aux différents modes de la décomposition, plutôt que les champs réels définis sur le maillage complet. Les champs physiques peuvent ensuite être reconstruits à partir des coefficients prédits et de la base réduite. Cette approche permet ainsi de réduire considérablement la dimension de l'espace de sortie du modèle d'apprentissage, tout en conservant les principales structures spatiales contenues dans les solutions éléments finis.

La section qui suit présente un cas jouet permettant d'illustrer la logique de cette méthode.

4.1.2 Application à un cas jouet

Afin de vérifier la bonne implémentation de la technique, on applique la POD un cas unidimensionnel très simple. On résout numériquement l'équation de la chaleur suivante :

$$\frac{\partial u}{\partial t} - D\frac{\partial^2 u}{\partial x^2} = 0, \quad t \in [0,1]\,,\, x \in [0,1] \tag{1}$$

Avec la valeur $D = 0.05$ les conditions suivantes :

$$u(t=0,\, x) = \begin{cases} 1 & \text{si} \quad x \in [0.4, 0.6] \\ 0 & \text{sinon} \end{cases}$$
$$u(t,\, 0) = u(t,\, 1) = 0, \quad \forall t \in [0,1]$$

On résout numériquement le problème par la méthode des différences finies sur le domaine $\{(t,x) \mid t \in [0,1] \text{ et } x \in [0,1]\}$. Pour ce type d'équation, la condition de stabilité $2.D.\Delta t \leq \Delta x^2$ doit être vérifiée par le pas de temps et de l'espace. Alors pour combiner la présentation fine de la solution et la convergence du schéma, les nombre d'incréments choisis pour le temps et l'espace doivent être suffisamment élevés. Par conséquent la matrice des snapshots est de grande taille et prend plus d'espace en mémoire, ce qui suscite l'intérêt de la présenter dans un espace réduit, en minimisant la perte d'information induite par la réduction de dimension. On prend dans ce cas $N_t = 500$ incréments de temps et $N_x = 200$ incréments points de l'espace. Les snapshots de la fonction solution sont calculés sur une matrice $\mathbb{U}$. Le tracé de la fonction solution à des instants différents $t_1, t_2, \ldots, t_m$ est présenté sur la figure (5)

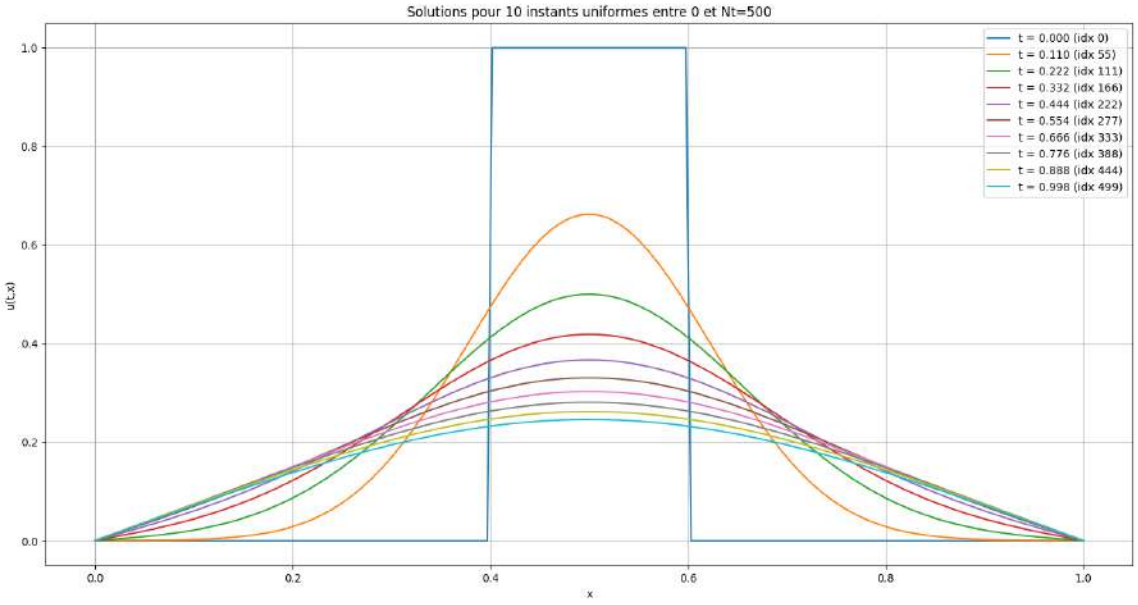
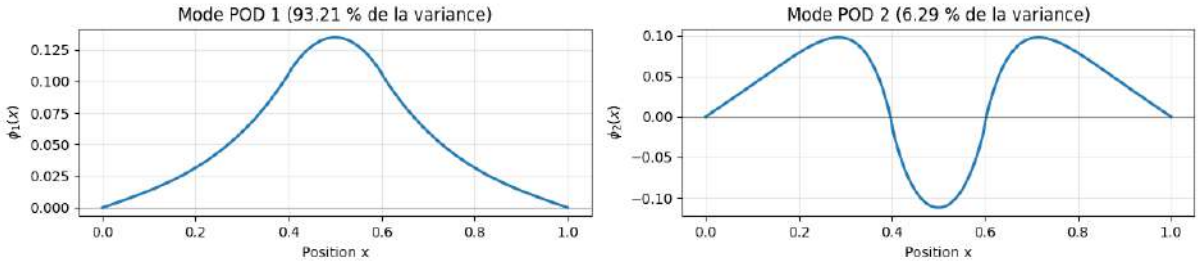
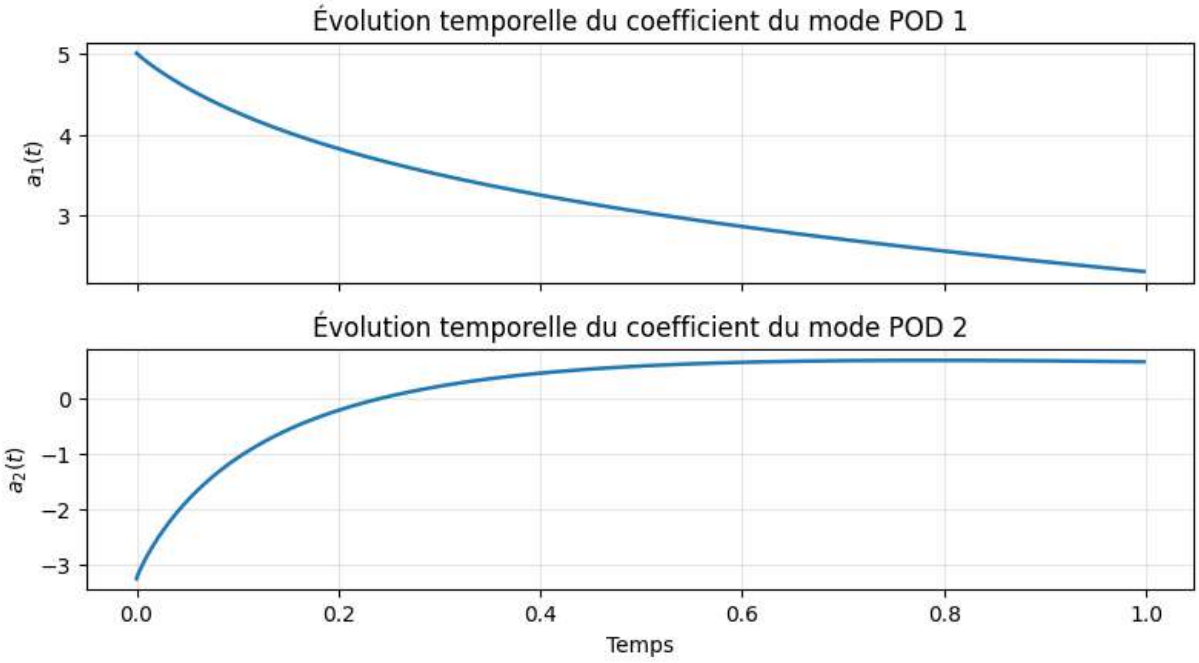


FIGURE 5 – Tracé de la solution de l'équation (1) à différents instants

Les tracés des modes propres de cette fonction et de l'évolution temporelle de ses contributions modales sont présentés respectivement sur les intervalles $[0, 1]$ en fonction de la variable d'espace x et $[0, 1]$ en fonction du temps t.



(a) Tracé des 2 premiers modes propres de la solution de l'équation (1)



(b) Tracé de l'évolution temporelle des contributions modales des 2 premiers modes propres de la solution de l'équation (1)

FIGURE 6 – Visualisation de la décomposition POD de la solution de l'équation (1)

La figure (7) présente l'évolution de la variance expliquée de l'information physique totale contenue dans la matrice des snapshots $\mathbb{U}$ en fonction du nombre de modes sélectionnés, ainsi que le taux de variance expliqué par chacun des premiers 10 modes. Dans ce cas jouet, la sélection des modes sera basée uniquement sur le critère de la variance expliquée, en imposant un seuil sur cette quantité. Par exemple, on fixe un seuil de 99.99% de la variance totale et on conserve le minimum de modes qui expliquent ce seuil. Ceci emmène à une réduction de dimension vers 5 modes. Plus tard, la reconstruction de la solution se fera à partir de ces 5 modes seulement.

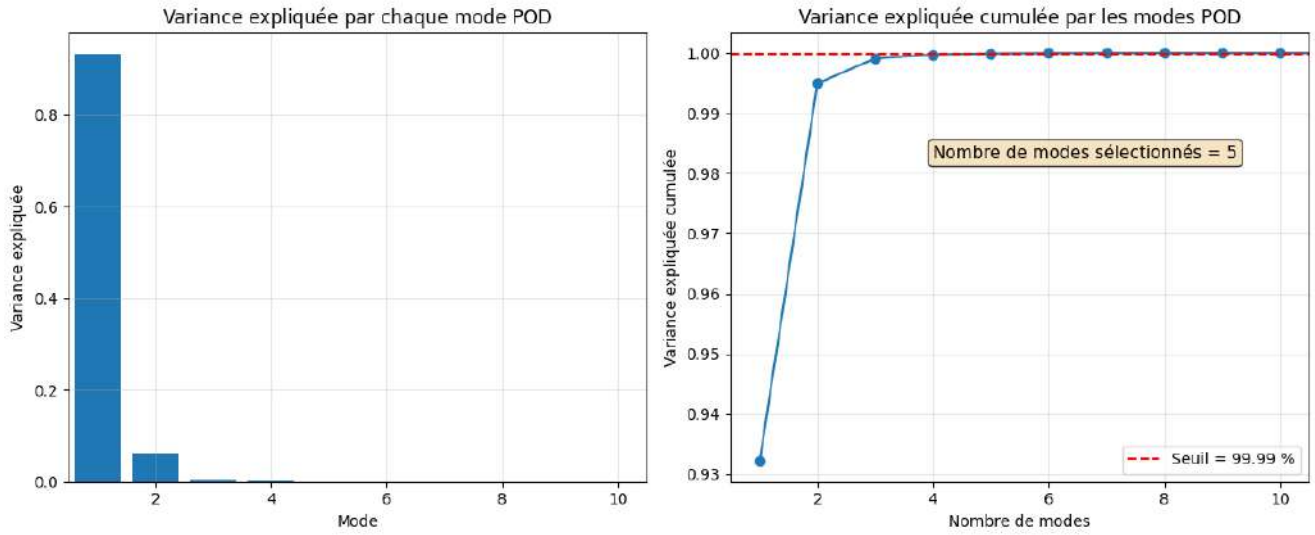
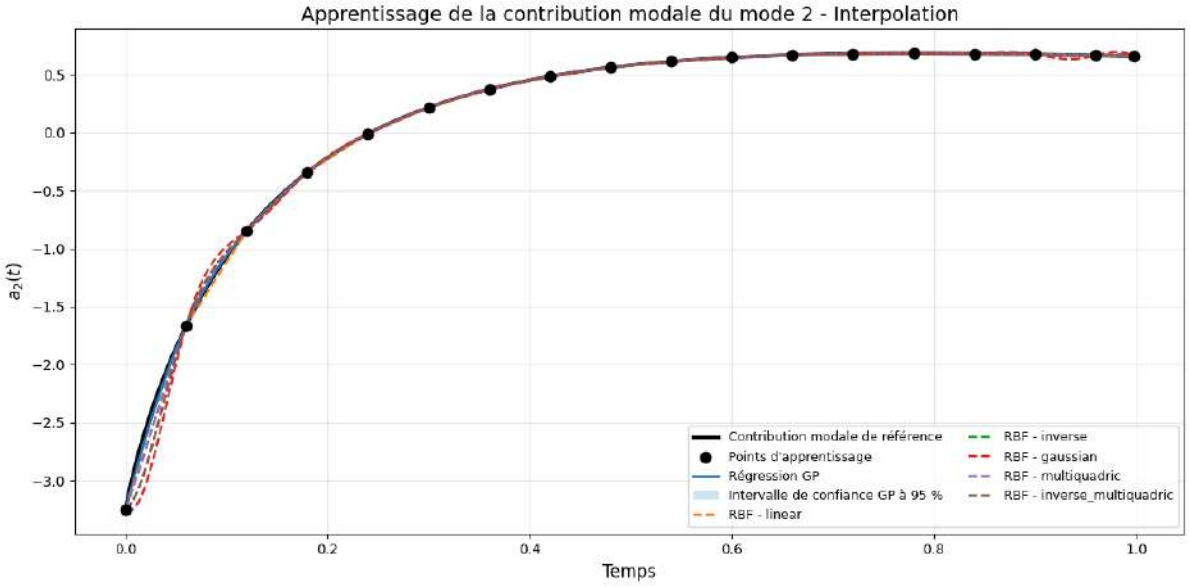
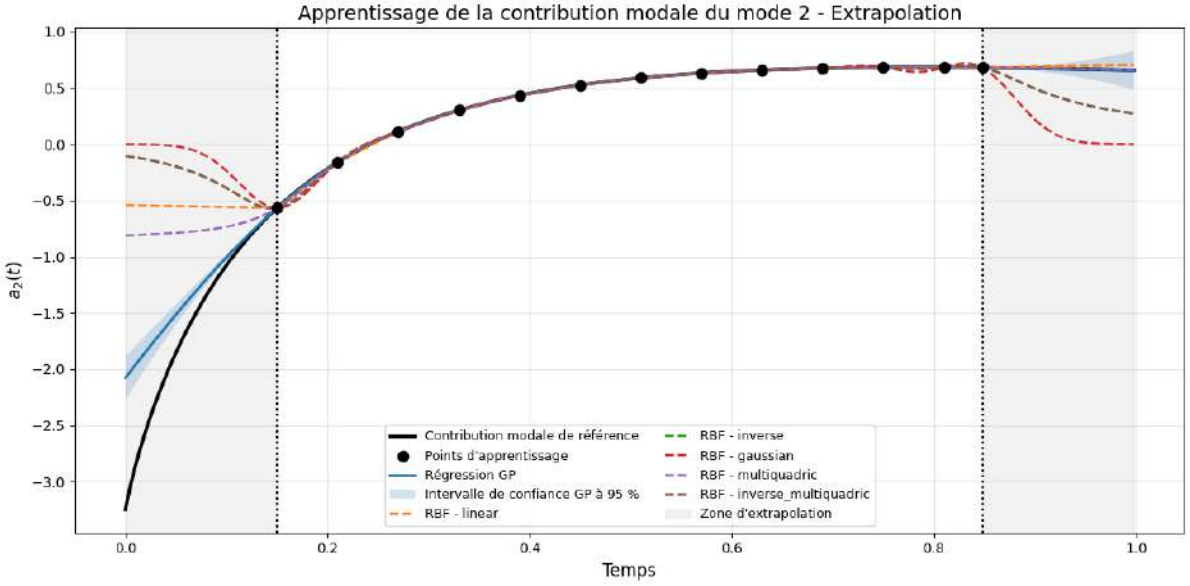


FIGURE 7 – Résultat du code de calcul POD et de la sélection des modes

Une fois la base réduite obtenue par décomposition POD, on cherche à reconstruire la solution à partir d'un nombre limité d'observations des contributions modales associées aux modes retenus. Cette étape permet d'évaluer la capacité d'un modèle de régression à approximer l'évolution temporelle des coefficients modaux, puis à reconstruire le champ physique à partir de la base réduite. Deux approches sont comparées dans cette étude : la régression par processus gaussiens (*Gaussian Process* (GP)) et par fonctions à base radiale (*Radial Basis Function* (RBF)). L'évaluation est menée selon deux configurations distinctes. Dans le cas de l'apprentissage en **interpolation**, les points d'apprentissage sont répartis sur l'ensemble de l'intervalle temporel considéré. À l'inverse, dans le cas de l'apprentissage en **extrapolation**, les observations utilisées pour l'entraînement sont limitées à une portion de l'intervalle temporel. Le modèle est ensuite sollicité en dehors de cette zone afin de prédire l'évolution future ou antérieure des contributions modales. Ce second cas constitue une situation plus contraignante, puisqu'il permet d'évaluer la capacité de généralisation du modèle au-delà du domaine directement couvert par les données disponibles. Afin de comparer quantitativement les différentes méthodes, le score R^2 est retenu comme métrique d'évaluation ; car il permet de quantifier la part de la variabilité de la solution de référence expliquée par le modèle reconstruit, tout en fournissant un indicateur sans dimension facilement comparable entre les différentes méthodes et configurations d'apprentissage. La figure (14) présente un exemple d'apprentissage du deuxième mode de la base retenue avec les différents modèles, dans les deux configurations



(a) Apprentissage en interpolation



(b) Apprentissage en extrapolation

FIGURE 8 – Tracé de l'apprentissage du deuxième mode avec les différents modèles dans les deux configurations

L'histogramme (9) présente les résultats de la comparaison entre les modèles testés dans les deux configurations. On observe que tous les modèles ne sont pas performants en extrapolation, en plus que généralement l'incertitude de prédiction augmente pour les processus gaussiens. Dans le cas de ce problème jouet, la régression par processus gaussiens est la plus performante. En plus, on observe que les noyaux RBF présentent des niveaux de performances différents d'un mode à un autre.

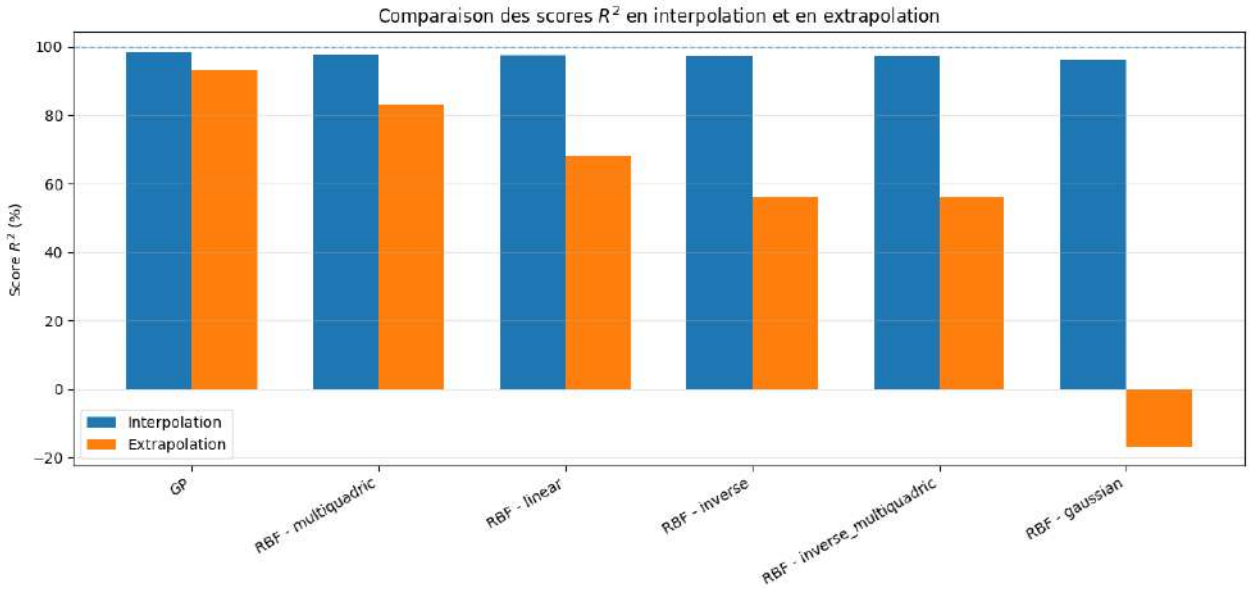


FIGURE 9 – Comparaison des différents modèles d'apprentissage testés

Une fois les contributions modales apprises, on reconstruit la fonction $u(t, x)$ par POD inverse. La figure (10) présente le résultat obtenu, à titre d'exemple, à l'incrément de temps t_{10}. La figure montre que la qualité de l'apprentissage est très bonne. Par ailleurs on observe des erreurs de prédictions pour certaines valeurs de l'abscisse x. En effet, la fonction prédite prend des valeurs négatives alors que la fonction réelle est à valeurs positives. Cette erreur peut être contournée par exemple en imposant la positivité de la solution, c'est à dire prendre le maximum entre la valeur prédite et zéro.

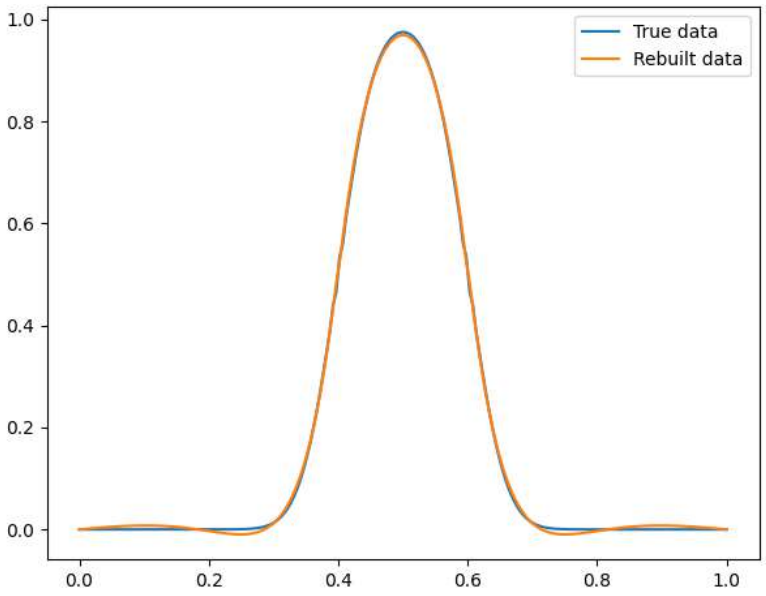


FIGURE 10 – Reconstruction de la solution de l'équation de la chaleur par régression à processus gaussiens sur les contributions modales de la POD

4.2 Méthode MMGP (Mesh Morphing Gaussian Process) [3]

Le MMGP est une méthode de Machine Learning mise en œuvre afin de construire un modèle de substitution pour des simulations définies sur des géométries non paramétrées et des maillages variables. Dans le cas de ce stage, il est utilisé pour prédire des solutions d'équations aux dérivées partielles (EDPs) complexes dont la simulation en éléments finis est coûteuse.

Méthodologie

Cadre théorique On considère un ensemble de domaines $\Omega_1, \Omega_2, \ldots, \Omega_n$ partageant la même topologie et dépendant d'un ensemble de vecteurs de paramètres $\mu_1, \mu_2, \ldots, \mu_n$ gouvernant l'EDP étudiée. Chaque vecteur $\mu_i \in \mathbb{R}^{p+q}$, où $p, q \in \mathbb{N}$, regroupe deux catégories de paramètres :

- p paramètres physiques caractérisant le phénomène étudié (par exemple : viscosité, pression, coefficient de diffusion, propriétés thermiques, etc.) ;
- q paramètres géométriques décrivant la forme ou les dimensions du domaine considéré (longueur, largeur, hauteur, rayon de courbure, etc.). Dans le cas de ce projet, on dispose des paramètres géométriques qui décrivent les formes des domaines étudiés. Par contre, à la base, ces paramètres ne sont pas nécessaires pour le modèle MMGP.

À chaque domaine Ω_i est associée une solution

$$u_i : \Omega_i \to \mathbb{R}, \qquad i = 1, \ldots, n,$$

issue de la résolution de la même EDP paramétrée, sous des conditions aux limites supposées identiques. Cette hypothèse est essentielle afin d'assurer la cohérence physique et mathématique du modèle ainsi que la comparabilité des solutions obtenues.

Pour tout $i \in \{1, \ldots, n\}$, la solution u_i est discrétisée sur un maillage éléments finis $\mathcal{M}_i$ défini sur le domaine Ω_i. Les différents maillages pouvant présenter des géométries et des discrétisations distinctes, l'objectif de la méthode MMGP est de construire un modèle de substitution capable d'apprendre la dépendance simultanée de la solution vis-à-vis des paramètres physiques et de la géométrie du domaine.

Plus précisément, le MMGP vise à approximer l'opérateur paramétré

$$\mathcal{F} : (\mu, \mathcal{M}) \longmapsto u,$$

qui, à un vecteur de paramètres μ et à un maillage $\mathcal{M}$ représentant la géométrie considérée, associe la solution discrétisée u de l'EDP correspondante.

L'enjeu principal de la méthode réside dans le fait que les solutions sont définies sur des maillages. Les maillages étant définis sur des domaines Ω_i de géométries et de dimensions différentes, avec des pas de discrétisation différents, sont potentiellement incomparables. Par conséquent, les données discrètes issues de ces maillages ne sont pas directement comparables, rendant impossible une utilisation brute dans un cadre d'apprentissage supervisé avec des méthodes classiques. La stratégie MMGP consiste alors à projeter ou interpoler les solutions sur une représentation commune permettant leur comparaison et leur apprentissage statistique, avant d'utiliser un modèle de processus gaussien afin de prédire efficacement la solution associée à de nouveaux paramètres ou à de nouvelles géométries.

Mesh Morphing Afin de surmonter la difficulté précédente liée à la variabilité des maillages, une étape de pré-traitement est introduite pour représenter l'ensemble des solutions dans un espace commun de dimension fixe. Cette étape, appelée *Mesh Morphing*, consiste à remodeler les domaines Ω_i vers un domaine de référence $\bar{\Omega}$, afin d'obtenir une famille de maillages remodelés $\bar{\mathcal{M}}_1, \bar{\mathcal{M}}_2, \ldots, \bar{\mathcal{M}}_n$ définis sur un même domaine de référence.

Plusieurs approches permettent de réaliser cette transformation géométrique. Par exemple, l'algorithme de *Tutte's barycentric mapping* (voir l'annexe E) permet de paramétriser les maillages vers le disque unité, tandis que les méthodes basées sur les *Radial Basis Functions* (RBF) (voir l'annexe F) offrent une plus grande flexibilité en permettant le morphing vers des domaines de forme arbitraire.

Cette transformation doit préserver la structure topologique du maillage, en particulier les relations de connectivité entre les nœuds et les éléments. Les nœuds appartenant au bord du maillage initial sont ainsi projetés sur le bord du maillage remodelé, garantissant la conservation de la géométrie relative et de la connectivité. En conséquence, le maillage transformé conserve le même nombre de nœuds et la même structure de discrétisation que le maillage d'origine, mais les coordonnées des noeuds dans les deux maillages sont différents.

Définition du maillage commun sur le domaine de référence : Une fois l'étape de *Mesh Morphing* réalisée, les maillages remodelés demeurent généralement incomparables, car ils peuvent présenter des nombres de nœuds différents ainsi que des connectivités distinctes. Afin de lever cette difficulté, on introduit un maillage commun $\bar{\mathcal{M}}_c$ défini sur le domaine de référence $\bar{\Omega}$. Ce maillage peut être choisi parmi les maillages remodelés $\bar{\mathcal{M}}_i$ issus du *Mesh Morphing*, ou construit indépendamment selon des critères adaptés à la précision recherchée et au coût numérique.

Dans la suite, l'ensemble des quantités physiques d'intérêt sera projeté ou interpolé sur ce maillage commun, fournissant ainsi une représentation uniforme des solutions et permettant leur comparaison ainsi que leur apprentissage statistique.

Transport des quantités d'intérêt vers le maillage commun $\bar{\mathcal{M}}_c$ Une fois le maillage commun $\bar{\mathcal{M}}_c$ défini, l'étape suivante consiste à transporter l'ensemble des solutions discrétisées vers ce support commun afin d'obtenir des représentations homogènes et directement comparables. En effet, les solutions initiales étant définies sur des maillages distincts, elles possèdent généralement des dimensions et des connectivités différentes, ce qui empêche leur utilisation directe dans un cadre d'apprentissage supervisé.

Pour cette raison, chaque solution est interpolée sur le maillage commun $\bar{\mathcal{M}}_c$ à l'aide d'une interpolation éléments finis de type $\mathbb{P}_1$. On obtient ainsi une famille de solutions transportées $\tilde{u}_1, \tilde{u}_2, \ldots, \tilde{u}_n$, toutes représentées dans un espace de dimension fixe et pouvant être exploitées pour l'apprentissage statistique de l'opérateur $\mathcal{F}$.

On introduit les notations suivantes :

- N_i : nombre de nœuds du maillage remodelé $\bar{\mathcal{M}}_i$;
- $\{\bar{\phi}_I^i\}_{I=1}^{N_i}$: base éléments finis $\mathbb{P}_1$ associée au maillage $\bar{\mathcal{M}}_i$;
- $\bar{\mathbf{x}}_I^i$: coordonnées des nœuds du maillage $\bar{\mathcal{M}}_i$;

— N_c : nombre de nœuds du maillage commun $\bar{\mathcal{M}}_c$;

— $\{\bar{\phi}_J^c\}_{J=1}^{N_c}$: base $\mathbb{P}_1$ associée au maillage commun $\bar{\mathcal{M}}_c$;

— $\bar{\mathbf{x}}_J^c$: coordonnées des nœuds du maillage commun $\bar{\mathcal{M}}_c$.

Soit $\mathbf{U}^i \in \mathbb{R}^{N_i}$ une quantité d'intérêt discrétisée sur le maillage initial $\mathcal{M}_i$. Après l'étape de *Mesh Morphing*, cette quantité est représentée sur le maillage remodelé $\bar{\mathcal{M}}_i$ sous la forme éléments finis

$$\bar{\mathcal{U}}^i(\bar{\mathbf{x}}) = \sum_{I=1}^{N_i} U_I^i \bar{\phi}_I^i(\bar{\mathbf{x}}), \tag{2}$$

où $\bar{\mathcal{U}}^i$ désigne le champ associé à la quantité transportée sur le maillage remodelé $\bar{\mathcal{M}}_i$. Ce champ est ensuite interpolé sur le maillage commun $\bar{\mathcal{M}}_c$. L'interpolation s'écrit :

$$\bar{\mathcal{U}}_c^i(\bar{\mathbf{x}}) = \sum_{J=1}^{N_c} \bar{\mathcal{U}}^i(\bar{\mathbf{x}}_J^c)\bar{\phi}_J^c(\bar{\mathbf{x}}) = \sum_{J=1}^{N_c}\sum_{I=1}^{N_i} U_I^i \bar{\phi}_I^i(\bar{\mathbf{x}}_J^c)\bar{\phi}_J^c(\bar{\mathbf{x}}), \tag{3}$$

où $\bar{\mathcal{U}}_c^i$ désigne la représentation finale de la quantité d'intérêt sur le maillage commun.

À l'issue de cette étape, toutes les quantités transportées $\bar{\mathcal{U}}_c^i \in \mathbb{R}^{N_c}$ sont définies sur un support identique et possèdent une dimension commune. Elles deviennent ainsi directement comparables et exploitables dans un cadre d'apprentissage statistique.

Il convient toutefois de noter que, bien que les paramètres physiques d'entrée demeurent inchangés lors du transport, les informations géométriques associées aux maillages initiaux ne sont plus explicitement décrites par la seule quantité transportée. Afin de préserver cette information géométrique, les champs de coordonnées des nœuds des maillages initiaux, notés (X_i, Y_i), sont eux aussi transportés vers le maillage commun à l'aide des relations (2) et (3). Les champs obtenus sont notés $\bar{\mathcal{X}}_c^i \in \mathbb{R}^{N_c}$ et $\bar{\mathcal{Y}}_c^i \in \mathbb{R}^{N_c}$ et constituent une représentation implicite de la géométrie des domaines initiaux dans l'espace de référence.

Réduction de dimension À ce stade, les données transportées peuvent être exploitées par des méthodes d'apprentissage statistique, notamment des modèles de régression de type processus gaussien, pour prédire les solutions associées à de nouveaux paramètres. Toutefois, la dimension élevée du maillage commun, caractérisée par le nombre de nœuds N_c, demeure un obstacle majeur en termes de coût de calcul et de stabilité numérique.

Afin de contourner cette difficulté, une étape de réduction de dimension est introduite à l'aide de la *Proper Orthogonal Decomposition* (POD). Cette méthode permet de projeter les champs transportés sur une base réduite constituée des modes les plus énergétiques, puis de ne conserver que leurs contributions modales dans le modèle statistique.

La réduction de dimension est appliquée aux quantités suivantes :

— le champ des abscisses $\bar{\mathcal{X}}_c^i$, réduit à l_x composantes et représenté par les abscisses réduites $\tilde{X}_i \in \mathbb{R}^{l_x}$. On appelle $\{\Phi_i^x\}_{i=1}^{l_x}$ la base réduite qui leur correspond.

— le champ des ordonnées $\bar{\mathcal{Y}}_c^i$, réduit à l_y composantes et représenté par les ordonnées réduites $\tilde{Y}_i \in \mathbb{R}^{l_y}$. On appelle $\{\Phi_i^y\}_{i=1}^{l_y}$ la base réduite qui leur correspond.

— la quantité d'intérêt $\bar{\mathcal{U}}_c^i$, réduite à l_u composantes et représentée par les coordonnées modales $\tilde{U}_i \in \mathbb{R}^{l_u}$. On appelle $\{\Phi_i^u\}_{i=1}^{l_u}$ la base réduite qui leur correspond.

Entraînement du processus gaussien : Pour l'entraînement du modèle, on n'utilise que les paramètres physiques d'entrée qu'on note $\tilde{\mu}_i \in \mathbb{R}^p$. Les informations sur la géométrie des maillages utilisés sont contenues dans les coordonnées réduites $\tilde{X}_i$ et $\tilde{Y}_i$. Les données d'entrée sont notées $\tilde{Z}_i = (\tilde{\mu}_i, \tilde{X}_i, \tilde{Y}_i) \in \mathbb{R}^p \times \mathbb{R}^{l_x} \times \mathbb{R}^{l_y}$. Les sorties correspondantes du modèle sont les coordonnées réduites des quantités d'intérêt $\tilde{U}_i \in \mathbb{R}^{l_u}$. Autrement dit on cherche à apprendre les fonctions :

$$\tilde{\mathcal{F}}_m \ : \ \tilde{Z}_i \ = \ (\tilde{\mu}_i, \tilde{X}_i, \tilde{Y}_i) \longmapsto \tilde{U}_{i,m} \quad m = 1, 2, \ldots, l_u$$

Cette fonction est apprise par une régression à processus gaussiens. On part d'un ensemble d'entraînement $\mathcal{D} = \{(\tilde{Z}_i, \tilde{U}_i)\}_{i=1}^n$. Pour chaque composante $m = 1, 2, \ldots, l_u$, on apprend la fonction $\tilde{\mathcal{F}}_m$ par krigeage, puis pour un nouveau jeu de paramètres d'entrée $\tilde{Z}^*$, on prédit la contribution modale $\tilde{U}_m(\tilde{Z}^*)$.

Déduction de la solution pour une nouvelle valeur d'entrée : Soit $\mu^* \in \mathcal{R}^{p+q}$ un nouveau jeu d'entrée pour lequel on cherche à prédire la solution de l'EDP. On utilise les notations suivantes :

- $\tilde{\mu}^* \in \mathbb{R}^p$ le jeu de paramètres physiques qui correspond à μ^*,
- $\mathcal{M}^*$ maillage de test qui correspond aux nouveaux paramètres géométriques,
- $\bar{\mathcal{M}}^*$ le maillage remodelé qui correspond à $\mathcal{M}^*$
- $(\tilde{X}^*, \tilde{Y}^*)$ les coordonnées réduites de $\mathcal{M}^*$ transportées vers le maillage de référence fixé précédemment $\bar{\mathcal{M}}_c$, calculées dans Φ^x et Φ^y.

Par ce qui précède on prédit les valeurs des contributions modales de la solution dans la base Φ^u, qu'on note $\tilde{U}_m^*$, pour tout $m = 1, 2, \ldots, l_u$. Ensuite, on déduit la solution sur le maillage commun $\bar{\mathcal{M}}_c$ par POD inverse via l'approximation

$$\bar{U}_c^* = \sum_{m=1}^{l_u} \tilde{U}_m^* \, \Phi_m^u$$

Cette solution est ensuite interpolée sur le maillage remodelé $\bar{\mathcal{M}}^*$. On utilise simplement l'interpolation $\mathbb{P}_1$ en éléments finis. De cette manière on obtient la solution prédite.

La figure (11) de l'article [3] illustre un schéma expliquant le processus complet :

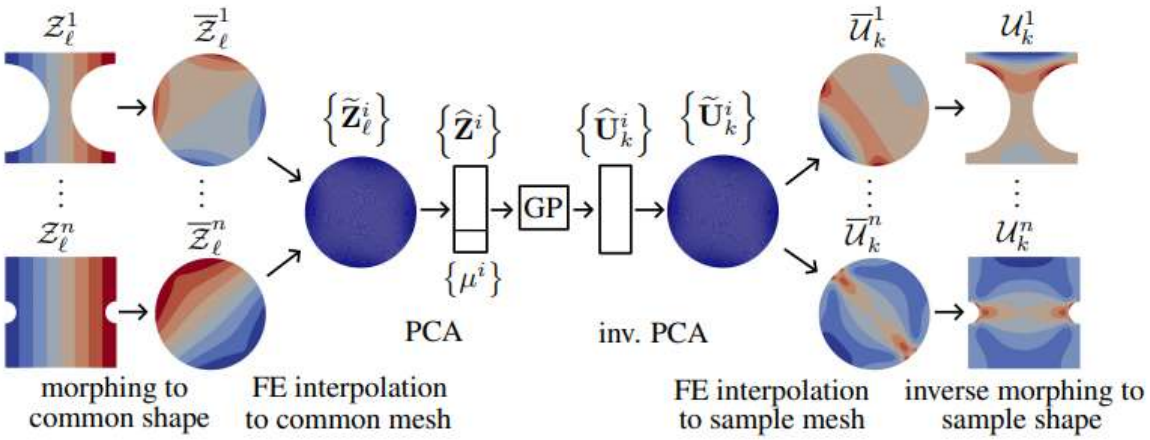


FIGURE 11 – Algorithme MMGP [3]

5 Etapes suivies dans l'implémentation de la solution

5.1 Définition des variables et leurs plages de variations

Comme expliqué dans la section (2.1), les inputs du modèle représentent les grandeurs physiques qui gouvernent le comportement rhéologique de la gomme lors de son écoulement dans le système de cylindres, ainsi que les grandeurs géométriques qui contrôlent la taille du domaine d'étude. L'analyse complète du modèle utilisé par l'entreprise implique 19 paramètres. Pour des raisons de confidentialité, ces paramètres ne seront pas présentés. Dans cette étude, seulement 8 paramètres sont considérés comme variables dans l'entraînement du modèle de substitution, dont 6 sont des paramètres physiques et 2 sont géométriques. Les grandeurs restantes sont maintenues constantes à des valeurs fixées par défaut. Le tableau (1) résume les plages de variation de chacun des inputs du modèle de substitution :

	Paramètre	Intervalle
Paramètres géométriques	Paramètre g_1	$[0.02, 0.5]$
	Paramètre g_2	$[0.0001, 0.00035]$
Paramètres physiques	Paramètre p_1	$[0.5, 4]$
	Paramètre p_2	$[293.15, 373.15]$
	Paramètre p_3	$[293.15, 373.15]$
	Paramètre p_4	$[150000, 350000]$
	Paramètre p_5	$[0.1, 0.3]$
	Paramètre p_6	$[601.35, 962.17]$

TABLE 1 – Intervalles de variation des paramètres géométriques et physiques.

5.2 Construction du plan d'expériences

Le choix du plan d'expériences constitue une étape déterminante dans la construction d'un modèle d'apprentissage par régression GP. En effet, la qualité du modèle dépend directement de la pertinence et de la répartition des points utilisés pour son apprentissage : un échantillonnage insuffisamment représentatif peut conduire à une mauvaise approximation du comportement du système dans certaines régions du domaine d'étude. Dans le cadre de ce projet, l'objectif est d'obtenir une représentation globale du phénomène sur l'ensemble de l'espace des paramètres, sans privilégier a priori une zone particulière. Le choix s'est donc porté sur un **plan d'expériences de type Latin Hypercube Sampling (LHS) à discrépance optimisée**. Cette méthode permet d'assurer une bonne stratification des variables tout en recherchant une distribution aussi uniforme que possible des points dans l'espace multidimensionnel. La minimisation de la discrépance contribue ainsi à limiter les zones sous-échantillonnées ou les regroupements excessifs de points, ce qui favorise une exploration homogène du domaine [12].

On prend un ensemble d'entraînement de 350 observations, et un ensemble de test de 25 observations. Les deux ensembles sont construits à partir de deux plans d'expériences indépendants pour qu'ils puissent couvrir tout l'ensemble. Sinon, si les deux ensembles

sont tirés d'un même plan d'expériences de taille 375 observations, des zones du domaine risquent d'être prises uniquement par les points de test au détriments des points d'entraînement. Une partie des projections bidimensionnelles du plan utilisé est présentée sur la figure (12). On observe que certaines projections bidimensionnelles peuvent présenter des zones apparemment peu ou non échantillonnées. Ce phénomène est inhérent à la dimension élevée de l'espace de recherche : dans un hypercube à huit dimensions, un nombre fini de points ne peut assurer une couverture parfaitement homogène dans l'ensemble des projections deux à deux. Par ailleurs, la propriété de stratification du LHS garantit principalement une répartition uniforme selon chaque variable prise individuellement, sans imposer une uniformité parfaite dans toutes les projections bidimensionnelles. Les régions vides observées localement ne traduisent donc pas nécessairement une insuffisance du plan, mais constituent une conséquence attendue de la malédiction de la dimensionnalité et de la représentation d'un espace multidimensionnel à travers des projections en deux dimensions.

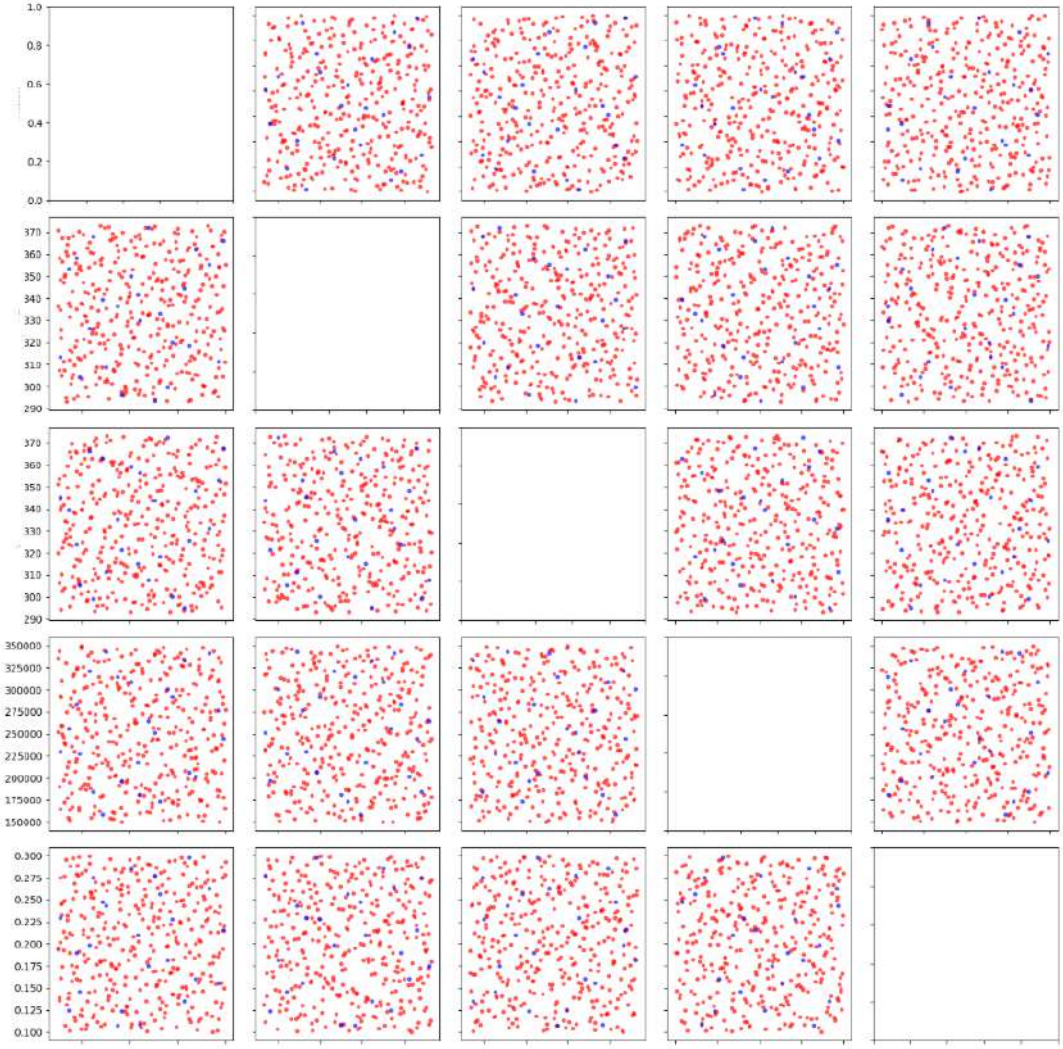


FIGURE 12 – Plan d'expériences utilisé

Comme vu dans le cas jouet étudié dans la section (4.1.2), la régression à processus gaussiens est très mauvaise en extrapolation. Pour cette raison, on s'intéresse à visualiser la distribution des ensembles d'entraînement et de test pour chaque variable. Comme le

montre la figure (13), la distribution est uniforme sur le même intervalle pour toutes les variables.

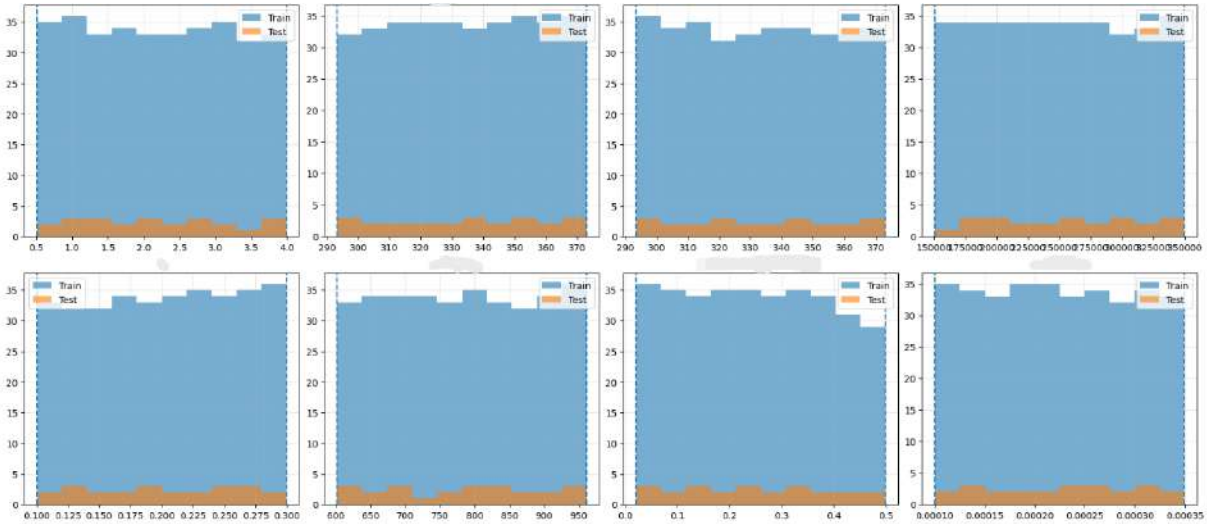
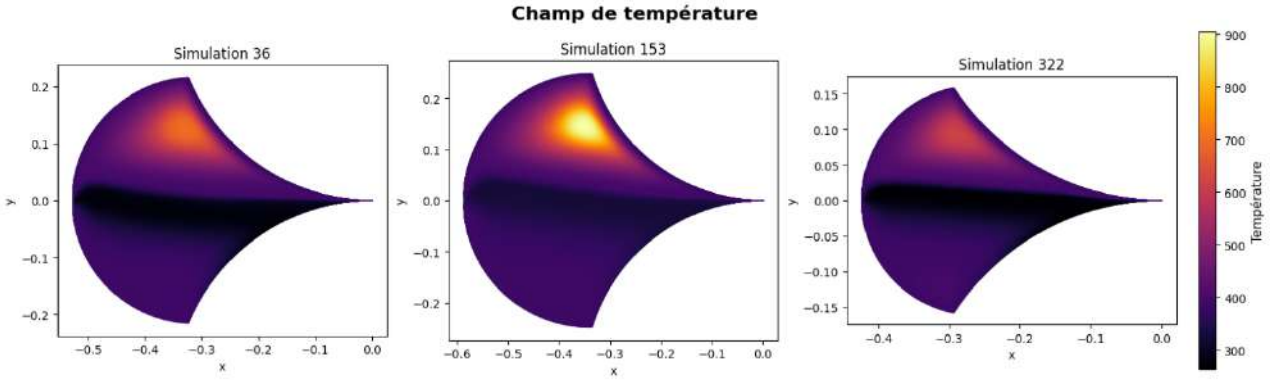


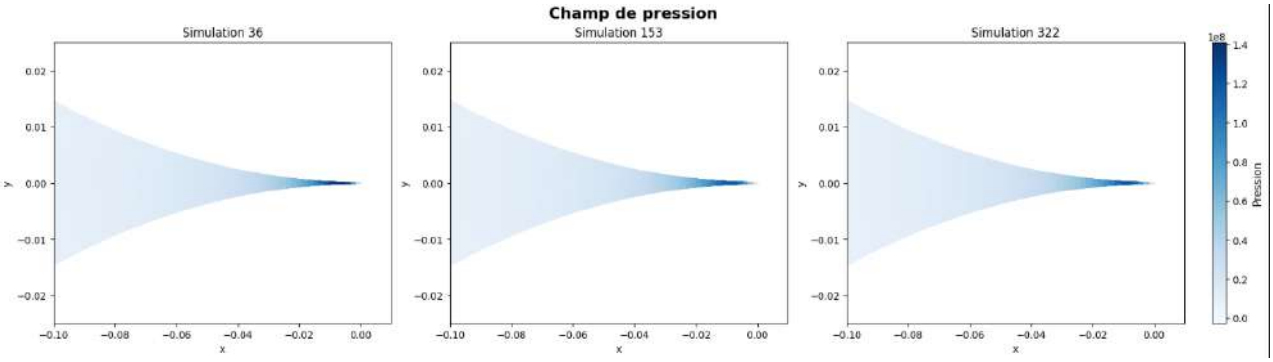
FIGURE 13 – Distribution de chaque variable dans l'ensemble d'entraînement et de test

5.3 Calcul des solutions éléments finis et visualisation des données

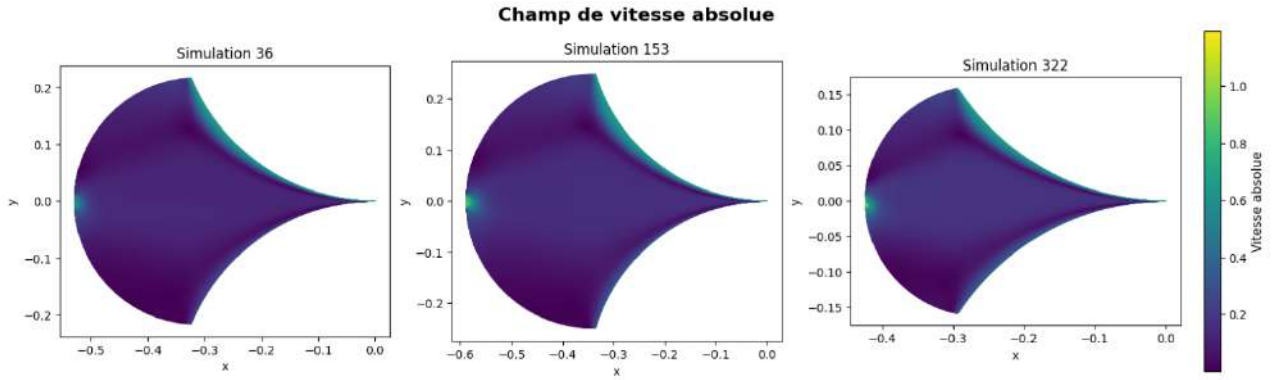
Le calcul des solutions par éléments finis dans chaque point se fait par un logiciel de simulation éléments finis interne. L'accès au code de calcul n'est pas autorisé pour des raisons de confidentialité et de sécurité d'information. Par contre, une interface Python permettant d'appeler le code et de lancer le calcul est fournie. Avant l'implémentation de la solution, on commence par la visualisation de quelques résultats. Cette étape permet d'avoir une idée préliminaire des champs physiques qu'on cherchera à prédire ainsi que de comprendre qualitativement des phénomènes qui y apparaissent. La figure (6) présente quelques exemples de champs physiques de la base d'entraînement



(a) Visualisation des champs de température



(b) Visualisation des champs de pression



(c) Visualisation des champs de vitesse

FIGURE 14 – Tracé des champs physiques dans quelques points d'observation

Dans la figure (14a), le champ de température est fortement non uniforme et asymétrique. On observe une zone chaude localisée dans la partie supérieure du domaine, tandis que la partie inférieure reste nettement plus froide. La position et surtout l'intensité de ce maximum varient entre les simulations.

Concernant le champ de pression dans la figure (14b), celui-ci apparaît beaucoup plus homogène sur la majeure partie du domaine. Les seules variations observées sont concentrées au niveau de l'entrefer (extrémité droite du domaine), où un gradient localisé est visible. La dynamique de pression est donc caractérisée par une variation localisée.

Enfin, le champ de vitesse dans la figure (14c) absolue présente une organisation spatiale assez reproductible entre les simulations. Les vitesses sont relativement faibles

dans la partie centrale, tandis que des valeurs plus élevées apparaissent le long de certaines frontières, en particulier sur la paroi supérieure convergente, ainsi qu'à proximité des extrémités du domaine. Ces zones correspondent également à des gradients de vitesse plus importants.

5.4 Mesh Morphing

Dans cette phase du modèle, la première question qui se pose, c'est le domaine qui sera pris comme référence. Dans l'article [3], le domaine de référence choisi est le cercle unitaire, cependant, un choix qui s'impose comme deuxième possibilité est de prendre un domaine de la base d'entraînement. L'idée vient du fait que le transport des champs vers un domaine complètement différent de leur support d'origine peut fortement les déformer lors de l'interpolation sur la grille de référence ; car probablement des points qui sont à la base proches peuvent devenir éloignés. Pour relever le défi posé par ce choix, les deux possibilités sont testées, les résultats obtenus sont comparés quantitativement. Concernant le Mesh Morphing vers un maillage de la base d'entraînement, une deuxième problématique se pose : quel individu est le meilleur pour être sélectionné comme référence. Pour répondre à cette question, on fait l'exploration de l'ensemble de domaines disponibles, on sélectionne un nombre de domaines bien choisis à tester, ainsi qu'un ensemble sur lequel on fera le test et l'évaluation avec des métriques quantitatives.

5.4.1 Méthodes testées

L'algorithme de Tutte est une méthode classique de paramétrisation permettant de transformer un maillage surfacique simplement connexe en un domaine plan convexe, tout en conservant sa connectivité [14, 5]. Son principe consiste à fixer les sommets du bord du maillage sur une frontière convexe, généralement un cercle ou un polygone, puis à déterminer les coordonnées des sommets intérieurs comme des combinaisons barycentriques de leurs sommets voisins. Cette formulation conduit à la résolution d'un système linéaire creux pour les coordonnées dans le domaine paramétrique (voir annexe E).

Le RBF Mesh Morphing est une technique de déformation de maillage fondée sur l'interpolation par fonctions de base radiales (Radial Basis Functions, RBF) [1, 11]. Le principe consiste à prescrire le déplacement d'un ensemble de points de contrôle, généralement choisis sur les frontières de la géométrie, puis à construire une fonction d'interpolation permettant de propager ces déplacements de manière continue vers l'ensemble des nœuds du maillage. Le déplacement d'un point est ainsi exprimé comme une combinaison de fonctions radiales dépendant de sa distance aux points de contrôle, éventuellement complétée par un terme polynomial (voir annexe F). Cette approche permet de générer efficacement différentes configurations géométriques à partir d'un même maillage de référence et peut traiter des déformations en deux ou trois dimensions. La qualité du maillage déformé dépend cependant du choix de la fonction RBF, de la disposition des points de contrôle et de l'amplitude de la transformation [1, 11].

5.4.2 Comparaison des méthodes

On commence par tester les domaines d'étude contenus dans la base d'entraînement afin de déterminer la meilleure référence dans cet ensemble. Comme expliqué dans la

section (5.1), les domaines sont contrôlés par deux paramètres g_1 et g_2. On sélectionne 5 maillages bien répartis de cet ensemble pour les tester comme référence. Le test est effectué uniquement sur une vingtaine de maillages eux aussi bien répartis dans l'ensemble. La figure (15) présente la distribution des domaines de la base d'entraînement dans le plan $g_1 - g_2$:

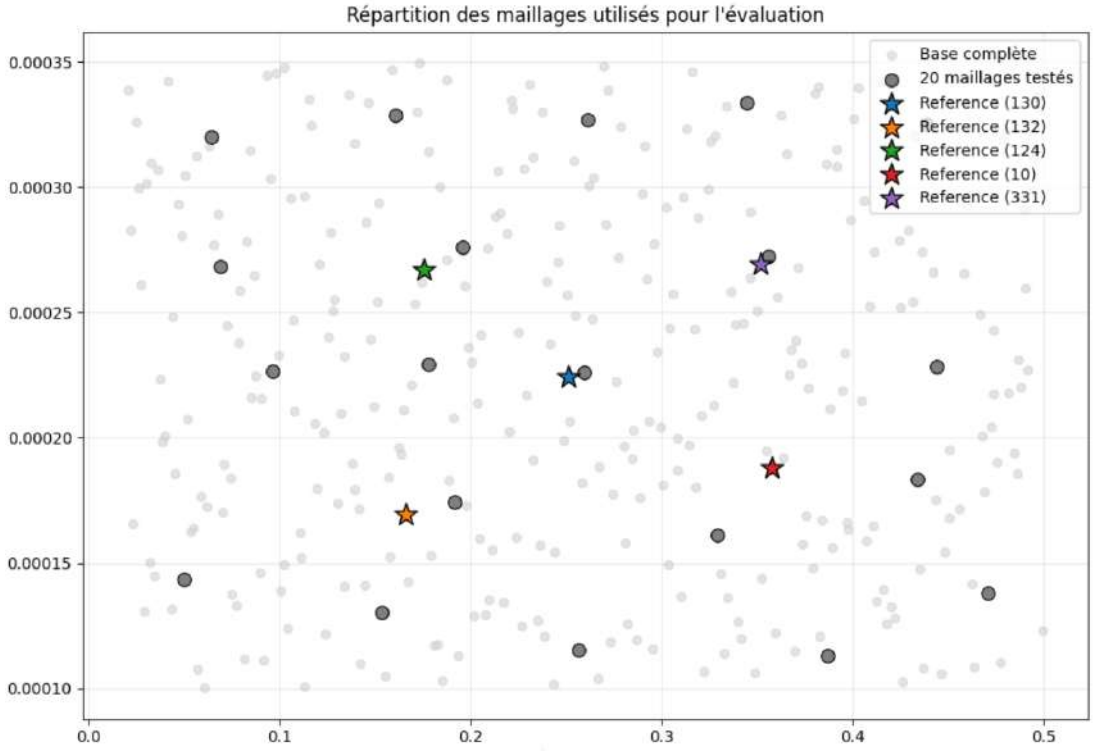


FIGURE 15 – Distribution des domaines d'étude et repérage des domaines pris comme référence et les domaines testés

Le maillage en bleu (d'indice 130) est pris dans la médiane de la distribution. Les quatre autres domaines sont piochés dans les quatre zones du pavé $[0.02, 0.5]\times[1\times10^{-4}, 3.5\times10^{-4}]$. On compare à quel point l'information physique contenue dans les champs physiques testés est-elle conservée par le transport vers chacun des 5 domaines. La comparaison est quantifiée par un nombre de métriques qu'on cite ci dessous :

— **Distance de Wasserstein**. qui est généralement utilisée pour comparer des distributions, qui est donnée par l'expression

$$W_1(\mu,\nu) = \inf_{\gamma\in\Pi(\mu,\nu)} \int_{\mathbb{R}\times\mathbb{R}} |x-y| \, \mathrm{d}\gamma(x,y)$$

On choisit d'utiliser cette métrique parce qu'on considère que les champs physiques qu'on cherche à comparer peuvent être vus comme des distributions. Vu que les domaines sont de tailles différentes, on procède par pondérer les triangles de chaque maillage par leur taille afin que les mesures soient comparables.

— **Conservation de la moyenne et de la variance des champs physiques**. cette comparaison consiste à comparer la valeur moyenne et la variance de chaque champ avant et après son transport vers le maillage de référence. Pour quantifier cette comparaison, on utilise comme métrique l'erreur relative.

— **Conservation de la régularité des champs physiques**. pour cette comparaison, on évalue la semi-norme H^1. Cette grandeur permet de caractériser l'intensité globale des variations spatiales du champ à travers son gradient :

$$|u|_{H^1(\Omega)} = \left(\frac{1}{|\Omega|} \int_\Omega \|\nabla u(\mathbf{x})\|^2 \, \mathrm{d}\Omega \right)^{1/2}$$

Une valeur élevée de cette semi-norme traduit la présence de variations spatiales importantes, tandis qu'une valeur plus faible correspond à un champ plus régulier. Pour chacune des 20 simulations utilisées dans l'étude, on compare les valeurs de la semi-norme H^1 obtenues avant et après transport permet ainsi de quantifier la capacité de chaque maillage de référence à préserver la régularité du champ. Pour chaque référence, les écarts ont ensuite été moyennés sur l'ensemble des 20 simulations.

L'objectif de cette analyse n'est pas de mesurer une erreur de reconstruction point à point, mais d'identifier le maillage de référence induisant la plus faible modification des propriétés physiques des champs.

Le Mesh Morphing vers les cinq domaines de la base d'entraînement se fait par le **RBF Mesh Morphing**. Les points de contrôle sont pris uniformément sur le bord du domaine, on prend au total 1400 points. Et on prend comme fonction RBF la fonction linéaire $\phi : r \to r$. Cette méthode est implémentée par un simple appel à la fonction `RBFInterpolator` du module `scipy.interpolate` de Python. La figure (16) présente un exemple de Mesh Morphing appliqué à un domaine de la base d'entraînement vers le domaine 130 situé à la médiane :

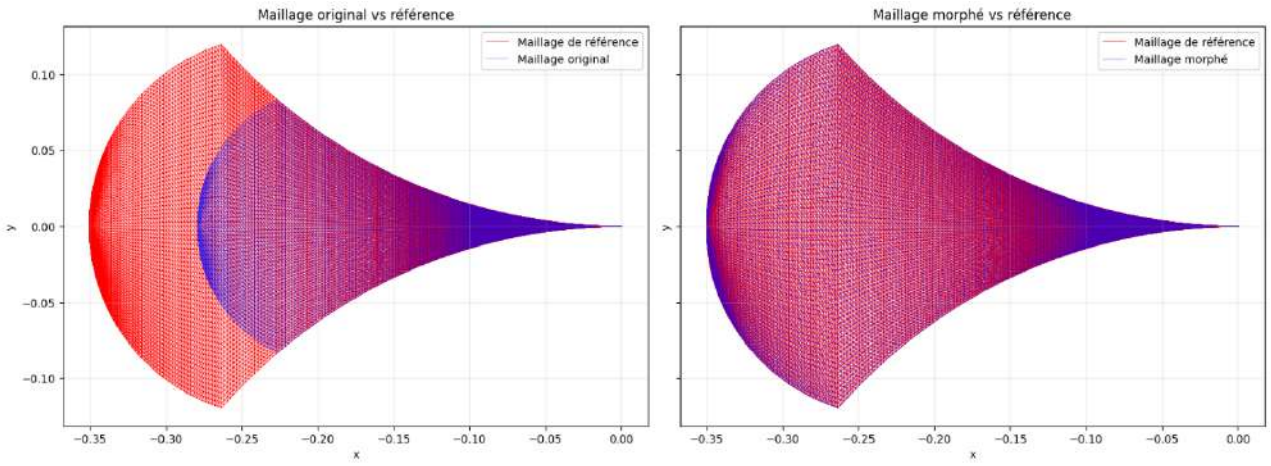
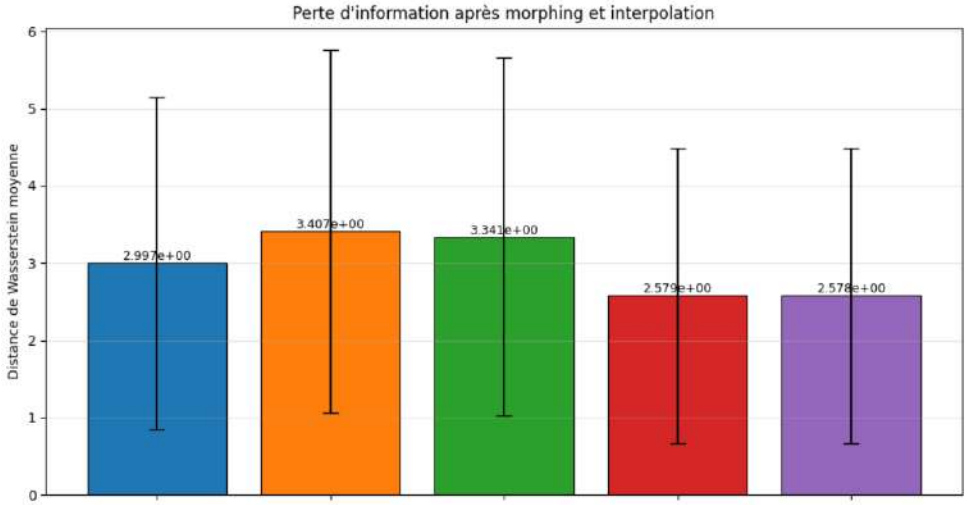
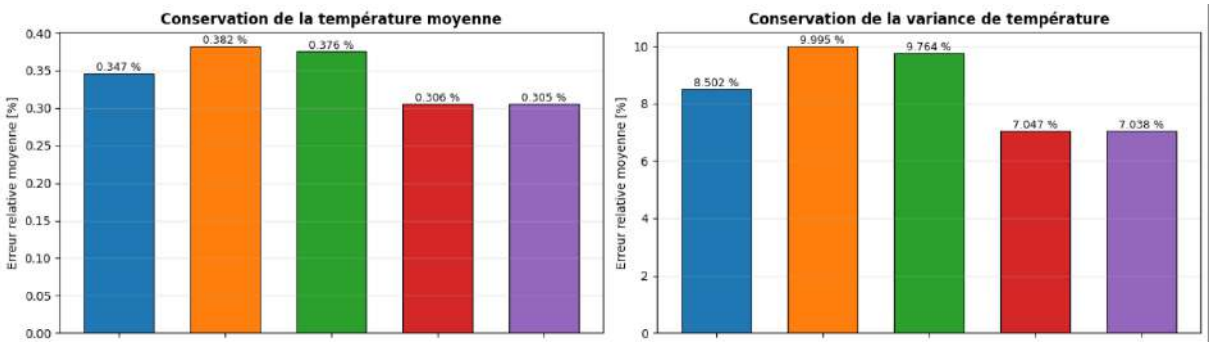


FIGURE 16 – Exemple du Mesh Morphing RBF appliqué à un maillage de la base l'entraînement

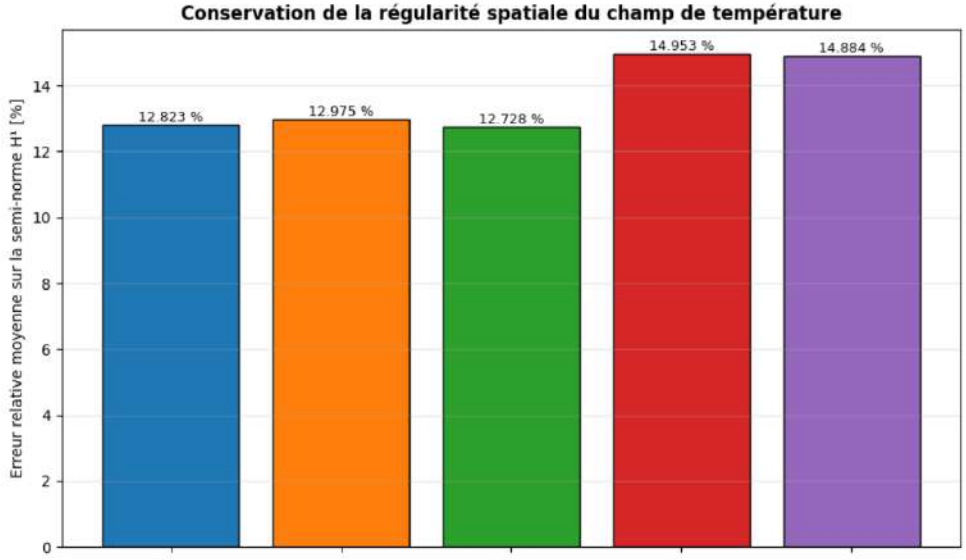
A titre d'exemple, la comparaison décrite précédemment est faite en se basant sur les champs de température. La figure (17) présente les résultats obtenus lors de cette comparaison.



(a) Distance de Wassertein, avec les écart-types de la distribution pour chaque domaine de référence



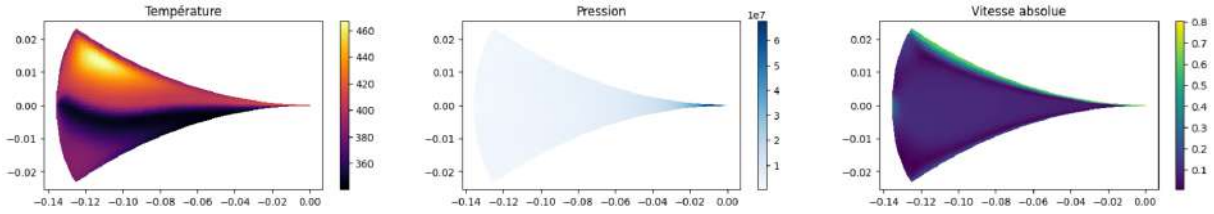
(b) Comparaison des quantités physiques



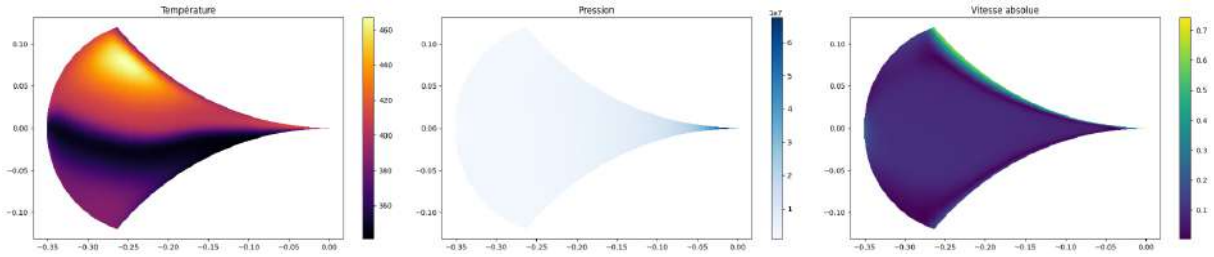
(c) Comparaison de la régularité

FIGURE 17 – Comparaison des domaines de référence en se basant sur des métriques quantitatives

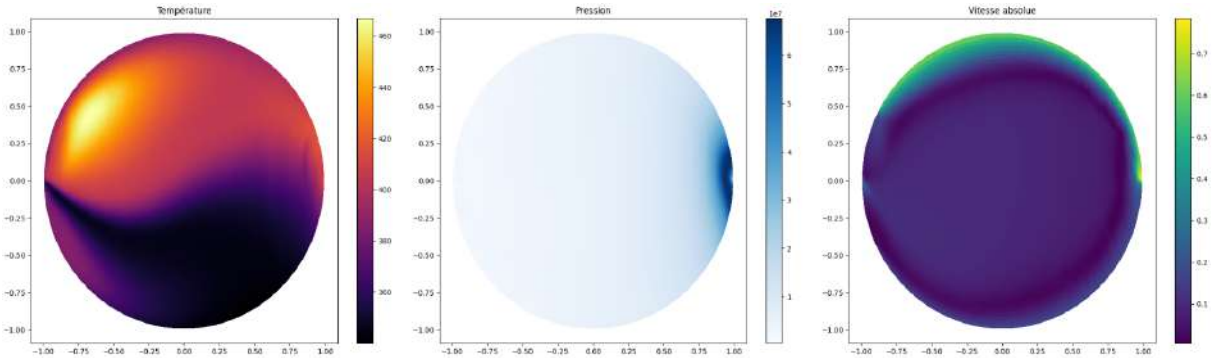
D'après la figure (17), la comparaison précédente montre qu'il n'y a pas de différence remarquable entre les domaines et qu'il n'y a pas un domaine qui se distingue par une excellence dans tous les critère. Pour cette raison, on opte pour le choix qui fait le compromis entre toutes les métriques. Ainsi, on choisit le domaine 130 situé à la médiane comme référence. On garde comme maillage de référence celui qui a été défini initialement sur ce domaine, ce qui conduit à l'utilisation de champs de taille 13 125. On passe maintenant à comparer ce domaine avec le disque unité utilisé dans l'article [3]. Un point essentiel à tenir en considération, c'est que le Mesh Morphing présente généralement des défauts : triangles repliés, orientation de triangles inversée, nœuds situés en dehors du domaine de référence, coordonnées légèrement déplacées, etc. La gestion de ce genre d'erreur est prise en considération dans le choix de la référence. Quelques exemples de champs transportés sur les deux domaines de référence sont présentés sur la figure (18) :



(a) Champs réels



(b) Champs transportés puis interpolés sur le maillage de référence défini sur le domaine médiane



(c) Champs transportés puis interpolés sur le maillage de référence défini sur le disque unité

FIGURE 18 – Champs physiques obtenus par transport vers les domaines de références comparés

L'analyse visuelle met en évidence une différence nette entre les deux stratégies de transport. D'après la figure (18b) lorsque les champs sont morphés puis interpolés vers le

maillage de référence médian, leur organisation spatiale reste globalement proche de celle observée sur les champs réels. Les principales zones de température élevée, les gradients de pression et les régions de forte vitesse conservent une localisation et une structure cohérentes malgré la modification géométrique. À l'inverse, dans la figure (18c), le transport vers le disque unité impose une déformation beaucoup plus importante du domaine. Les structures physiques restent reconnaissables, mais leur répartition spatiale est déformée, en particulier pour la température et la vitesse. Cette transformation plus sévère peut donc introduire une altération plus marquée de l'organisation spatiale des champs. Cette observation devra néanmoins être confirmée par des métriques quantitatives.
La comparaison directe des champs après transport est délicate dans ce cas, car les deux représentations sont définies sur des domaines géométriquement différents. Afin d'évaluer de manière plus objective la perte d'information introduite par chaque stratégie, un transport aller-retour est réalisé. Pour chaque simulation, le champ initial est d'abord transporté vers le domaine de référence considéré, puis interpolé dans le sens inverse afin de reconstruire le champ sur son maillage d'origine. Le champ reconstruit et le champ initial sont ainsi définis sur le même support géométrique et sur les mêmes degrés de liberté. Cette procédure permet de mesurer directement la part d'information qui n'est pas conservée au cours des opérations de morphing et d'interpolation, indépendamment du changement de domaine de représentation. Dans cette comparaison, on fait appel aux mêmes métriques utilisées précédemment. Les résultats sont présentés dans la figure (19)

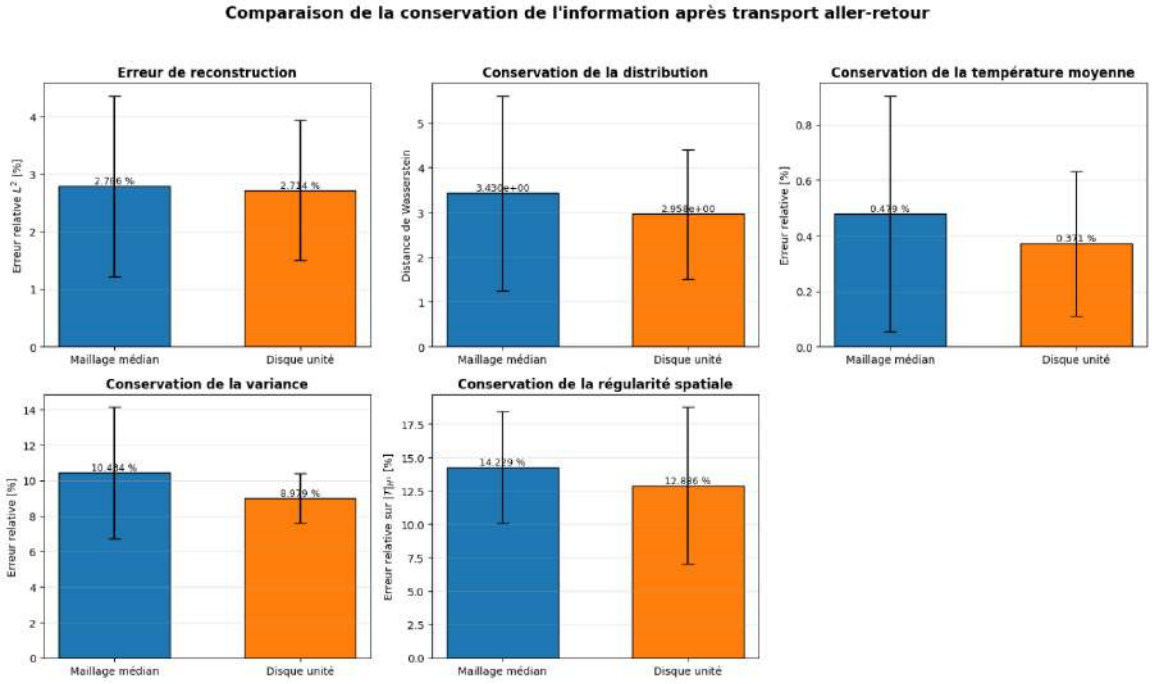


FIGURE 19 – Comparaison de la qualité de transport des champs vers le maillage circulaire et le maillage médian

La comparaison précédente n'ayant pas mis en évidence de différence majeure entre les deux stratégies en termes de conservation de l'information après transport aller-retour.

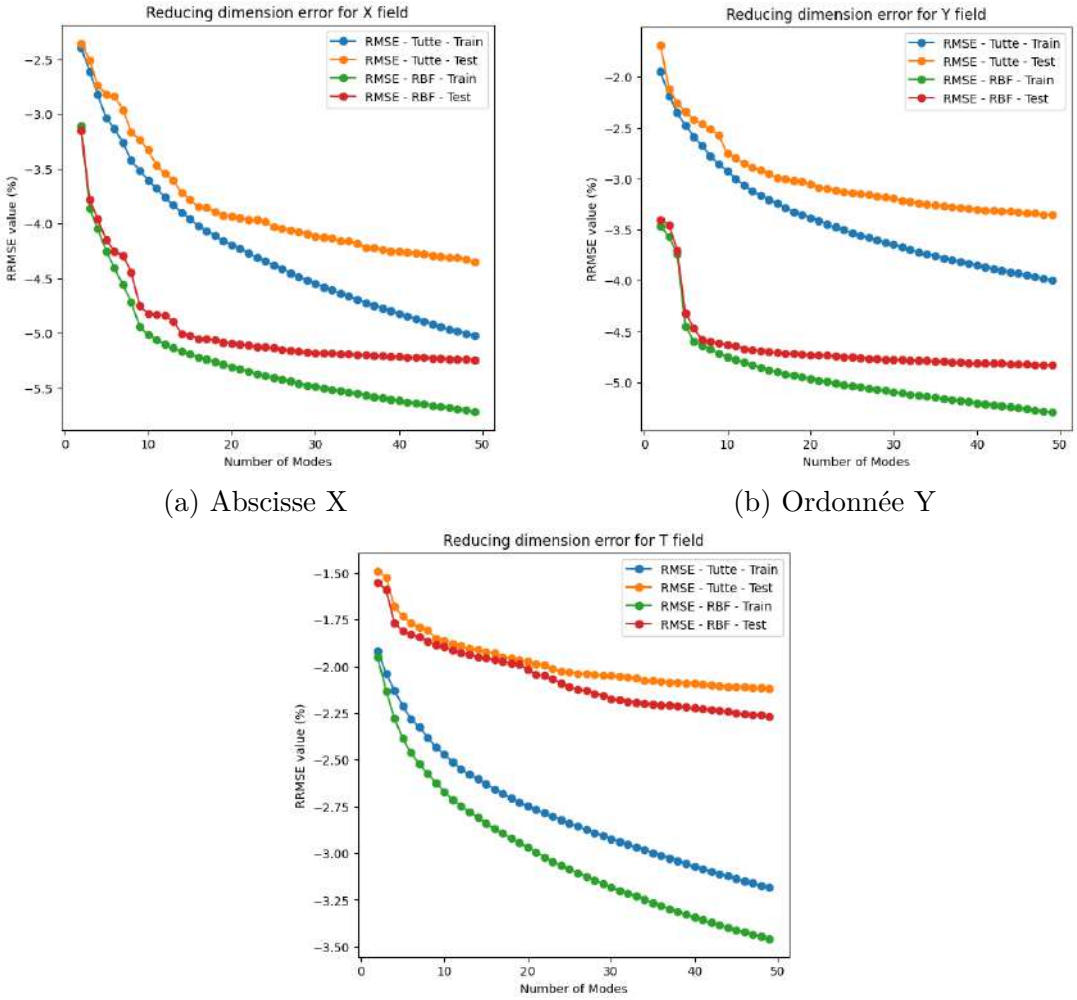
Vu que l'étude précédente n'a pas abouti à un résultat, on passe à étudier un autre critère : **l'aptitude à la réduction dimensionnelle**, c'est à dire, comment évolue la perte d'information physique en terme de nombre de modes retenus lors de la réduction de

dimension par POD qui sera utilisée dans le modèle. Vu que les systèmes de coordonnées x et y seront réduits et utilisés comme varaible d'entrée du modèle, ils seront aussi inclus dans cette étude. La figure (20) présente le résultat de cette étude pour les systèmes de coordonnées x et y, et le champ de température T. La métrique utilisée est *Relative Root Mean Square Error* (RRMSE), donnée par la formule suivante :

$$RRMSE(U_{ref}, U) = \sqrt{\frac{1}{n^*}\sum_{i=1}^{n^*}\frac{\frac{1}{N_i}\|U^i_{ref} - U^i\|_2^2}{\|U^i_{ref}\|_\infty^2}} \tag{4}$$

Avec, dans l'expression (4), les termes U_{ref} et U_{enc} désignent respectivement le champ d'origine et le champ obtenu après l'encodage-décodage, n^* désigne le nombre total de champs qu'on évalue, N_i est le nombre total de noeuds dans le i-ème champ, la norme $\|.\|_2$ désigne la norme euclidienne dans l'espace $\mathbb{R}^{N_i}$, définie par $\|x\|_2^2 = x_1^2 + x_2^2 + \cdots + x_{N_i}^2$, et la norme infinie $\|.\|_\infty$ définie sur $\mathbb{R}^{N_i}$ par $\|x\|_\infty = max_{i=1}^{N_i}|x_i|$.

Vu que les valeurs de l'erreur sont petites, on la visualise en utilisant l'échelle logarithmique :



(a) Abscisse X

(b) Ordonnée Y

(c) Température T

FIGURE 20 – Comparaison des erreurs moyennes RRMSE de la réduction de dimension par POD pour les deux types de Mesh Morphing, pour l'ensemble d'entraînement et de test

Les champs transportés vers le maillage médian par morphing RBF présentent globalement une décroissance plus rapide de l'erreur et des erreurs de reconstruction plus faibles que ceux transportés vers le disque unité par la paramétrisation de Tutte. Cette différence est particulièrement marquée pour les champs associés aux coordonnées X et Y, tandis qu'elle est plus modérée pour le champ de température. Ces résultats indiquent que la représentation sur le maillage médian conduit à des données plus compressibles et apparaît ainsi mieux adaptée à la construction du modèle réduit. Le tableau suivant résume tous les résultats de la comparaison des deux approches :

Critère	**Transport vers le disque unité (mapping de Tutte)**	**Transport vers le maillage médian de la base**
Domaine cible	Disque unité, domaine canonique convexe.	Domaine de géométrie représentative de la base d'entraînement, potentiellement non convexe.
Avantages	• Domaine cible simple et standardisé. • Convexité facilitant le transport et l'interpolation. • Paramétrisation commune indépendante de la géométrie initiale. • Bonne conservation globale de l'information physique après transport.	• Géométrie proche de celles présentes dans la base d'entraînement. • Déformations géométriques plus limitées lors du transport. • Bonne conservation de l'information physique. • Meilleure compressibilité des champs observée lors de la réduction par POD.
Inconvénients	• Déformation géométrique importante par rapport au domaine physique initial. • Organisation spatiale des champs davantage modifiée par la transformation. • Compressibilité par POD moins favorable dans les résultats obtenus.	• Domaine non convexe pouvant compliquer certaines étapes d'interpolation. • Risque de points situés légèrement hors du domaine de référence, nécessitant une correction par changement d'échelle. • Construction du morphing dépendante de la définition et de la correspondance des points de contrôle.

TABLE 2 – Comparaison des deux stratégies de transport des champs physiques

Au regard des différentes analyses menées, on choisit de retenir le domaine médian comme domaine de référence. Les comparaisons ont montré une conservation de l'information physique du même ordre que celle obtenue avec le disque unité, tout en préservant une géométrie plus proche des domaines réels. Surtout, les champs transportés vers ce maillage présentent une meilleure compressibilité lors de la réduction par POD. Ce choix constitue ainsi un compromis pertinent entre fidélité physique, représentativité géométrique et efficacité pour la réduction de modèle.

5.5 Transport des champs physiques vers le maillage de référence

Une fois ce traitement accompli, les champs physiques utilisés sont tous transporté vers le maillage morphé puis interpolés sur le maillage de référence, en utilisant la formule (3). Une visualisation des champs obtenus permet de vérifier que le Mesh Morphing est bien fait, que les nouveaux maillages ont la même orientation, que les phénomènes réels sont toujours observables, et que les maillages sont comparables. La figure (21) présente le surf des champs de la température T, de pression P et de la norme de la vitesse (U, V) avant et après le transport et l'interpolation :

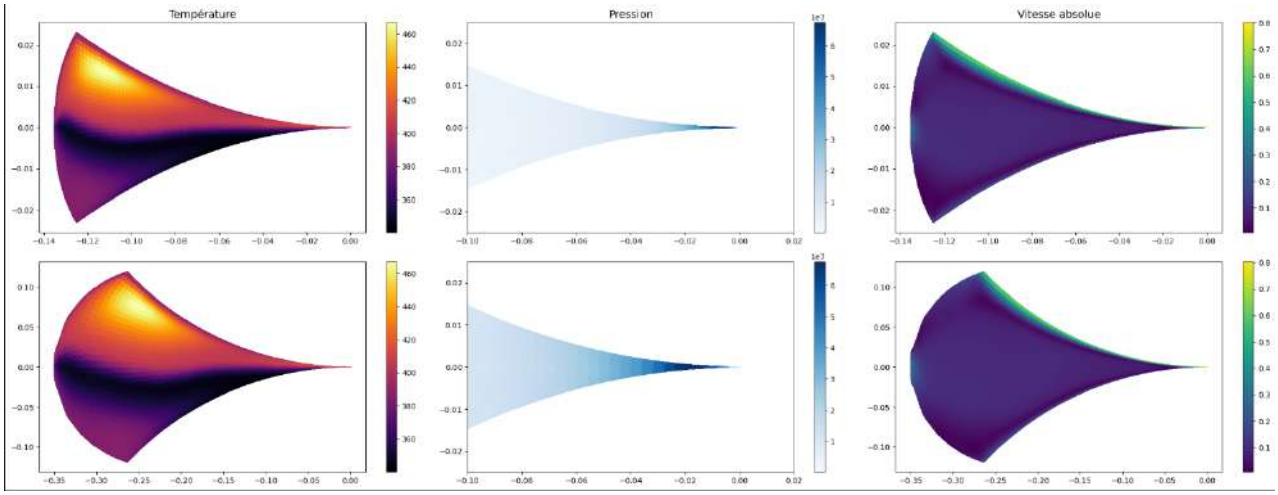
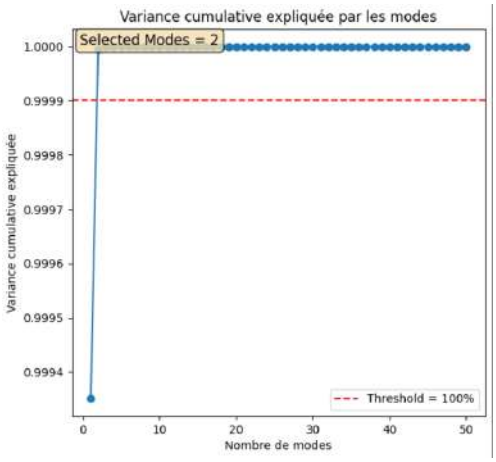


FIGURE 21 – Champs de température T, de pression P et de vitesse (U, V) avant et après le transport et l'interpolation

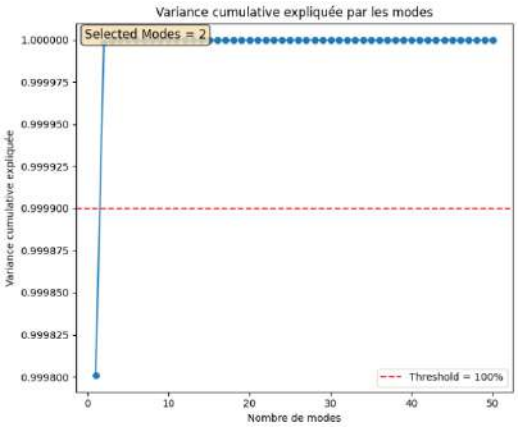
5.6 Réduction de dimension par POD

Comme expliqué dans la section (4.2), une fois les champs transportés sur le maillage de référence, la réduction de dimension a pour rôle de réduire le nombre de composantes à utiliser comme input et à prédire. Par exemple, dans le problème étudié, le maillage de référence est de taille 13 125 noeuds. La prédiction du champ point par point est très coûteuse, pour cette raison on passe par une réduction de dimension par POD, appliquée au champs de coordonnées ainsi qu'aux champs cible transportés sur le maillage de référence. A titre d'exemple, une première étude est menée sur les champs de coordonnées et sur le champ de température. Dans un premier temps, le nombre de modes à retenir est déterminé à partir d'un pourcentage de la variance totale à pouvoir expliquer. Vu que les champs physiques qu'on cherche à encoder ont généralement les mêmes tendances, on

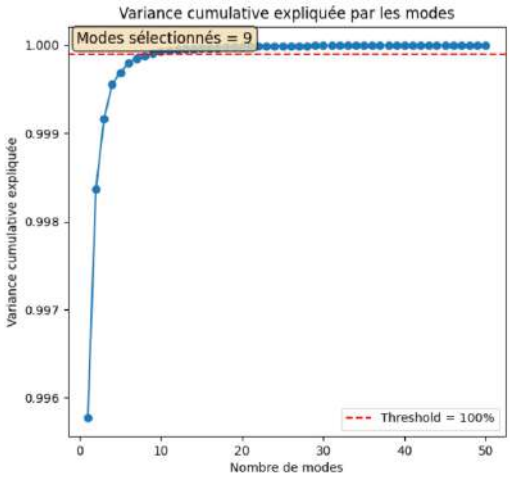
s'attend que la quasi totalité de la variance soit expliquée par le premier mode uniquement. On choisit dans un premier temps comme seuil le pourcentage 99.99%. Le résultat du calcul appliqué aux coordonnées x et y, ainsi qu'au champ de la température T, à titre d'exemple, est présenté sur la figure (22) :



(a) Sélection des modes de la POD pour le champ des abscisses x



(b) Sélection des modes de la POD pour le champ des ordonnées y



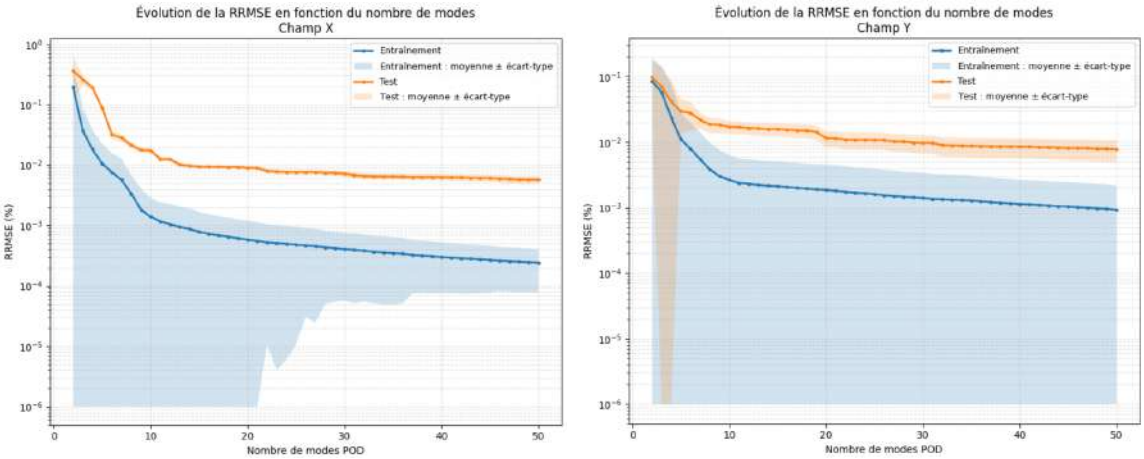
(c) Sélection des modes de la POD pour le champ de la température T

FIGURE 22 – Sélection des modes de la POD par le critère du taux de variance expliqué pour les champs des abscisses x, des ordonnées y et de la température T

A l'issue de cette étape, on dispose des encodages des champs de coordonnées $\{\tilde{X}_i\}$ et $\{\tilde{Y}_i\}$, et de celui du champ de la température $\{\tilde{T}_i\}$. La même analyse est appliquée aussi aux champs de pression P et de vitesse (U, V). La troncature POD permet de retenir 9 modes pour le champ de température, 7 modes pour la pression, et 7 modes pour la vitesse.

L'analyse précédente fait une troncature de 2 modes pour chacune des coordonnées réduites. Par contre, la figure (23) présente l'évolution de la RRMSE des champs encodés par rapport aux champs réels en fonction du nombre de modes retenus pour chaque coordonnée. En observant les courbes de la figure (23a) et (23b), on réalise que l'erreur de réduction de dimension diminue encore lorsqu'on augmente le nombre de modes des

coordonnées réduites $\{\tilde{X}_i\}$ et $\{\tilde{Y}_i\}$ jusqu'à que la diminution devient très lente. A ce stade, on peut considérer que l'erreur plafonne. Alors on s'intéresse aussi à voir comment évolue la distribution de ces erreurs, y compris le bruit qui l'accompagne avant de décider le nombre de modes. La figure (23) illustre cette évolution :



(a) Abscisse X (b) Ordonnée Y

FIGURE 23 – Évolution de l'erreur RRMSE en fonction du nombre de modes retenus pour les champs de coordonnées **en échelle logarithmique**

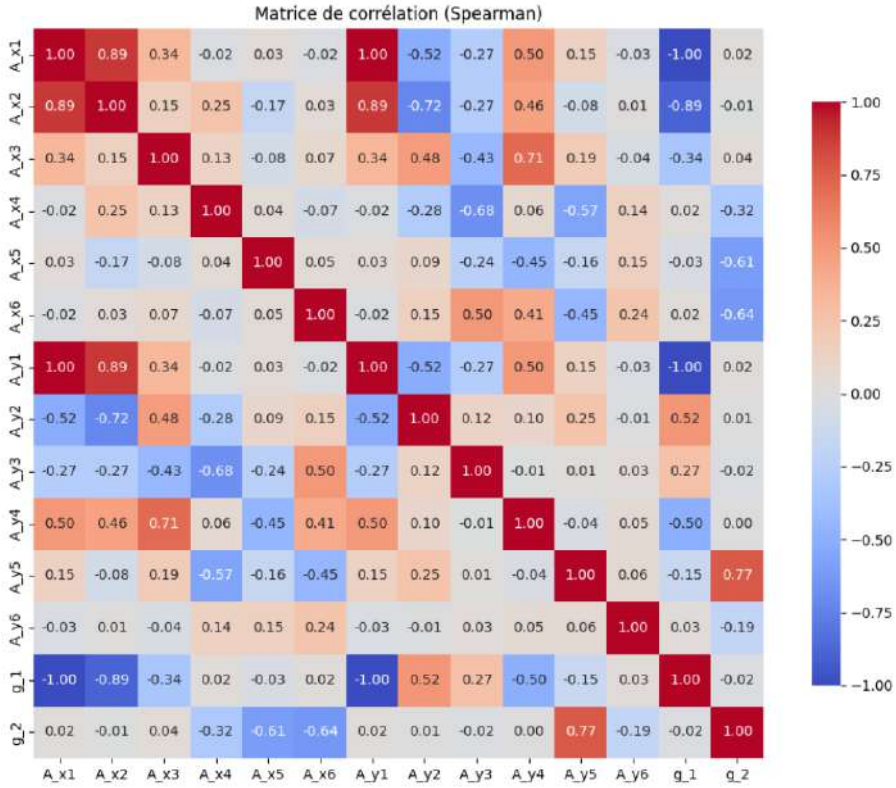
Le choix s'installe sur 6 modes pour chacune des coordonnées, car c'est le nombre minimal de modes pour lequel les erreurs et les écart-type se stabilisent.

5.7 Inspection de la corrélation

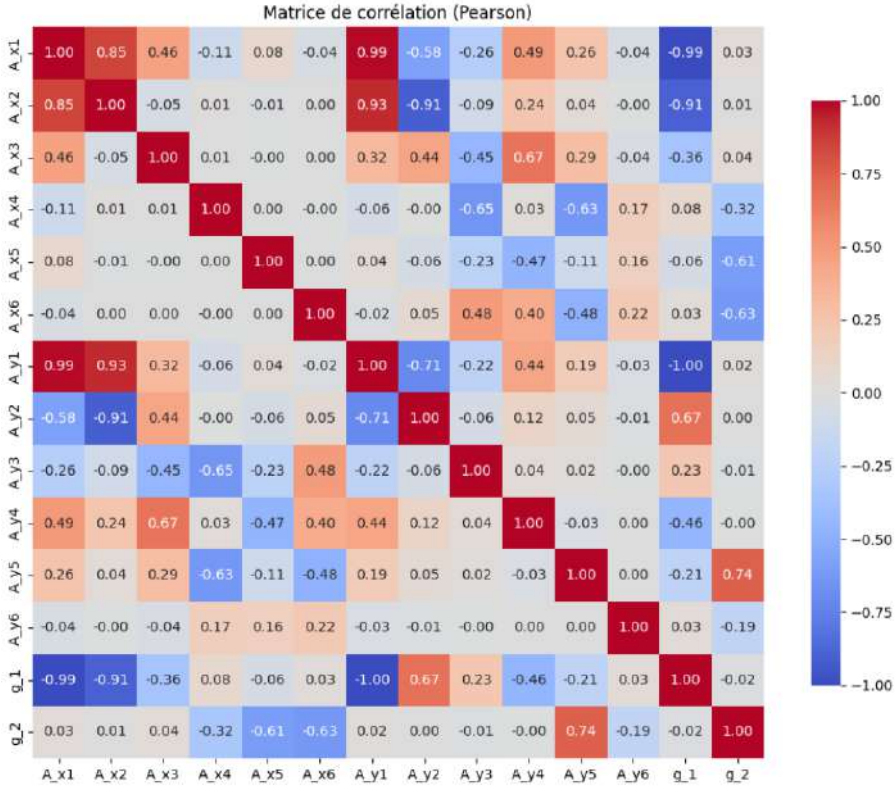
Une fois les coordonnées réduites calculées, on passe à inspecter la corrélation entre les inputs. En effet, des variables fortement corrélées créent de la redondance d'information. Cela peut rendre l'estimation des paramètres du modèle (longueurs d'échelle, variogramme, hyperparamètres) instable et mal identifiée, détériorant la robustesse des prédictions. Un modèle correctement informé sur ces corrélations fournit des intervalles de confiance plus réalistes. Les résultats de l'inspection sont rassemblés dans la matrice sur la figure (24a) et (24b). Un point essentiel qu'on remarque dans ces matrices est qu'elles présentent globalement les mêmes tendances, ce qui suggère que les dépendances entre les paramètres géométriques et les premiers coefficients modaux sont non seulement monotones, mais souvent assez proches de relations linéaires.

Les premiers modes $\tilde{X}_1$ et $\tilde{Y}_1$ dont une corrélation au sens de Spearman égale à 1, ce qui indique qu'ils portent une information extrêmement redondante en termes de classement des géométries. Alors, la variable $\tilde{Y}_1$ sera éliminée du modèle. Cette élimination sera ensuite prouvée dans la section (5.11).

On remarque aussi que le paramètre g_1 est fortement corrélé au sens de Spearman aux premiers modes, donc correspond à une variation géométrique globale, captée très tôt dans la décomposition. Ce qui est très différent de ce qu'on observe pour le paramètre g_2. En effet, ce dernier est plutôt absent des premiers modes puis capturé par des modes plus élevés. Cela montre aussi pourquoi il ne serait pas pertinent de sélectionner les modes uniquement sur leur ordre ou sur leur énergie : un paramètre géométrique physiquement important peut être porté par un mode de relativement faible énergie.



(a) Spearman



(b) Pearson

FIGURE 24 – Matrices de la corrélation

5.8 Implémentation du modèle

A l'issue de la réduction de la dimension des champs utilisés par le modèle, il importe de bien choisir les hyperparamètres du modèle de régression. D'abord, le choix du kernel de la corrélation est basé sur les informations dont on dispose sur la physique de l'écoulement étudié et la régularité des fonctions qu'on souhaite apprendre. En effet, les champs physiques qu'on cherche à prédire sont continus et infiniment dérivables. Le meilleur kernel à vérifier ces propriétés de régularité est le kernel **Matern 5/2** donné par la formule suivante :

$$k_\theta(u,v) = \sigma^2 \prod_{j=1}^{p} \left(1 + \frac{\sqrt{5}\,|u_j - v_j|}{\theta_j} + \frac{5\,(u_j - v_j)^2}{3\theta_j^2}\right) \exp\left(-\frac{\sqrt{5}\,|u_j - v_j|}{\theta_j}\right).$$

Dans un premier temps, un premier modèle, qu'on appelle **MMGP paramétré**, volontairement simple, est considéré en utilisant directement l'ensemble des paramètres d'entrée décrits dans la section(5.1). Le vecteur d'entrée est ainsi constitué de six paramètres physiques auxquels s'ajoutent les deux paramètres géométriques g_1 et g_2. Ce modèle présente l'avantage d'une formulation plus simple et de la préservation de l'information explicite : dans le cadre du projet considéré, l'ensemble des géométries est entièrement décrit par les deux paramètres g_1 et g_2, de sorte qu'il n'est pas nécessaire de représenter la géométrie dans un espace de dimension plus élevée. Cette propriété est particulièrement intéressante dans le contexte de la régression par processus gaussiens, dont les performances peuvent se dégrader lorsque la dimension de l'espace d'entrée augmente.

Ensuite, on teste un second modèle, qu'on appelle **MMGP classique**, bien que plus complexe, qui présente en revanche un caractère plus général et plus flexible. En effet, l'utilisation des coordonnées réduites permet de décrire directement la géométrie du domaine sans supposer que celle-ci soit entièrement caractérisée par un nombre restreint de paramètres géométriques explicitement connus. Cette approche peut ainsi être étendue à des domaines de formes plus variées ou dont la paramétrisation géométrique n'est pas directement disponible. Par ailleurs, comme indiqué dans la section (5.1), certains paramètres géométriques des domaines sont maintenus constants dans le plan d'expériences considéré. Une représentation fondée sur le Mesh Morphing pourrait donc, sous réserve que l'espace d'apprentissage couvre suffisamment les variations géométriques correspondantes, faciliter l'extension du modèle à des configurations dans lesquelles ces paramètres seraient amenés à varier.

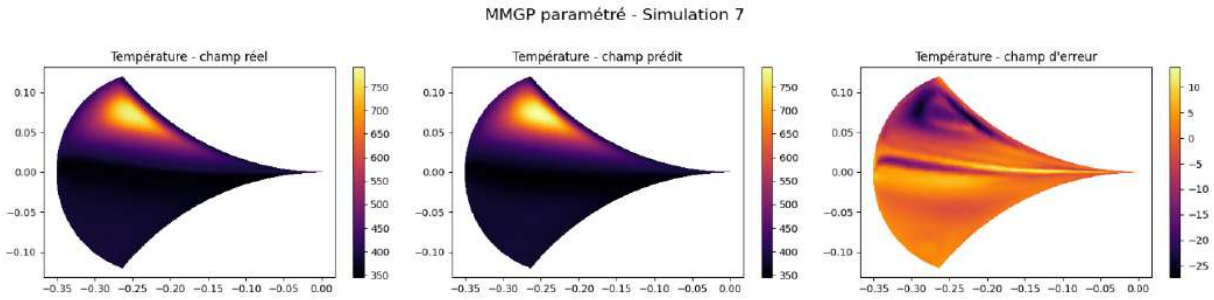
Les deux modèles permettent de prédire les coefficients modaux associés aux modes retenus lors de la décomposition POD, pour chacune des trois grandeurs physiques considérées dans cette étude. Chaque coefficient modal est prédit indépendamment dans l'espace réduit. Le champ physique complet est ensuite reconstruit par projection inverse sur la base POD, selon la même procédure de décodage que celle utilisée pour le cas jouet présenté dans la section (4.1.2). Les résultats de la prédiction sont présentés dans la section (5.9).

5.9 Résultats obtenus

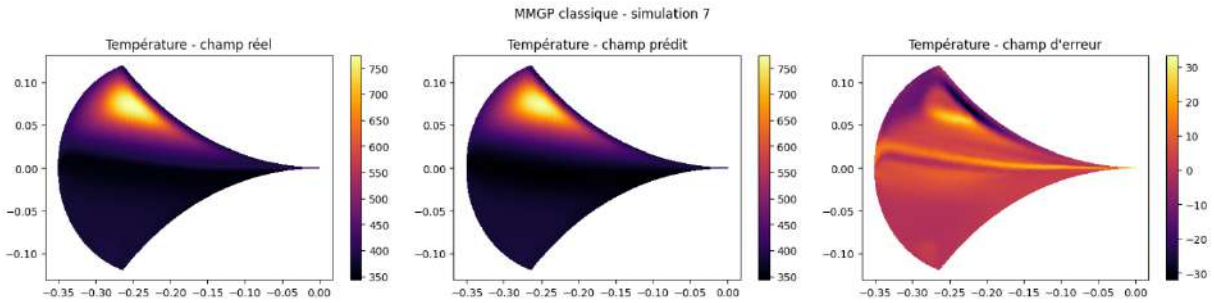
On commence par visualiser les champs reconstruits afin d'évaluer qualitativement la capacité de chaque modèle à restituer les structures physiques. Les champs de température, de pression et de vitesse prédits sont ainsi comparés visuellement aux champs de référence. Cette première analyse permet d'avoir une idée de la qualité des reconstructions, et d'identifier d'éventuelles observations présentant des écarts importants. Dans la section (5.10), la comparaison va être basée sur des métriques quantitaives.Dans ette partie, on présente les champs physiques bidimensionnels reconstruits à partir de cette prédiction.

5.9.1 Prédiction de la température

La figure (25) présente le résultat d'une simulation de l'ensemble de test. On confronte le champ réel et les champs prédits par le modèle, ainsi que les résidus de prédiction.



(a) Résultat obtenu par MMGP paramétré



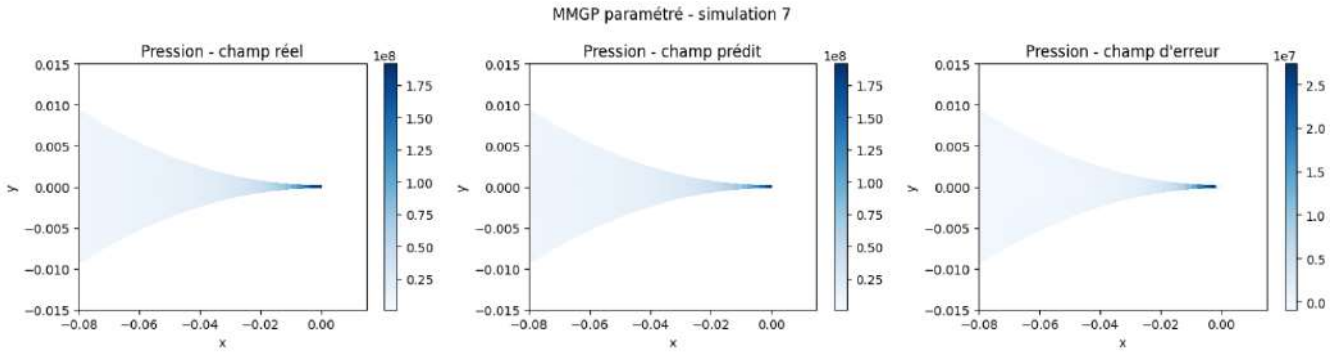
(b) Résultat obtenu par MMGP classique

FIGURE 25 – Résultats de prédiction des champs de température

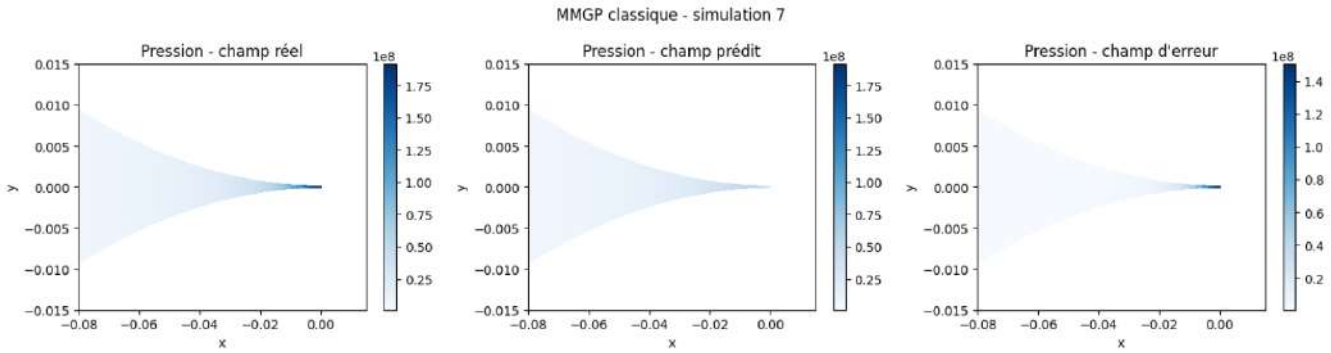
La figure (25) montre que les deux modèles reproduisent correctement les principales tendances du champ thermique. On observe la reproduction du réchauffement situé dans la partie supérieure du domaine, ainsi que la diminution progressive de la température vers l'aval. La zone plus froide observée dans la partie centrale et inférieure est également bien restituée. Les erreurs relatives restent généralement faibles, avec des écarts principalement localisés dans les régions présentant les gradients thermiques les plus marqués. Mais ces écarts sont critiques dans certaines zones où elles dépassent 20°C de différence en valeur absolue dans les deux modèles. On observe également que dans certaines zones, la température est sur-estimée, alors qu'elle est sous-estimée dans d'autres. Toutefois, Le modèle MMGP paramétré reproduit plus fidèlement les structures locales du champ.

5.9.2 Prédiction de la pression

On passe à visualiser les résultats obtenus pour le champ de pression. Ce dernier est particulier parce qu'il y a aucun phénomène que se passe dans la quasi-totalité du domaine d'étude, sauf au niveau de l'entrefer où on observe une compression, dont l'amplitude varie en fonction des inputs. La figure (26) présente un résultat de simulation pour les deux modèles testés.



(a) Résultat obtenu par MMGP paramétré



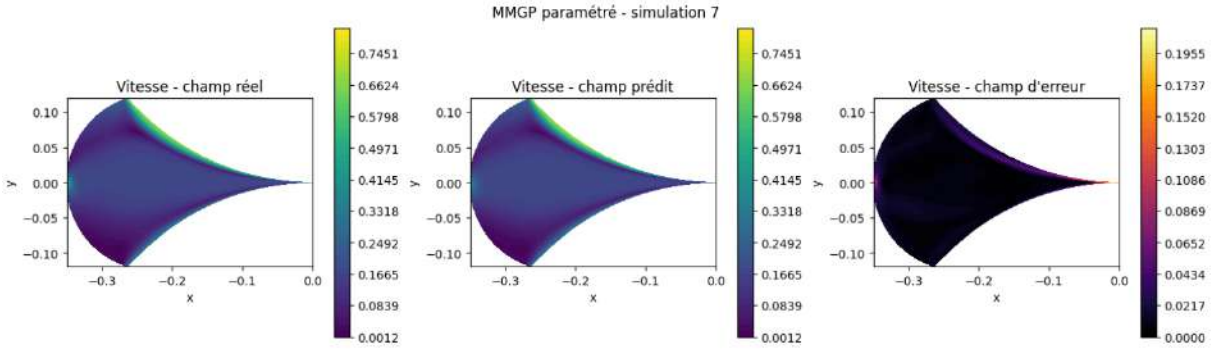
(b) Résultat obtenu par MMGP classique

FIGURE 26 – Résultats de prédiction des champs de pression

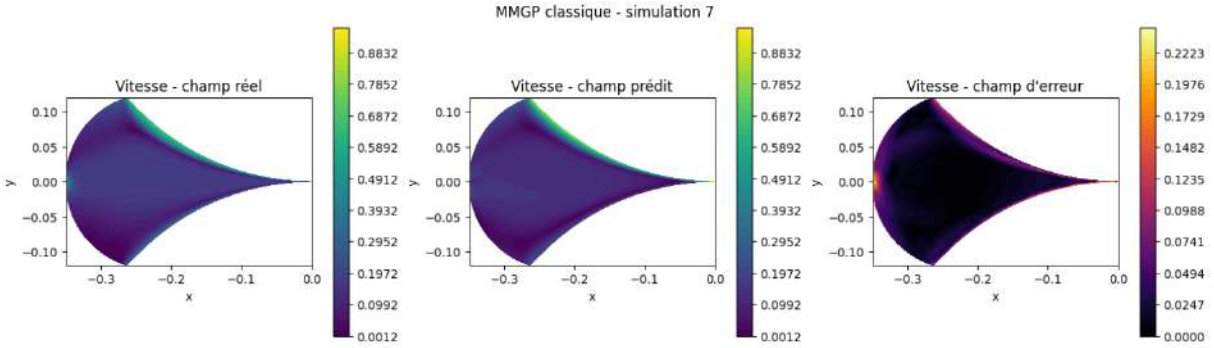
Les deux modèles reproduisent correctement la tendance globale du champ. Les écarts concernent uniquement la zone située à l'entrefer. Dans cette zone, les valeurs des résidus sont très critiques, car dans le cas de la simulation présentée dans cette figure, l'erreur est très élevée, de l'ordre de 100 bar (c'est la valeur de la pression à 1000 m de profondeur dans la mer). La comparaison des cartes d'erreur montre toutefois un avantage net du MMGP paramétré, dont l'amplitude maximale de l'erreur reste plus faible que MMGP classique. Dans ce dernier, la valeur de la pression au niveau de l'entrefer est fortement sous estimée.

5.9.3 Prédiction de la vitesse

Ensuite on visualise les résultats de la prédiction de la vitesse par les deux modèles. La figure (27) illustre un exemple :



(a) Résultat obtenu par MMGP paramétré



(b) Résultat obtenu par MMGP classique

FIGURE 27 – Résultats de prédiction des champs de vitesse

Pour le champ de vitesse, les deux modèles reproduisent correctement les principales structures de l'écoulement. La première structure capturée est la couche limite qui apparaît au voisinage des cylindres de la calandre, où on observe un gradient de vitesse élevé au voisinage du cylindre supérieur. On observe aussi la reproduction des vitesses faibles et homogènes au centre du domaine. Les modèles capturent notamment . La diminution progressive des vitesses vers la zone de sortie est également bien restituée.

Contrairement au champ de la pression, les valeurs des résidus n'atteignent pas des valeurs énormes (ordre de 0.2 m/s). Les écarts se concentrent principalement au voisinage des cylindres de la calandre et dans les régions où les gradients de vitesse sont importants. Comme il a été remarqué pour les champs de température e de pression, le MMGP paramétré présente toutefois des erreurs globalement plus faibles et plus localisées que le MMGP classique, traduisant une meilleure reconstruction des variations spatiales du champ de vitesse.

5.10 Comparaison des performances des modèles :

Afin d'évaluer quantitativement la qualité de la reconstruction des champs physiques, on considère tout d'abord des métriques permettant de quantifier la **restitution de l'information globale**. L'objectif est d'évaluer à la fois l'erreur moyenne commise sur l'ensemble du champ et la capacité du modèle à reproduire sa variabilité globale. Deux métriques complémentaires sont utilisées :

— **Relative Root Mean Square Error (RRMSE).** donnée par l'expression (4). La RRMSE mesure l'erreur quadratique moyenne de reconstruction relativement à l'amplitude du champ de référence. Elle permet ainsi de comparer les erreurs obtenues pour différents champs, indépendamment de leur ordre de grandeur.

— **Coefficient de détermination R^2.** Le coefficient R^2 quantifie la capacité du modèle à reproduire la variabilité présente dans les données de référence. Une valeur proche de 1 indique une bonne concordance entre les valeurs prédites et les valeurs de référence. Il est défini par

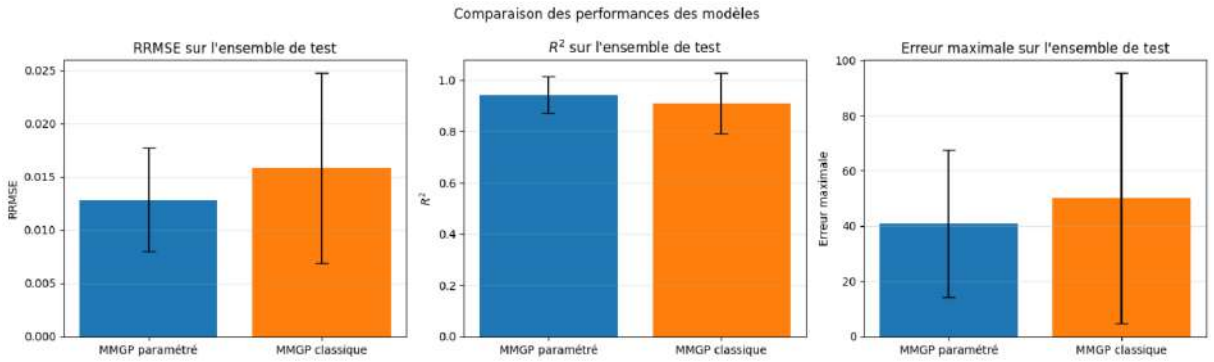
$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \widehat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \overline{y})^2}.$$

En complément de ces indicateurs globaux, il est également important d'évaluer la **restitution de l'information locale**. En effet, les métriques précédentes fournissent une mesure synthétique de la qualité globale de la reconstruction. Cependant, elles ne permettent pas toujours d'identifier des erreurs importantes mais spatialement localisées. Un modèle peut ainsi présenter de bonnes performances moyennes tout en reproduisant très mal certaines zones critiques du champ. Ce cas est surtout critique pour les champs physiques localisés, par exemple le champ de pression, où on observe une compression importante uniquement dans une zone très localisée au niveau de l'entrefer, comme illustré dans les figures (14b) et (26). Pour cette raison, on considère une métrique permettant d'identifier directement l'erreur ponctuelle la plus importante :

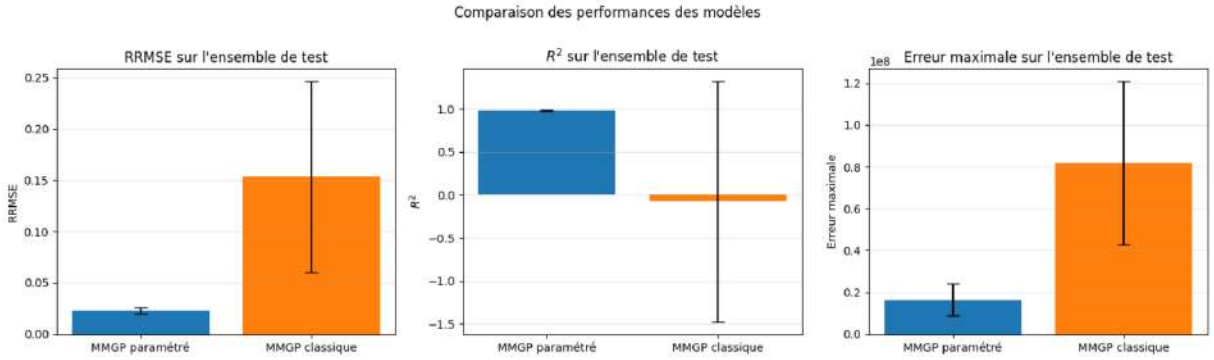
— **Erreur maximale.** L'erreur maximale correspond à la norme infinie de la différence entre le champ de référence et le champ reconstruit. Elle permet de quantifier le plus grand écart local observé sur l'ensemble du domaine :

$$\|U_{\text{réel}} - U_{\text{pred}}\|_\infty = \max_{i=1,\dots,N_i} \left| U^i_{\text{réel}} - U^i_{\text{pred}} \right|.$$

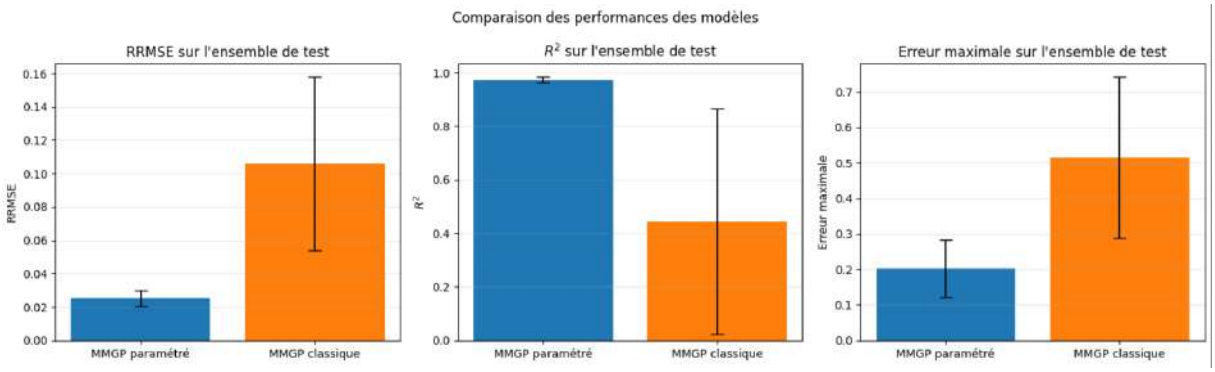
On compare les performances de ces deux modèles sur l'ensemble de test, en utilisant les métriques définies précédemment



(a) Champ de température



(b) Champ de pression



(c) Champ de vitesse

FIGURE 28 – Comparaison des performances des deux modèles

La figure (28) met en évidence une meilleure performance globale du modèle MMGP paramétré par rapport au MMGP classique pour les trois champs physiques considérés. Pour le champ de température, l'amélioration reste modérée mais cohérente : le MMGP paramétré présente une RRMSE plus faible, un coefficient de détermination R^2 légèrement supérieur et une erreur maximale moyenne plus réduite. La qualité de prédiction des tendances globales reste généralement bonne pour les deux modèles, alors que l'erreur locale n'est pas satisfaisante. Une moyenne de 40°C d'erreur maximale absolue est très forte lorsqu'on cherche à prédire si le gratonnage aura lieu ou pas.

L'écart entre les deux approches devient nettement plus marqué pour les champs de pression et de vitesse. Pour la pression, le MMGP paramétré atteint un R^2 qui dépasse 95%, tandis que le MMGP classique présente une valeur très faible, avec un grand écart-type entre les observations, traduisant une mauvaise qualité de prédiction. En ef-

fet, lorsqu'on évalue la moyenne d'erreur locale du MMGP classique, elle est de l'ordre de 1000 bar (c'est la pression au fond de l'océan). La RRMSE et l'erreur maximale sont également fortement réduites avec le modèle paramétré. Ce dernier tend à bien prédire les tendances globales du champ, par contre l'erreur locale qu'il commet demeure intolérable, afin de ne pas induire en erreur les étapes de traitement qui suivent la prédiction (prédiction de l'état de cuisson du mélange). Ces observations laissent conclure que ces deux modèles ne sont pas adaptés à la prédiction de ce genre de champs très localisés dans le domaine d'étude. En effet, la décomposition POD repose sur des modes spatiaux globaux, qui peuvent nécessiter un nombre plus important de composantes pour représenter avec précision des phénomènes très localisés. La prédiction des coefficients modaux par les modèles MMGP hérite alors de cette difficulté. Ce propos sera plus tard vérifié dans la section (5.12).

Pour le champ de la vitesse, on observe toujours que MMGP paramétré est plus performant, avec un R^2 proche de 1 et des erreurs locales et globales plus faibles.

5.11 Analyse SHAP pour le modèle MMGP classique

L'évaluation du modèle MMGP classique a mis en évidence des performances de prédiction insuffisantes sur l'ensemble de test. Ces résultats suggèrent que certaines variables d'entrée peuvent être peu informatives, redondantes, ou défavorables à la capacité de généralisation du modèle. On mène alors une étude de sélection de variables afin d'identifier les paramètres les plus pertinents, de réduire la dimension de l'espace d'entrée et d'améliorer la robustesse du modèle. Cette analyse repose sur l'interprétation des importances SHAP, la sélection progressive des variables et une étude d'ablation permettant d'évaluer directement leur influence sur les performances prédictives.

5.11.1 Analyse de l'importance des variables.

L'analyse de l'importance des variables est faite par une analyse de type SHAP (*SHapley Additive exPlanations*) (voir l'annexe C). La première étape consiste à entraîner un modèle de référence en utilisant l'ensemble des variables disponibles : les 6 paramètres physiques $p_1, \ldots, p_6$ en plus des dimensions réduites $\tilde{X}_1, \tilde{X}_2, \ldots, \tilde{Y}_1, \ldots, \tilde{Y}_6$. Chaque mode POD des trois champs physiques $\{\tilde{T}_i\}$, $\{\tilde{P}_i\}$ et $\{\tilde{V}_i\}$ est prédit par un processus gaussien prenant en entrée toutes ces variables.

Une analyse de type SHAP est ensuite appliquée à chaque mode des champs afin d'évaluer la contribution de chaque variable d'entrée à la prédiction des coefficients modaux des trois champs physiques. Ensuite, la contribution de chaque variable d'entrée est moyennée sur les modes de chaque champ physique. La figure (29) présente les résultats obtenus :

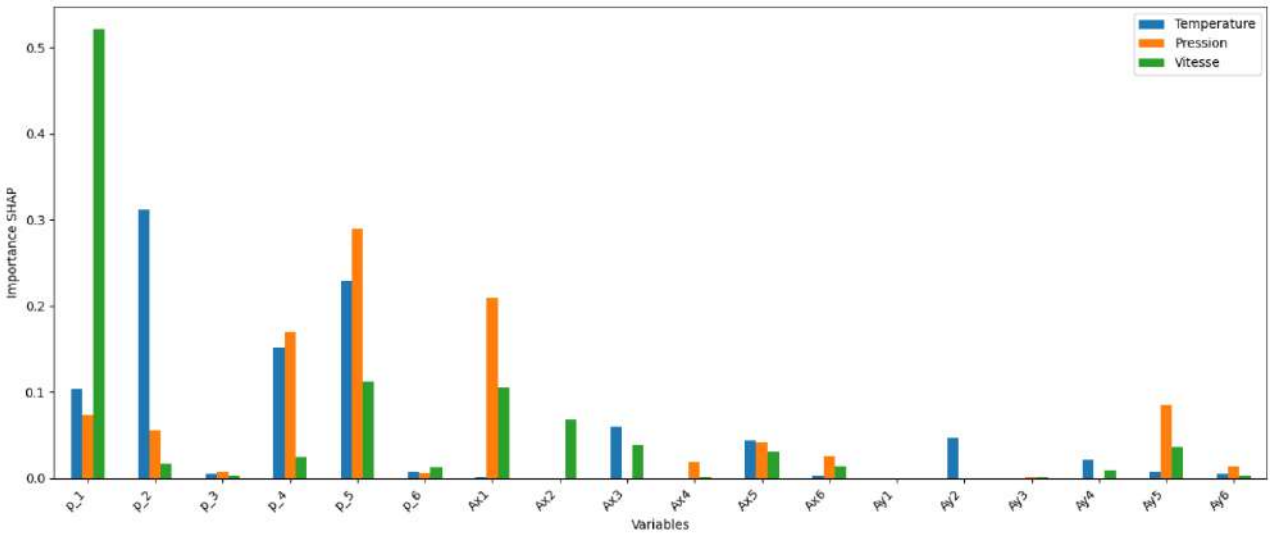


FIGURE 29 – Analyse SHAP moyennée sur tous les modes pour chaque champ physique

Cette analyse met en évidence une forte **hétérogénéité** des dépendances vis-à-vis des entrées. En particulier, une variable pouvant être déterminante pour la prédiction d'un mode dans un champ physique peut présenter une contribution très faible pour un mode dans un autre champ. Cette hétérogénéité est également observée entre les différents modes POD d'un même champ, comme on peut observer dans la figure (30). Ainsi, la notion d'importance d'une variable ne peut pas être considérée comme universelle : elle dépend à la fois du champ considéré et du mode à prédire.

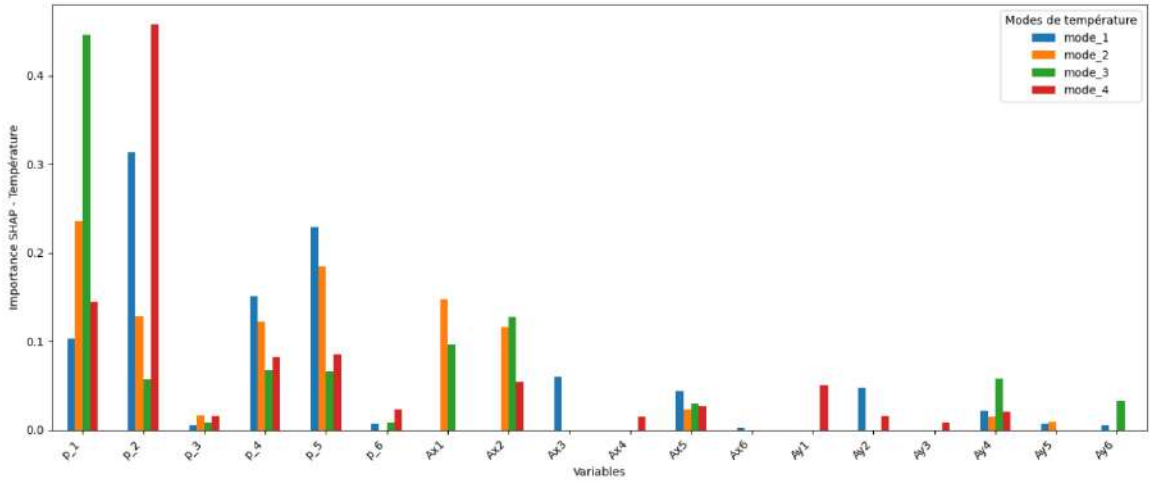


FIGURE 30 – Importance des variables pour les trois premiers modes de la température

Afin d'obtenir un classement global exploitable pour la réduction de dimension, les importances SHAP obtenues pour les différents modes sont agrégées, en tenant compte de leur contribution relative. Les variables sont ensuite classées par ordre décroissant d'importance. Le résultat est dans la figure (31) :

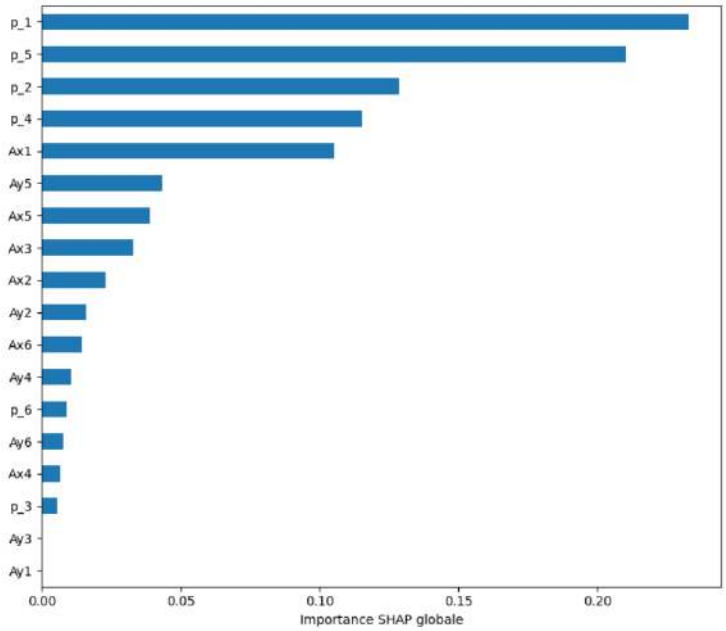


FIGURE 31 – Classement des variables en fonction de leur importance globale

5.11.2 Sélection progressive des coordonnées réduites

La sélection finale n'est pas basée uniquement sur un seuil d'importance SHAP. On introduit les coordonnées réduites $\tilde{X}_1, \tilde{X}_2, \ldots, \tilde{Y}_1, \ldots, \tilde{Y}_6$ progressivement dans le modèle, en respectant leur classement d'importance illustré dans la figure (31), puis on ré-entraîne les modèles de régression pour différentes dimensions de l'espace d'entrée. Cette procédure permet d'étudier directement l'évolution de la qualité de prédiction en fonction du nombre de variables conservées. Le choix du modèle réduit correspond ainsi à un compromis entre la diminution de la dimension d'entrée et la conservation des performances prédictives. Cette approche est préférable à une sélection fondée uniquement sur un seuil SHAP, car elle permet de vérifier expérimentalement l'effet réel de chaque niveau de réduction sur les performances du modèle.

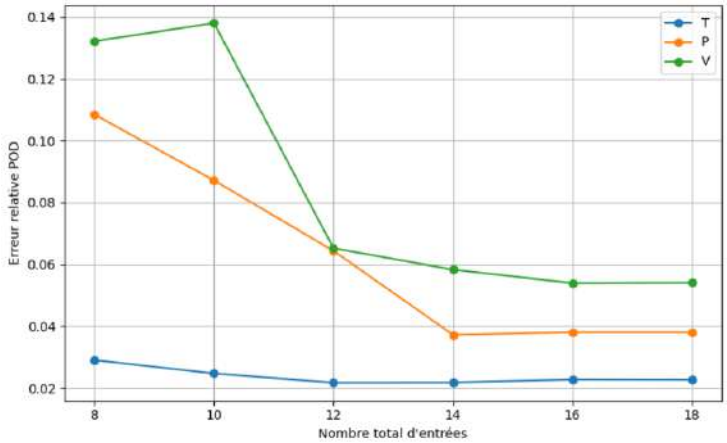


FIGURE 32 – Évolution de la qualité de prédiction en fonction du nombre de variables d'entrée conservées pour les trois champs physiques cibles

Vu le résultat précédent, le modèle final sélectionné comprend 14 variables au total, correspondant aux paramètres physiques $p_1, \ldots, p_6$ en plus des 8 dimensions réduites les plus influentes, qui sont $\tilde{X}_1, \tilde{X}_2, \tilde{X}_3, \tilde{X}_5, \tilde{X}_6, \tilde{Y}_2, \tilde{Y}_4, \tilde{Y}_5$. Comme on a évoqué dans la partie (5.7), la variable $\tilde{Y}_1$ est éliminée.

Détection de variables défavorables On réalise un test complémentaire sur un nouvel ensemble de données afin d'évaluer la robustesse du modèle sélectionné. Les résultats obtenus dans ce test montrent que les performances sont très mauvaises. En effet, les deux variables $\tilde{X}_5$ et $\tilde{X}_6$, malgré leur importance SHAP moyenne non négligeable, détériorent fortement la capacité de généralisation du modèle.

Étude d'ablation et détection de variables défavorables. On réalise alors une étude d'ablation : on compare quatre configurations :

- Le modèle complet sélectionné,
- Le modèle sans la variable $\tilde{X}_5$,
- Le modèle sans la variable $\tilde{X}_6$,
- Le modèle sans les deux variables $\tilde{X}_5$ et $\tilde{X}_6$ simultanément.

Le résultat de la comparaison montre que **la suppression simultanée des deux variables** conduit à une amélioration importante des performances **globales** sur le nouvel ensemble de données. Par contre, plusieurs modes de la décomposition POD se détériorent suite à cette suppression. À titre d'exemple, quelques résultats obtenus pour les coefficients POD des 3 champs sont présentés dans le Tableau (3).

Mode POD	Modèle initial	Modèle après ablation
Température 5	0.773	0.607
Température 6	0.892	0.803086
Pression 7	0.425	0.542
Vitesse 5	0.908	0.964

TABLE 3 – Exemples de scores R^2 obtenus avant et après suppression simultanée des deux variables identifiées lors de l'étude d'ablation

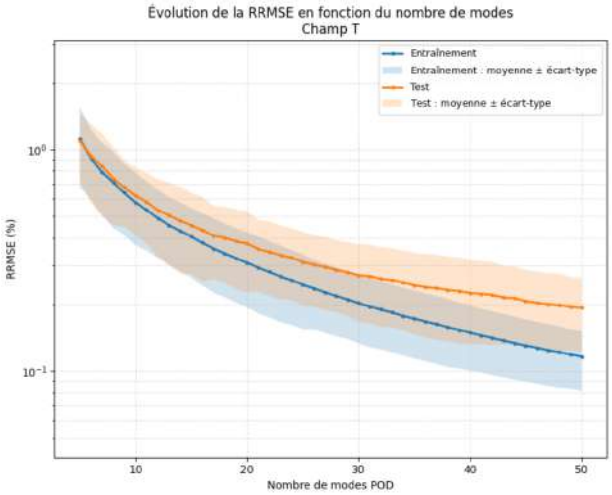
D'après le tableau (3), la suppression de ces deux variables ne constitue toutefois pas une amélioration systématique pour tous les modes. Plusieurs modes présentent une diminution de leur score après ablation. Cela s'explique par le fait que $\tilde{X}_5$ et $\tilde{X}_6$ restent informatives pour ces modes, comme c'est le cas pour certaines variables dans la figure (30). Leur importance moyenne demeure donc relativement élevée, bien que leur présence soit défavorable à la robustesse globale du modèle sur le nouveau domaine.

Ce résultat met en évidence une **limite importante** du modèle MMGP classique : une même coordonnée réduite peut être bénéfique pour certains coefficients modaux et défavorable pour d'autres. Il existe ainsi un compromis entre performance locale, réduction de dimension et robustesse hors distribution. Dans la configuration retenue, la suppression des deux variables a été privilégiée car elle améliore fortement la stabilité et la capacité de généralisation globale du modèle, au prix d'une dégradation modérée de certains GP individuels.

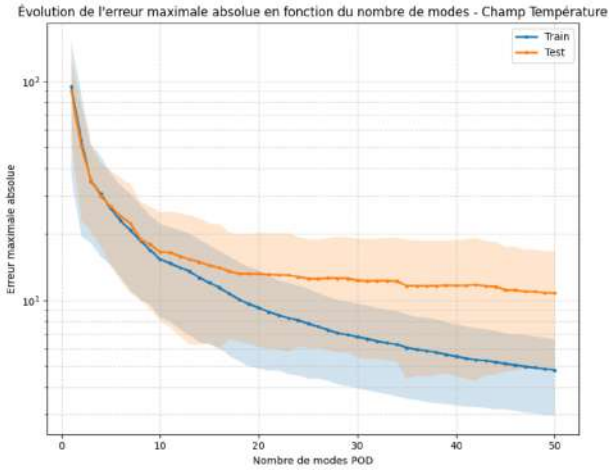
5.12 Diagnostic : évaluation de la qualité de l'encodage de l'information par POD

Pour mettre en évidence l'origine des erreurs locales élevées lors de la prédiction, on s'intéresse à vérifier si les données d'entrée sont suffisamment représentatives. Autrement dit, si les coordonnées réduites conservent suffisamment l'information contenue dans les champs physiques encodés, à la fois les grandes tendances et les phénomènes locaux. Pour cela, on reconstruit ces champs à partir des dimensions réduite, et on évalue l'erreur induite par l'encodage-décodage au niveau de l'ensemble d'entraînement et de test. On utilise comme métriques l'erreur **RRMSE** pour les tendances globales, et **l'erreur maximale absolue** pour les phénomènes locaux. On visualise l'évolution de ces erreurs en fonction du nombre de modes retenus dans la réduction de dimension POD. L'erreur RRMSE es présentée en échelle logarithmique car ses valeurs sont petites. le résultat est présenté sur la figure (33).

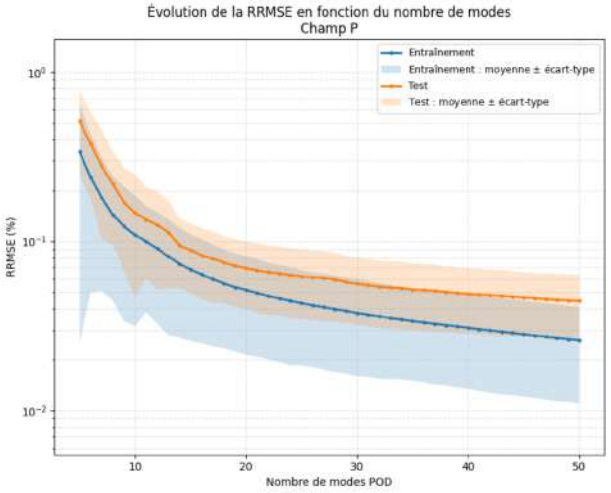
Globalement, on observe l'augmentation du nombre de modes améliore la précision, mais avec des comportements différents selon que l'on considère une métrique globale ou locale. Pour la **RRMSE** dans les figures (33a), (33c) et (33e), l'erreur diminue de façon monotone aussi bien sur l'ensemble d'entraînement que sur l'ensemble de test. Les courbes d'entraînement et de test restent relativement proches, même si un écart apparaît progressivement en faveur de l'entraînement. On observe néanmoins un phénomène de rendement décroissant : l'ajout de nouveaux modes continue à réduire la RRMSE, mais de manière de plus en plus marginale. En revanche, l'évolution de l'erreur maximale absolue, illustrée par la figure (33b), (33d) et (33f), met en évidence un comportement différent. Pour un faible nombre de modes, l'erreur maximale diminue très fortement sur les ensembles d'entraînement et de test, ce qui montre que les premiers modes POD capturent une part importante des structures responsables des erreurs locales les plus importantes. Cependant, à partir d'un certain rang, les deux courbes se séparent nettement. Sur l'ensemble d'entraînement, l'erreur maximale continue à décroître régulièrement lorsque de nouveaux modes sont ajoutés, tandis que sur l'ensemble de test elle atteint un plateau avec seulement une faible amélioration. L'écart-type est par ailleurs relativement élevé, notamment pour les données de test, ce qui traduit une variabilité importante de l'erreur locale selon les réalisations considérées.



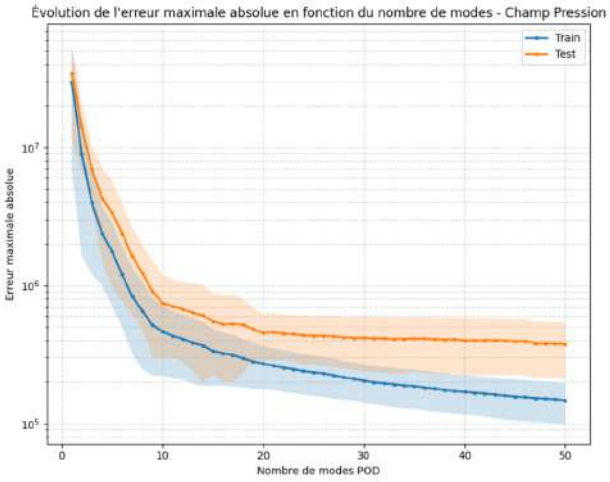
(a) Température – erreur RRMSE



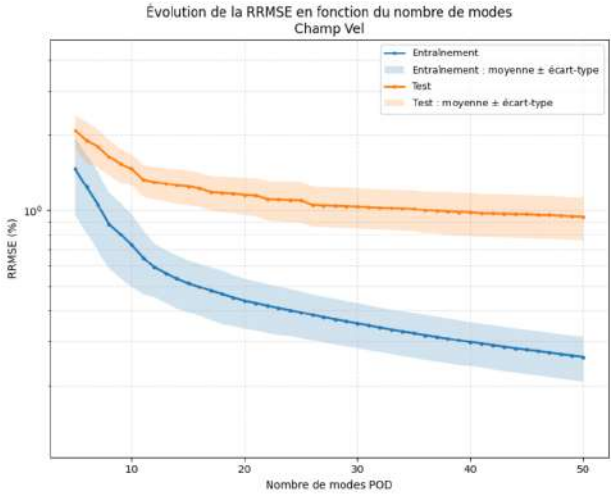
(b) Température – erreur maximale absolue



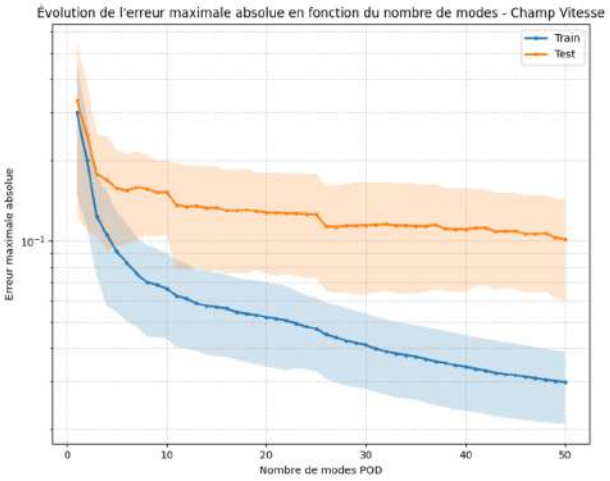
(c) Pression – erreur RRMSE



(d) Pression – erreur maximale absolue



(e) Vitesse – erreur RRMSE

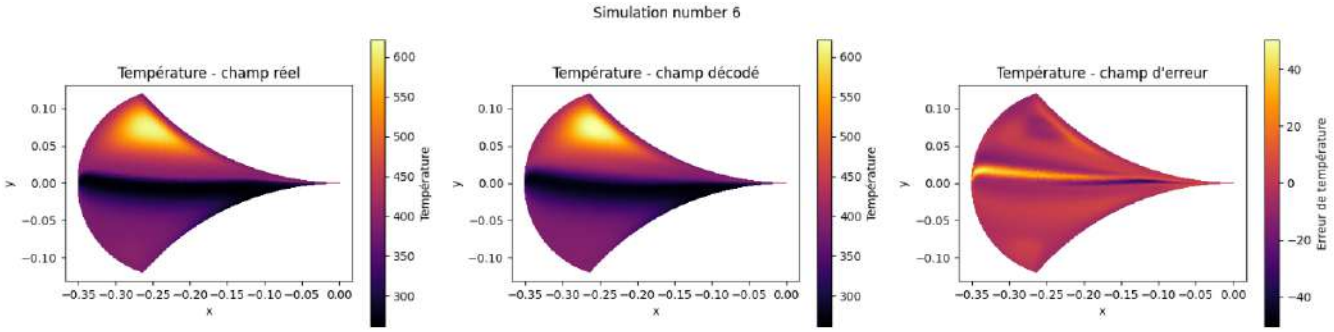


(f) Vitesse – erreur maximale absolue

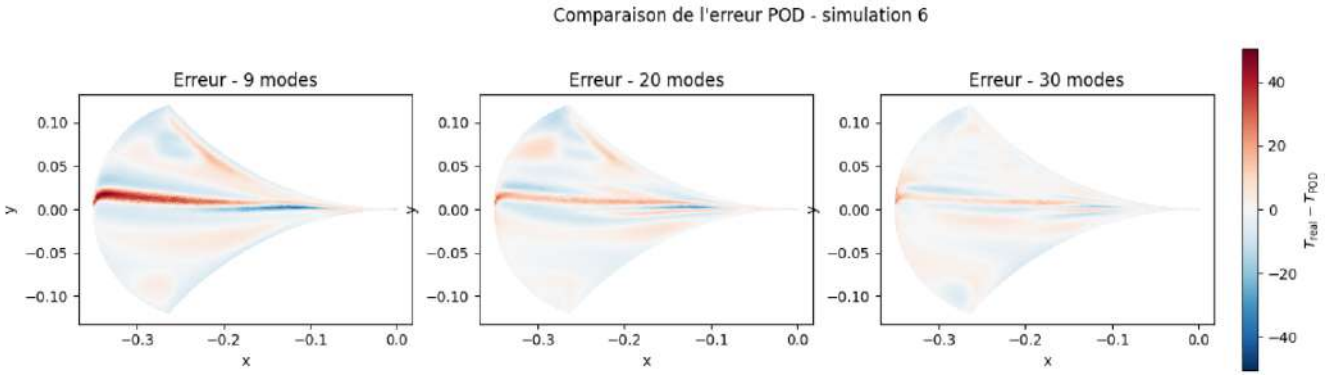
FIGURE 33 – Évolution de la qualité de l'encodage POD en fonction du nombre de modes pour les trois champs physiques étudiés : température, pression et vitesse.

Ces résultats mettent donc en évidence une distinction importante entre la qualité globale et la qualité locale de la reconstruction. L'augmentation du nombre de modes permet de réduire efficacement l'erreur moyenne globale, mais elle ne suffit pas à supprimer les erreurs ponctuelles importantes sur des configurations non observées lors de l'entraînement. Le fait que l'erreur maximale d'entraînement continue à diminuer alors que celle de test tend à se stabiliser indique que les modes supplémentaires améliorent essentiellement la représentation des données d'apprentissage, sans apporter le même gain pour les structures locales des nouvelles réalisations. Ainsi, augmenter simplement le nombre de modes ne constitue pas une solution suffisante pour maîtriser l'erreur locale ; au-delà d'un certain nombre de modes, la limitation semble davantage liée à la capacité du modèle à prédire correctement les structures locales qu'à la seule troncature de la base POD.

La figure (34) présente l'exemple du champ d'erreur d'une simulation de l'ensemble de test. La figure (34a confronte le champ réel et le champ encodé. On observe que les tendances globales sont généralement capturées. Mais, lorsqu'on évalue l'erreur point par point, on se rend compte qu'il y a des écarts qui atteignent -40°C ou +40°C dans certaines zones. On s'intéresse aussi à visualiser ce champ d'erreur en 2D pour différents nombres de modes retenus lors de la réduction de dimension POD. La figure (34b) présente le résultat. On observe que malgré que le nombre de modes retenus devient important (dans ce cas par exemple 30 modes retenus), une erreur locale de l'ordre de 20°C persiste.



(a) Comparaison entre la reconstruction POD et les valeurs réelles.



(b) Résidus des trois premières contributions modales du champ de température.

FIGURE 34 – Exemple d'évaluation de la reconstruction POD pour une simulation

5.13 Réduction de dimension non linéaire avec l'autoencodeur :

L'analyse menée à la section (5.12) suggère que la limitation rencontrée est en grande partie liée à la nature même de la réduction de dimension par POD. En effet, la POD construit une base linéaire optimisant la représentation du champ au sens d'un critère énergétique global. Elle privilégie donc les structures qui contribuent le plus à la variance globale des données. À l'inverse, certaines structures fortement localisées, bien que potentiellement importantes d'un point de vue physique, peuvent ne représenter qu'une faible fraction de l'énergie totale du champ et être moins bien décrites par les premiers modes. La troncature de la base POD introduit alors une erreur de reconstruction résiduelle, qui peut persister dans certaines zones du domaine. Lorsque les coefficients POD sont ensuite utilisés comme sorties du modèle d'apprentissage, celui-ci apprend à reproduire une représentation déjà imparfaite du champ. Les erreurs issues de l'étape de réduction de dimension se retrouvent ainsi dans les champs prédits, voire s'accentuent par les erreurs propres du modèle de régression.

Ces résultats ne remettent pas en cause l'intérêt de la POD, qui reste une méthode de réduction de dimension particulièrement efficace, interprétable et peu coûteuse. Cependant, ils montrent que, dans le cadre du problème étudié, une représentation linéaire ne semble pas suffisamment adaptée pour préserver les informations essentielles. Pour dépasser cette limitation, on s'oriente à utiliser une réduction de dimension non linéaire, par exemple via des **autoencodeurs** (voir l'annexe D). Comme discuté dans l'article [13], ce choix offre également une extension naturelle vers des représentations non linéaires et vers l'apprentissage profond, par l'ajout de couches supplémentaires et de fonctions d'activation non linéaires. Ainsi, un autoencodeur peut théoriquement représenter des relations plus complexes entre les différentes structures spatiales du champ et fournir ainsi un encodage plus adapté à des phénomènes fortement non linéaires ou localisés.

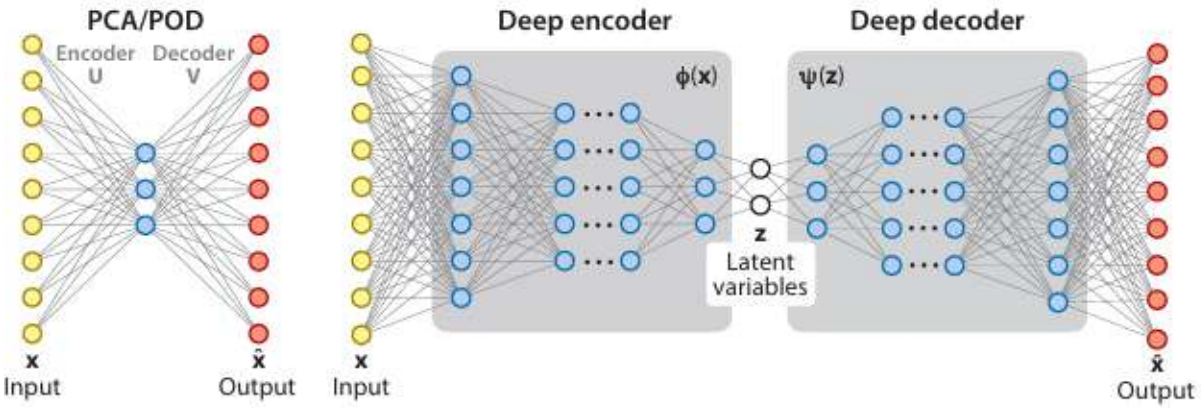


FIGURE 35 – Schéma explicatif confrontant la réduction de dimension par POD et par autoencodeur, mettant en évidence la complexité et la non linéarité éventuelle de l'autoencodeur [13]

La réduction de dimension par un autoencodeur implique la définition pertinente de la fonction de coût. Pour l'apprentissage des tendances globales,on utilise l'erreur quadratique moyenne (MSE) donnée par la formule suivante

$$\mathcal{L}_{MSE}(U, \hat{U}) = \frac{1}{n}\sum_{i=1}^{n}(U^i - \hat{U}^i)^2$$

où U désigne le champ réel qu'on cherche à prédire, et $\hat{U}$ le champ réduit obtenu par encodage-décodage. On utilise cette métrique plutôt que la RRMSE employée précédemment, car son gradient est directement proportionnel à l'erreur de reconstruction, ce qui facilite l'apprentissage. À l'inverse, la RRMSE introduit une normalisation par l'amplitude du signal, pouvant surpondérer les observations de faible amplitude et générer des instabilités lorsque les valeurs sont proches de zéro. Cependant, comme la POD, cette métrique globale accorde peu d'importance aux erreurs locales, alors que l'objectif recherché est précisément de réduire ce type de résidus. Une formulation mathématique du problème qu'on cherche à résoudre peut être donnée ainsi :

$$\max_{\|U-\hat{U}\|_\infty \leq U_{max}} \mathcal{L}_{MSE}(U, \hat{U})$$

Il est ainsi pertinent d'étudier des fonctions de coût qui ne mesurent pas uniquement la fidélité moyenne de la reconstruction, mais qui pénalisent davantage les erreurs locales importantes. Pour cette raison, on choisit de pénaliser l'erreur MSE par un terme d'erreur locale, comme défini dans l'équation suivante :

$$\mathcal{L}_{loss}(U, \hat{U}) = \mathcal{L}_{MSE}(U, \hat{U}) + \lambda.\|U - \hat{U}\|_\infty$$

Vu que la norme $\|.\|_\infty$ est non différentiable, elle est impossible à utiliser avec une optimisation par descente de gradient. On la remplace par une approximation lisse, donnée par la fonction suivante :

$$\mathcal{L}_{loc}(r) = \frac{1}{\alpha} \ln\left(\sum_{i=1}^{n} \exp(\alpha\,|r_i|)\right), \quad r \in \mathbb{R}^n$$

où les r_i sont les coordonnées du vecteur r. L'hyperparmètre α permet de régler le compromis entre lissage de l'optimisation et proximité avec le maximum. En effet :

$$\lim_{\alpha \to +\infty} \Psi_\alpha(r) = \|r\|_\infty, \quad r \in \mathbb{R}^n$$

L'introduction d'un autoencodeur soulève toutefois un problème supplémentaire : ses performances dépendent fortement du choix de son architecture et de ses hyperparamètres. Les éléments suivants doivent bien être choisis :

— La dimension latente,

— Le nombre de couches cachées,

— Le taux d'apprentissage,

— La fonction d'activation

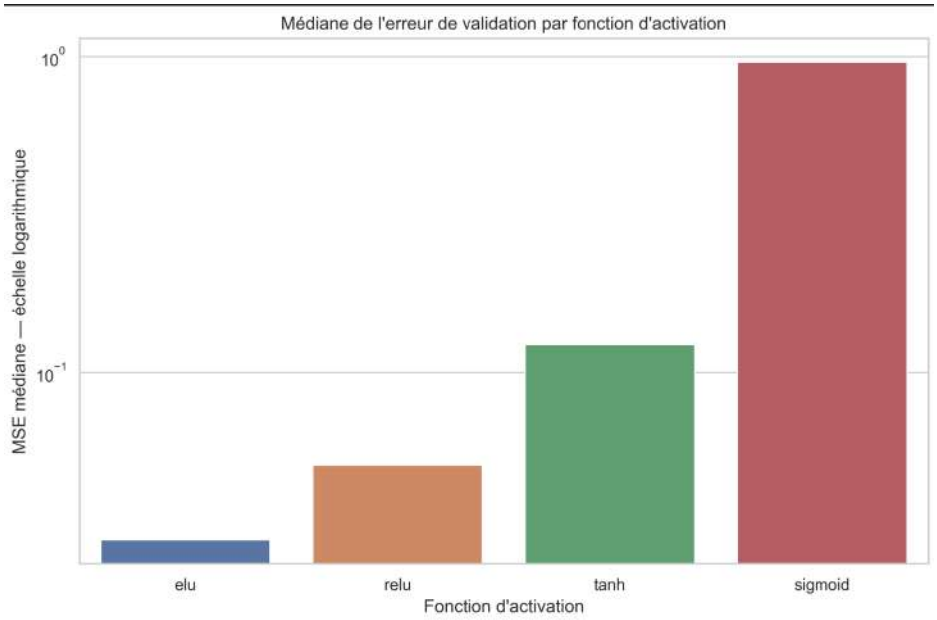
Ces hyperparamètres ne peuvent pas être choisis arbitrairement, car ils conditionnent directement le compromis entre capacité de représentation, généralisation et complexité du modèle. On procède alors par une recherche par quadrillage (*Grid Search*) afin d'identifier la configuration offrant les meilleures performances sur un ensemble de validation. Cette étape permet de comparer objectivement plusieurs architectures et d'éviter de sélectionner le modèle uniquement sur la base de résultats ponctuels.

Les paramètres λ et α sont déterminés empiriquement. On s'installe finalement sur

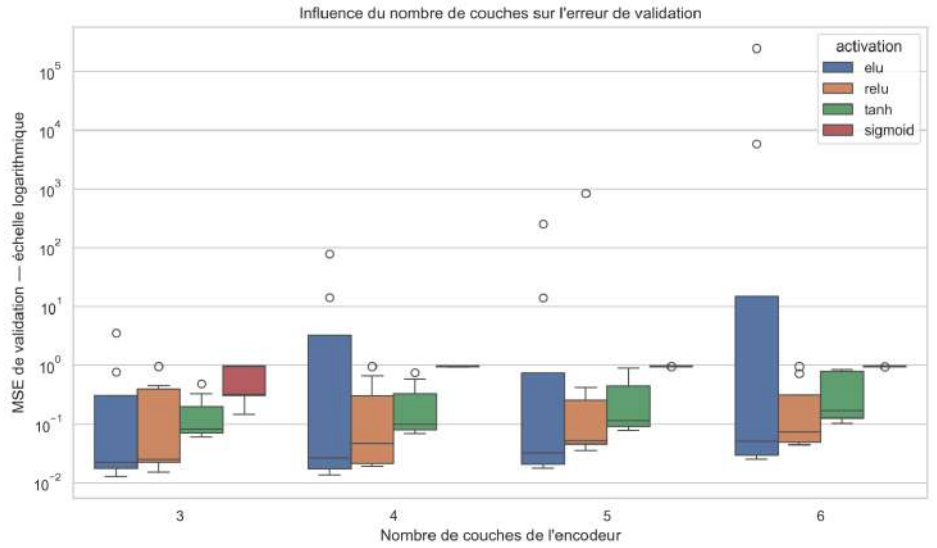
$$\alpha = 10, \qquad \lambda = 5,$$

5.14 Première étude et choix de la fonction d'activation

Une première étude a été menée avec une fonction de coût basée uniquement sur l'erreur quadratique moyenne ($\mathcal{L}_{MSE}$). Les fonctions d'activation qui ont été comparées sont : ReLu, ELu, tanh et sigmoïde. La figure (36a) présente la médiane de l'erreur de validation obtenue pour ces quatre fonctions, tandis que la figure (36b) présente les résultats pour différents architectures de l'autoencodeur.



(a) Comparaison des fonctions d'activation à partir de la médiane de la MSE de validation. L'échelle verticale est logarithmique.



(b) Résultats obtenus pour différentes fonctions d'activation en fonction de la dimension latente.

FIGURE 36 – Influence de la fonction d'activation sur les performances de l'autoencodeur.

La fonction ELU présente nettement la plus faible erreur de validation. ReLU arrive en deuxième position, tandis que les fonctions tanh et surtout sigmoïde conduisent à des performances moins satisfaisantes. D'après la figure (36b), la fonction ELU présente la meilleure performance dans toutes les structures, elle est donc retenue pour la suite de l'étude.

Cette première approche permet d'obtenir une reconstruction globale correcte. Elle ne produit toutefois pas une amélioration suffisante des erreurs locales par rapport à la POD. Ce résultat est cohérent avec la fonction objectif utilisée : la MSE moyenne les erreurs. Une erreur importante mais limitée à une petite région du domaine peut donc avoir une contribution relativement faible à la fonction de coût.

5.15 Prise en compte des erreurs locales

Ensuite, afin de mieux conserver les phénomènes locaux, on utilise la fonction de coût pénalisée $\mathcal{L}_{loss}$. Une recherche aléatoire est ensuite réalisée afin d'étudier l'influence de la dimension latente et de la profondeur du réseau. La fonction d'activation ELU est conservée, ainsi que les valeurs $\alpha = 10$ et $\lambda = 5$.

Pour les différentes configurations testées, on visualise l'évolution de l'erreur locale, qui nous intéresse dans cette partie en fonction de la dimension latente, pour différentes architectures. Le résultat est donné par la figure (37)

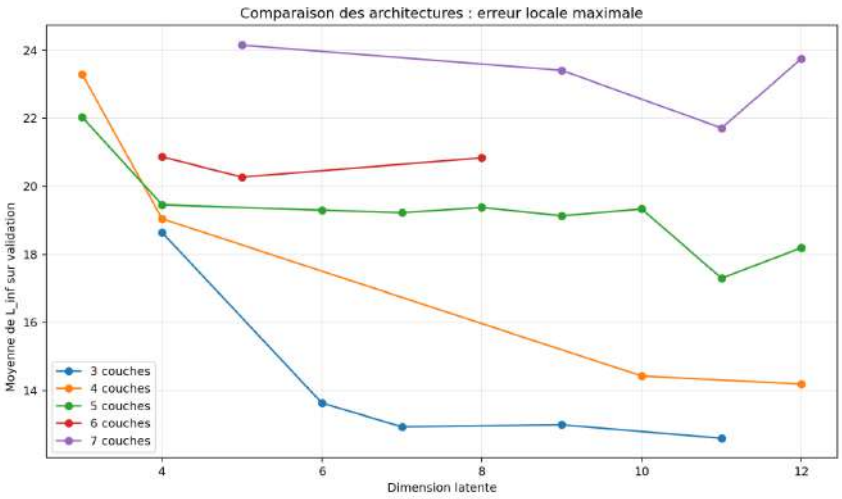


FIGURE 37 – Visualisation de l'erreur locale pour les différentes configurations testées

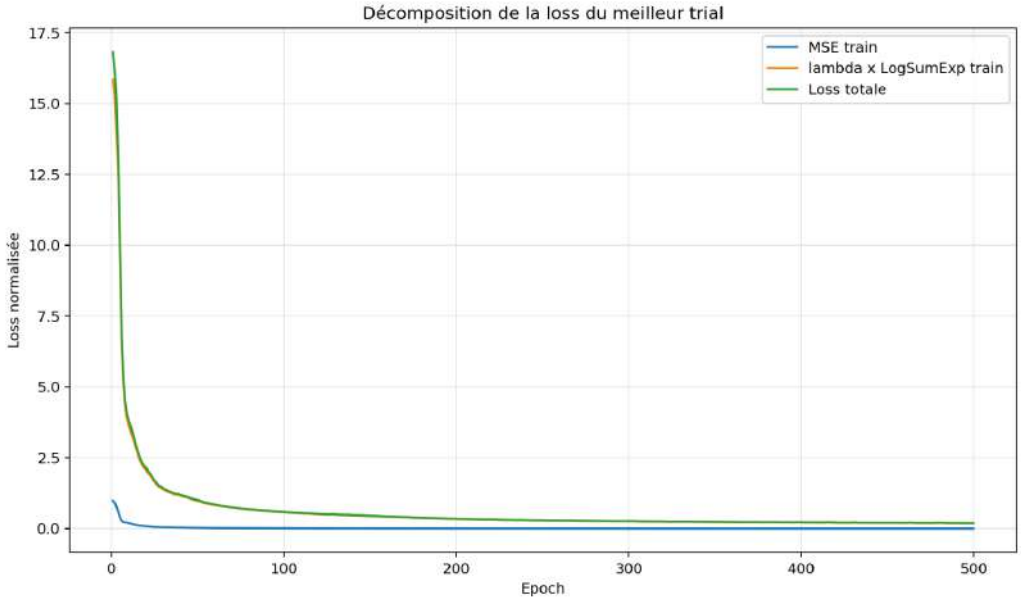
Les résultats de la figure (37) montrent que l'augmentation de la profondeur n'améliore pas systématiquement la reconstruction. Les réseaux à six et sept couches donnent notamment des erreurs sensiblement plus élevées. Ce comportement peut être lié au nombre limité de simulations disponibles par rapport au nombre de paramètres du réseau.

Les meilleurs résultats sont obtenus avec trois couches cachées. Pour cette profondeur, l'augmentation de la dimension latente améliore fortement les performances entre les premières configurations testées, puis l'amélioration devient plus faible. Parmi les architectures évaluées, la meilleure configuration correspond à une dimension latente égale à 11 et à trois couches cachées. L'encodeur associé est ainsi de la forme

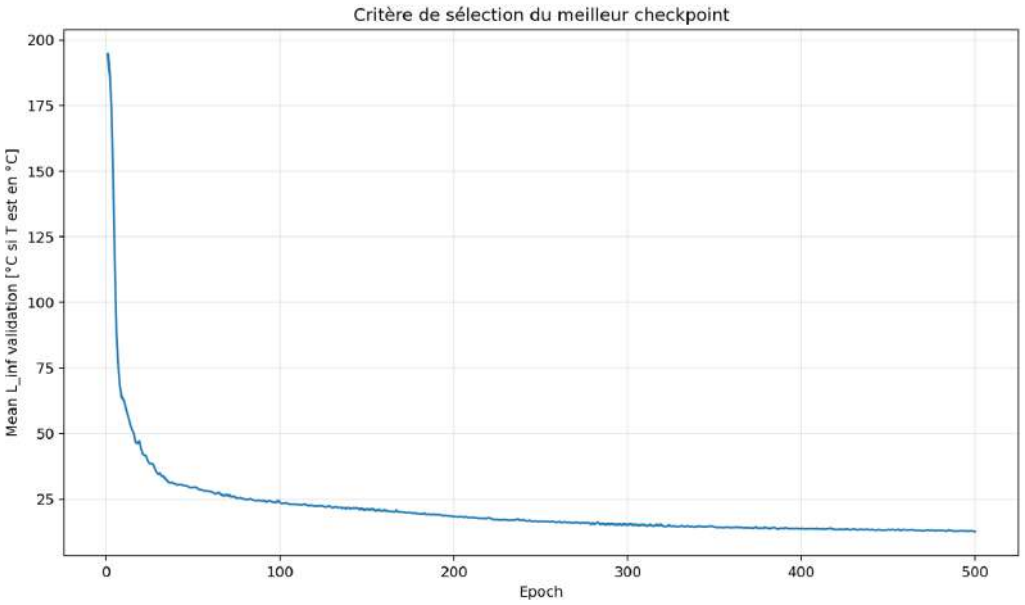
$$13125 \to 2048 \to 512 \to 128 \to 11.$$

L'erreur maximale moyenne de validation obtenue est d'environ 13 °C.

La figure (38) montre le comportement de la fonction de coût $\mathcal{L}_{loss}$ pour le meilleur essai. La $\mathcal{L}_{MSE}$ diminue très rapidement au début de l'entraînement. Le terme associé à la pénalisation par $\mathcal{L}_{loc}$ devient ensuite la contribution dominante de la fonction de coût. Le réseau continue ainsi à corriger progressivement les plus grandes erreurs locales après avoir appris la structure globale du champ.



(a) Décomposition de la fonction de coût.



(b) Évolution de la norme infinie moyenne sur la validation.

FIGURE 38 – Entraînement du meilleur autoencodeur avec la fonction de coût hybride $\mathcal{L}_{loss}$

Ce comportement est également visible sur la figure (38b). L'erreur maximale moyenne sur le jeu de validation chute fortement pendant les premières époques, puis continue à

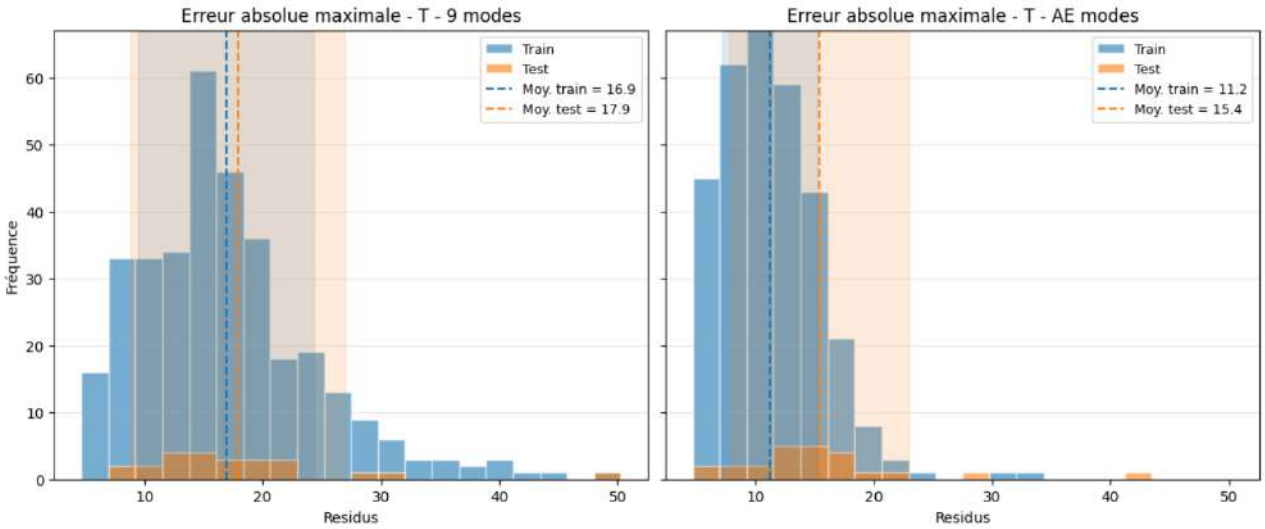


FIGURE 39 – Comparaison de la distribution des maximum de résidus pour l'encodage linéaire et non linéaire des champs

diminuer plus lentement. Elle passe d'une valeur initiale proche de 200 °C à une valeur de l'ordre de 13 °C en fin d'entraînement. La décroissance reste encore visible aux dernières époques, ce qui indique que l'optimisation est lente mais stable.

Le poids $\lambda = 5$ donne ici une importance élevée à la composante locale, comme le montre la domination du terme $\mathcal{L}_{loss}$ dans la fonction de coût.

5.15.1 Résultats de l'encodage

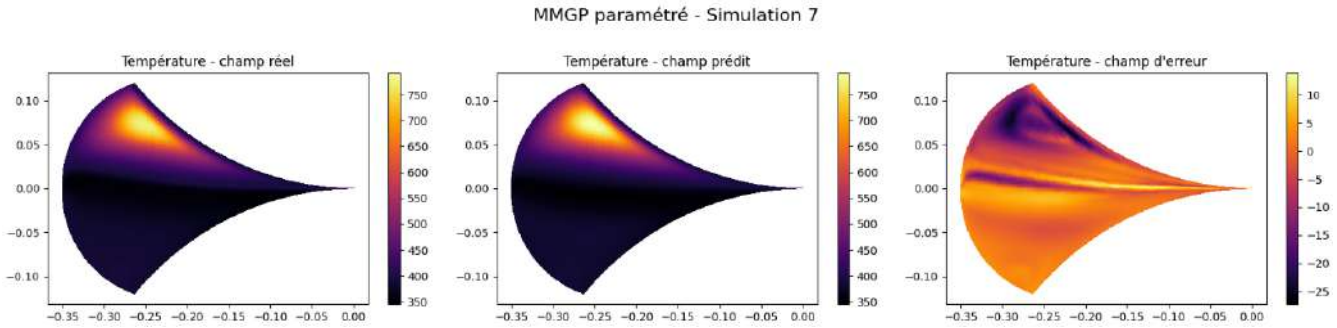
Une fois la meilleure architecture trouvée, on compare la distribution des maximums de résidus dans l'ensemble d'entraînement et de test, le résultat est présenté dans la figure (39) :

D'après la figure (39), l'autoencodeur présente globalement de meilleures performances, avec une diminution de l'erreur moyenne maximale aussi bien sur l'ensemble d'apprentissage que sur l'ensemble de test. Ce résultat met en évidence la capacité de l'autoencodeur à représenter plus efficacement certaines structures non linéaires du champ, contrairement à la POD qui repose sur une approximation linéaire. Pour les deux méthodes, les performances sur l'ensemble de test restent légèrement inférieures à celles observées sur l'apprentissage, ce qui traduit une dégradation modérée de la reconstruction sur des données non utilisées lors de l'entraînement. Enfin, quelques valeurs extrêmes persistent avec l'autoencodeur, indiquant que certaines configurations demeurent plus difficiles à reconstruire malgré l'amélioration globale obtenue.

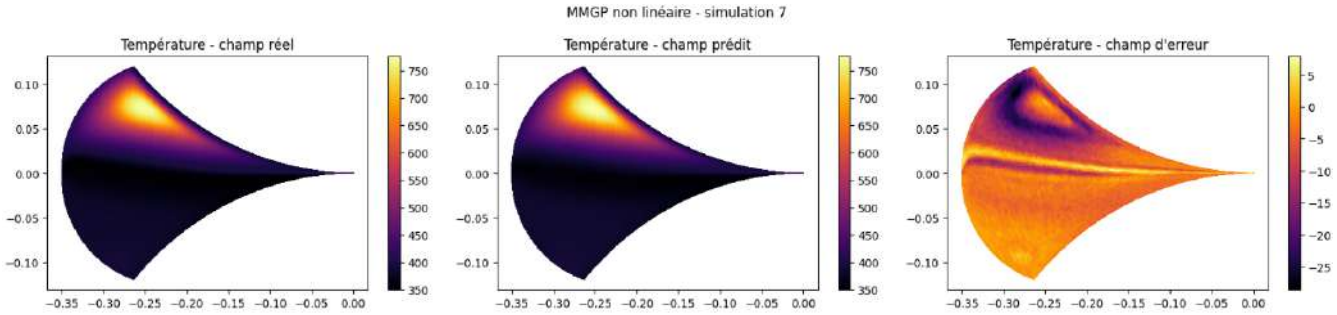
Cette étude confirme l'intérêt d'une représentation non linéaire pour limiter les erreurs locales de reconstruction. Elle montre également qu'une architecture relativement peu profonde est suffisante pour les données considérées. Le modèle retenu sera ensuite utilisé pour encoder les champs de température dans l'espace latent. Les coordonnées obtenues constitueront les variables cibles du modèle supervisé reliant les huit paramètres physiques aux champs thermiques reconstruits. Les prédictions sont toujours faites par régression à processus gaussiens. On utilise comme variables d'entrées celle du **MMGP paramétré**, vu que ce dernier performe mieux que MMGP classique. Ce nouveau modèle est appelé **MMGP non linéaire**.

5.15.2 Évaluation des performances du nouveau modèle

Une fois le modèle implémenté et les prédictions réalisée, on commence d'abord par visualiser les champs obtenus par ce modèle et le confronter avec celui du modèle MMGP paramétré basé sur la réduction de dimension linéaire, la figure (40) :



(a) Résultat pour MMGP paramétré



(b) Résultat pour MMGP non linéaire

FIGURE 40 – Exemple d'évaluation de la reconstruction POD pour une simulation

La comparaison des résultats montre que les deux modèles reproduisent correctement la structure globale du champ ainsi que la localisation de la zone de température maximale. Néanmoins, l'analyse des champs d'erreur met en évidence une meilleure restitution locale avec le MMGP non linéaire. Celui-ci présente notamment des erreurs positives d'amplitude plus faible et donne une meilleure restitution des variations associées aux forts gradients thermiques. À l'inverse, le MMGP paramétrique génère un champ d'erreur plus régulier, mais avec des écarts localement plus importants, notamment au voisinage de la zone chaude et le long de la région centrale du domaine. Cette simulation illustre que le MMGP non linéaire offre une meilleure prédiction des phénomènes locaux, mais au détriments de la régularité des champs.

La figure (41) présente une comparaison quantitative des performances des trois modèles, en faisant appel aux trois métriques utilisées précédemment :

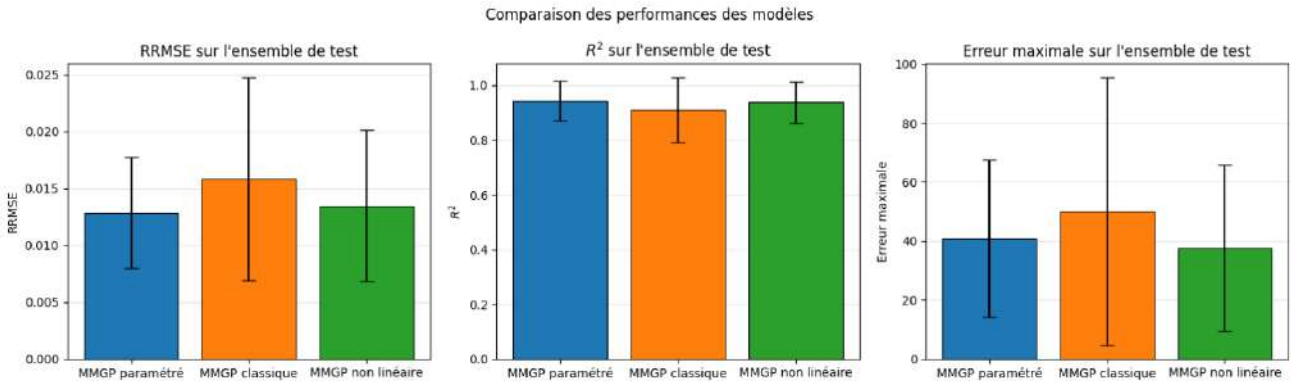


FIGURE 41 – Comparaison des trois modèles

La comparaison des performances sur l'ensemble du jeu de test montre que les formulations MMGP paramétrique et MMGP non linéaire présentent des niveaux de précision globale similaires. En revanche, le MMGP non linéaire présente une erreur maximale moyenne plus faible, ce qui suggère une meilleure maîtrise des erreurs locales les plus importantes. Les intervalles de dispersion associés aux différentes métriques se recouvrent cependant largement, ce qui ne permet pas d'établir une supériorité nette d'un modèle sur l'autre à partir des seules performances moyennes. Par contre, cette amélioration reste toujours insuffisante car les maximums de résidus dépassent 30°C en moyenne, cette valeur demeure intolérable dans le cadre de notre projet.

Conclusion et perspectives

En résumé, le travail réalisé dans ce projet a consisté à développer un modèle Machine Learning de substitution qui permet de prédire des champs physiques d'intérêt dans le cadre de résolution d'un problème physique complexe, exploité dans la simulation d'un procédé industriel utilisé par l'entreprise. Le choix de la solution n'a pas été basé uniquement sur ses performances prédictives, mais également sur sa capacité à s'intégrer dans une chaîne de traitement adaptée à la structure des données. Les contraintes qu'on a cherché à satisfaire dans cette chaîne sont : d'une part, standardiser les géométries et les maillages du domaine d'étude, afin de rendre les champs comparables, et d'autre part, réduire la dimension des sorties avant l'apprentissage, pour réduire autant que possible le coût computationnel du modèle. Les champs physiques complets sont ensuite reconstruits à partir des représentations réduites. Ces considérations ont directement orienté le choix de la méthodologie et du modèle retenus dans ce travail. Les modèles testés sont tous inspirés du MMGP [3], mais en variant les méthodes de standardisation des domaines d'étude et des maillages, les variables d'entrées et les méthodes de compression de l'information pour l'apprentissage.

Les résultats obtenus montrent tout d'abord que le modèle MMGP classique, malgré une sélection rigoureuse des variables d'entrée fondée sur l'analyse SHAP et une réduction progressive de la dimension, ne permet pas d'assurer une généralisation suffisamment robuste pour le problème étudié. Cette analyse met également en évidence les limites de ce type de représentation pour la prédiction de champs physiques caractérisés par des structures fortement localisées, comme c'est notamment le cas du champ de pression.

La stratégie retenue fournit néanmoins des résultats globalement satisfaisants pour les champs de température et de vitesse. Toutefois, son incapacité à restituer avec suffisamment de précision certaines structures locales limite la qualité globale des prédictions et ne permet pas d'atteindre le niveau de précision recherché. Ce constat a conduit à explorer des méthodes de compression plus avancées, capables de représenter des relations plus complexes et potentiellement non linéaires au sein des champs physiques, notamment les autoencodeurs. Ces approches ont effectivement permis d'améliorer la qualité de l'encodage, mais les performances obtenues restent encore insuffisantes au regard des objectifs de précision fixés dans le cadre de ce travail.

Les limites mises en évidence au cours de cette étude ouvrent plusieurs perspectives d'amélioration. On peut par exemple explorer des méthodes plus poussées pour la réduction de dimension, notamment des modèles plus développés d'autoencodeurs. Il serait également intéressant de développer des modèles de régression plus robustes, plus adaptés à ce genre de problèmes, par exemple : des modèles à base de processus gaussiens physiquement informés. Et vue que la standardisation des données passe dans le cas de ce projet inévitablement par un transport de champ, un mesh morphing et une interpolation éléments finis, on pourrait aussi mener une recherche permettant de quantifier et d'optimiser les erreurs liées à cette étape. Finalement, en raison de leur incompatibilité avec le modèle développé dans ce projet, on pourrait aussi proposer d'adapter le modèle pour la prédiction des champs localisés, notamment le champ de pression, par exemple en développant des méthodes qui se focalisent uniquement sur les zones d'intérêt.

Références

[1] A. de Boer, M.S. van der Schoot et H. Bijl. “Mesh deformation based on radial basis function interpolation”. In : mars 2007.

[2] Zhiwei Cao et al. “Transforming Future Data Center Operations and Management via Physical AI”. In : (2025). arXiv : 2504.04982 [cs.AI].

[3] Fabien Casenave, Brian Staber et Xavier Roynard. “MMGP : A Mesh Morphing Gaussian Process-based Machine Learning Method for Regression of Physical Problems under Nonparametrized Geometrical Variability”. In : *37th Conference on Neural Information Processing Systems (NeurIPS 2023)*. 2023.

[4] Maurice S. Fabien. “A Radial Basis Function (RBF) Method for the Fully Nonlinear 1D Serre Green–Naghdi Equations”. In : Houston, TX, juin 2014.

[5] Michael S. Floater. “Parametrization and Smooth Approximation of Surface Triangulations”. In : *Computer Aided Geometric Design* 14.3 (1997), p. 231-250. doi : 10.1016/S0167-8396(96)00031-3.

[6] Scarselli Franco et al. “The Graph Neural Network Model”. In : 2008.

[7] Xiaoxiao Guo, Wei Li et Francesco Iorio. “Convolutional Neural Networks for Steady Flow Approximation”. In : *Proceedings of KDD ’16*. San Francisco, CA, USA, 2016, p. 481-490.

[8] Abbas Kabalan et al. *Model-order reduction with optimal morphing for poorly reducible problems with geometric variabilities*. HAL Open Science. Déc. 2025.

[9] Michelin. *La stratégie de croissance durable de Michelin à horizon 2030*. url : https://www.michelin.com/groupe/strategie-michelin-in-motion.

[10] Michelin. *Rapport annuel et Document d’Enregistrement Universel*. url : https://www.michelin.com/investisseurs/rapport-annuel-documents-legaux-reglementes.

[11] T. C. S. Rendall et C. B. Allen. “Unified Fluid–Structure Interpolation and Mesh Motion Using Radial Basis Functions”. In : *International Journal for Numerical Methods in Engineering* 74.10 (2008), p. 1519-1559. doi : 10.1002/nme.2219.

[12] Olivier Roustant. *Metamodeling with Gaussian Processes*. HAL Open Science. Sept. 2025.

[13] L. Brunton Steven, R. Noack Bernd et Koumoutsakos Petros. “Machine Learning for Fluid Mechanics”. In : (sept. 2019).

[14] W. T. Tutte. “How to Draw a Graph”. In : *Proceedings of the London Mathematical Society* s3-13.1 (1963), p. 743-767. doi : 10.1112/plms/s3-13.1.743.

[15] Julien Weiss. “A Tutorial on the Proper Orthogonal Decomposition”. In : *AIAA Aviation Forum*. Dallas, Texas, USA, juin 2019.

[16] Cao Yadi et al. “Efficient learning of mesh-based physical simulation with bi-stride multi-scale Graph Neural Network”. In : *Proceedings of the 40th International Conference on Machine Learning, Honolulu, Hawaii, USA*. 2023.

A Retour d'expérience

Au-delà des résultats techniques obtenus au cours de ce stage, cette expérience a été particulièrement enrichissante sur les plans humain, professionnel et méthodologique. Elle m'a permis de découvrir concrètement le fonctionnement d'une équipe de recherche et développement au sein d'une grande entreprise, tout en développant à la fois mes compétences techniques et mes capacités relationnelles.

Sur le plan humain et professionnel, mon intégration au sein d'une équipe de R&D dans une entreprise mondiale comme Michelin m'a permis de mieux comprendre l'environnement de travail en entreprise et les différentes interactions qui rythment la vie d'une équipe. J'ai progressivement appris à m'adapter aux méthodes de travail, aux habitudes de l'équipe, aux modes de communication ainsi qu'aux pratiques propres à l'entreprise, y compris les règles de sécurité, l'organisation du temps et de l'espace de travail, les relations entre les personnes de différentes hiérarchies. Cette immersion m'a notamment permis de développer mon aisance dans les échanges professionnels, ma capacité d'écoute, mon autonomie ainsi que ma faculté à communiquer sur l'avancement de mon travail et les difficultés rencontrées.

J'ai également eu l'occasion d'assister à de nombreuses réunions (hebdomadaires, trimestrielles, team building, ...), présentations de stagiaires et soutenances de doctorat. Ces échanges m'ont donné une vision plus large de la philosophie et du sens d'équipe, des activités de recherche et développement menées en entreprise, ainsi que de la diversité des problématiques scientifiques et industrielles qui peuvent y être abordées. Ils m'ont également permis d'observer différentes manières de présenter un travail scientifique, d'argumenter des choix techniques et de communiquer des résultats à des interlocuteurs ayant des profils variés.

Ce stage a aussi représenté une expérience humaine importante grâce aux échanges avec les autres stagiaires, doctorants, ingénieurs et chercheurs rencontrés au cours de cette période. Ces interactions m'ont permis de créer de nouvelles relations, de confronter mes idées à celles des autres et de découvrir différents parcours et domaines de spécialisation. Elles ont ainsi contribué au développement de mes compétences relationnelles et de ma capacité à évoluer dans un environnement collaboratif.

Sur le plan technique, ce stage m'a donné l'opportunité de découvrir de nouveaux modèles mathématiques et de nouvelles méthodes, tout en renforçant mes compétences en programmation scientifique avec Python. Un des apprentissages les plus importants a notamment concerné l'implémentation d'algorithmes mathématiques. J'ai, par exemple, développé moi-même la méthode de RBF Mesh Morphing, en implémentant les différentes étapes de l'algorithme directement en Python. Cette démarche m'a permis de comprendre en profondeur le fonctionnement de la méthode, ses différentes étapes mathématiques ainsi que les difficultés numériques associées.Cependant, cette expérience m'a également permis de prendre conscience d'un aspect essentiel du développement en environnement industriel : comprendre et maîtriser un algorithme est important, mais il est également nécessaire de savoir s'appuyer sur des outils existants, robustes et optimisés lorsque cela est pertinent. Mon implémentation développée *from scratch* était fonctionnelle, mais demandait un temps de développement et d'exécution important. Sur les conseils de mon encadrant, j'ai ainsi découvert l'intérêt d'utiliser des routines scientifiques déjà optimisées, notamment celles proposées par des bibliothèques telles que SciPy. J'ai donc appris à trouver un équilibre entre la compréhension approfondie des méthodes numériques et l'uti-

lisation efficace d'outils éprouvés, ce qui constitue un enjeu important dans un contexte industriel où le temps de développement, la robustesse et les performances doivent également être pris en compte.

Enfin, ce stage m'a permis de développer une véritable démarche de résolution de problèmes et de recherche. Lorsqu'une approche ou un modèle ne produisait pas les résultats attendus, j'ai appris à ne pas simplement changer de méthode, mais à analyser méthodiquement l'origine du problème. Cela consiste notamment à formuler des hypothèses, à mettre en place des tests permettant de les vérifier ou de les invalider, puis à isoler progressivement les différentes sources possibles d'erreur. Cette démarche de diagnostic et de remise en question m'a appris à mieux déboguer mes programmes, mais également à adopter une méthode de travail plus scientifique et plus rigoureuse.

En guise de conclusion, ce stage m'a permis non seulement d'approfondir mes connaissances techniques, mais également de mieux comprendre la manière dont la recherche et la collaboration s'articulent dans un environnement industriel. Il m'a apporté une vision plus concrète du métier de R&D et m'a permis de progresser aussi bien dans ma manière de travailler que dans ma manière de communiquer et d'aborder un problème scientifique.

B Régression par processus gaussiens

Principe du modèle

La régression par processus gaussiens (GP) (appelée aussi krigeage) est une méthode probabiliste de régression permettant d'apprendre une fonction $y = f(x)$ réelle inconnue à partir d'un ensemble d'observations, avec $x \in \mathbb{R}^p$ présente l'input de la fonction f, et $y \in \mathbb{R}$ présente l'output.

Le principe de ce modèle ne suppose pas directement une forme paramétrique pour la fonction f recherchée, telle qu'une droite ou un polynôme, plutôt une distribution de probabilité sur l'ensemble des fonctions susceptibles d'expliquer les observations. Cette distribution est définie à l'aide d'un processus gaussien stationnaire de second ordre, c'est à dire qui s'écrit :

$$f(x) = m + Z(x) \tag{5}$$

avec m une moyenne réelle constante, et $(Z(x))$ un processus gaussien de moyenne nulle et de fonction de covariance k suivant le modèle

$$k(x, x') = \sigma^2 \, r_\theta(x - x')$$

où σ est la variance du processus Z qu'on suppose constante, et r_θ est la fonction de corrélation qui dépend du paramètre caractéristique $\theta \in \mathbb{R}^p$ appelé la portée. Ce paramètre traduit la dépendance entre les réalisation du processus Z dans deux points éloignés :

- **Lorsque θ_i diminue**, les observations dans deux points proches dans la direction i deviennent plus décorrélées, alors les trajectoires du processus Z présentent plus de fluctuations.
- **Lorsque θ_i augmente**, les observations dans deux points proches dans la direction i deviennent plus corrélées, alors les trajectoires du processus Z sont deviennent plus régulières.

Fonctions noyaux et propriétés de corrélation

La fonction noyau r_θ définit la covariance entre les valeurs du processus gaussien associées à deux entrées $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^p$:

$$r_\theta(\mathbf{x}, \mathbf{x}') = \mathrm{Corr}\left(f(\mathbf{x}), f(\mathbf{x}')\right).$$

Elle détermine ainsi la manière dont l'information observée en un point est propagée aux autres points de l'espace d'entrée. Pour être un noyau de corrélation valide, r_θ doit être symétrique et semi-définie positive. Ainsi, pour tout ensemble $\{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$, la matrice de Gram $\mathbf{K} = (r_\theta(\mathbf{x}_i, \mathbf{x}_j))_{ij}$ vérifie

$$\mathbf{a}^\top \mathbf{K} \mathbf{a} \geq 0, \qquad \forall\, \mathbf{a} \in \mathbb{R}^n.$$

Le choix du noyau traduit les hypothèses faites sur la fonction à modéliser, notamment sa régularité, ou son échelle de variation. Pour des entrées de dimension p, la distance peut être pondérée différemment selon chaque variable à l'aide de longueurs de corrélation $\theta_1, \ldots, \theta_p$. On définit alors

$$r^2(\mathbf{x}, \mathbf{x}') = \sum_{j=1}^{p} \frac{(x_j - x'_j)^2}{\theta_j^2}.$$

Cette formulation, souvent appelée *Automatic Relevance Determination* (ARD), permet au modèle d'apprendre une échelle caractéristique différente pour chaque dimension.

Noyau	**Expression**	**Propriétés principales**
Exponentiel	$\sigma^2 \exp\left(-\frac{1}{2}r^2\right)$	Fonctions très régulières et lisses. Adapté lorsque le phénomène varie progressivement.
Matérn 3/2	$\sigma^2 (1 + \sqrt{3}r) \exp(-\sqrt{3}r)$	Fonctions moins lisses que le RBF. Permet des variations locales plus importantes.
Matérn 5/2	$\sigma^2 \left(1 + \sqrt{5}r + \frac{5}{3}r^2\right) \exp(-\sqrt{5}r)$	Compromis entre la forte régularité du RBF et la flexibilité du Matérn 3/2.

TABLE 4 – Comparaison de quelques fonctions noyaux couramment utilisées en régression par processus gaussiens.

Apprentissage

On considère un ensemble d'apprentissage composé de n observations :

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n},$$

où $\mathbf{x}_i \in \mathbb{R}^p$ représente le vecteur des variables d'entrée associées à la i-ème observation et $y_i \in \mathbb{R}$ la sortie observée. Dans ce modèle, on suppose que les observations sont non bruitées, c'est à dire que pour une entrée $x_0 \in \mathbb{R}^p$ on observe toujours la même valeur de sortie $y \in \mathbb{R}$.

En notation matricielle, on introduit le vecteur des entrées et le vecteur des observations :

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix}, \qquad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} f(\mathbf{x}_1) \\ \vdots \\ f(\mathbf{x}_n) \end{bmatrix}$$

et la matrice de corrélation du vecteur $\mathbf{y}$ donnée par l'expression

$$\mathbf{K} = \begin{bmatrix} r_\theta(\mathbf{x}_1, \mathbf{x}_1) & \cdots & r_\theta(\mathbf{x}_1, \mathbf{x}_n) \\ \vdots & \ddots & \vdots \\ r_\theta(\mathbf{x}_n, \mathbf{x}_1) & \cdots & r_\theta(\mathbf{x}_n, \mathbf{x}_n) \end{bmatrix}.$$

L'objectif est alors de déterminer, pour une nouvelle entrée $\mathbf{x}_*$, la distribution de la sortie $y_* = f(x_*)$ en utilisant les observations disponibles dans $\mathcal{D}$. Le processus $(f(x))_x$ étant gaussien, le vecteur $(\mathbf{y}^\top, f(x_*)) = (f(x_1), \ldots, f(x_n), f(x_*))^\top$ est un vecteur gaussien de dimension $n+1$.

On définit le vecteur de covariance entre le nouveau point et les points d'apprentissage :

$$\mathbf{k}_* = \begin{bmatrix} k(\mathbf{x}_1, \mathbf{x}_*) \\ \vdots \\ k(\mathbf{x}_n, \mathbf{x}_*) \end{bmatrix},$$

d'après les hypothèses du modèle on a l'égalité

$$k(\mathbf{x}_*, \mathbf{x}_*) = \sigma^2$$

La propriété fondamentale du processus gaussien implique que les observations $\mathbf{y}$ et la valeur inconnue f_* suivent conjointement une loi normale :

$$\begin{bmatrix} \mathbf{y} \\ f_* \end{bmatrix} \sim \mathcal{N}\left(m.\mathbf{1}_{n+1},\, \sigma^2 \begin{bmatrix} \mathbf{K} & \mathbf{k}_* \\ \mathbf{k}_*^\top & 1 \end{bmatrix} \right), \tag{6}$$

Distribution prédictive

La prédiction est obtenue en conditionnant la distribution conjointe (6) par les observations disponibles $\mathbf{y}$. La propriété de conditionnement des lois normales multivariées donne

$$f_* \mid \mathbf{X}, \mathbf{y}, \mathbf{x}_* \sim \mathcal{N}\left(\mu_*, \sigma_*^2\right) \tag{7}$$

où la moyenne et la variance prédictives sont égales à

$$\mu_* = \mathbf{k}_*^\top \mathbf{K}^{-1} \mathbf{y} \tag{8}$$

$$\sigma_*^2 = \sigma^2 \left(1 - \mathbf{k}_*^\top \mathbf{K}^{-1} \mathbf{k}_*\right) \tag{9}$$

Ces deux expressions constituent les équations fondamentales de la régression par processus gaussiens.

La moyenne μ_* peut être interprétée comme une combinaison des observations disponibles. La prédiction dépend donc de la similarité, au sens du kernel de corrélation r_θ, entre le nouveau point $\mathbf{x}_*$ et chacun des points d'apprentissage. Les observations situées dans des régions fortement corrélées avec $\mathbf{x}_*$ ont davantage d'influence sur la prédiction.

La variance σ_*^2 mesure l'incertitude du modèle concernant la valeur de la fonction en $\mathbf{x}_*$. Le terme σ^2 correspond à l'incertitude a priori sur la fonction en ce point. Le second terme $\mathbf{k}_*^\top \mathbf{K}^{-1}\mathbf{k}_*$ représente la réduction d'incertitude apportée par les observations. Ainsi, lorsqu'un nouveau point est fortement corrélé aux données déjà observées, le terme $\mathbf{k}_*$ contient des valeurs importantes et l'incertitude prédictive diminue. À l'inverse, dans une région éloignée des observations au sens du kernel de corrélation r_θ, $\mathbf{k}_*$ devient faible et la variance prédictive se rapproche de la variance a priori.

La distribution donnée par la proposition (7) permet de construire directement un intervalle de confiance sur la valeur moyenne prédire au nouveau point x_*. Pour un réel $\alpha \in]0,\ 1[$, on note q le quantile d'ordre $1 - \frac{\alpha}{2}$ de la loi normale centrée réduite $\mathcal{N}(0, 1)$. Vu la symétrie de cette loi, le quantile d'ordre $\frac{\alpha}{2}$ est égal à $-q$, alors l'intervalle de confiance à $1 - \alpha$ est donné par :

$$[\mu_* - q.\,\sigma_*,\ \mu_* + q.\,\sigma_*]$$

Généralement on prend $\alpha = 0.05$, dans ce cas le quantile vaut $q = 1.96$.

Cette propriété constitue un avantage majeur des processus gaussiens : le modèle indique non seulement quelle valeur il prédit, mais également à quel point cette prédiction est incertaine.

Estimation des paramètres

Les hyperparamètres du modèle à estimer sont la moyenne m, la variance σ^2 et la portée θ. Généralement, l'estimation se fait par maximum de vraisemblance. Cette méthode permet de trouver directement l'expression d'un estimateur statistique pour la moyenne m et la variance σ^2. Pour un ensemble de n observations, le vecteur des sorties $\mathbf{y}$ est supposé suivre une loi normale multivariée :

$$\mathbf{y} \sim \mathcal{N}\left(m\mathbf{1}_n,\ \sigma^2\mathbf{K}\right),$$

où la matrice $\mathbf{K}$ dépend de la portée θ. Sous cette hypothèse, la vraisemblance des observations s'écrit

$$\mathcal{L}\left(\mathbf{y}, m, \sigma^2, \theta\right) = \frac{1}{(2\pi\sigma^2)^{n/2}|\mathbf{K}|^{1/2}} \exp\left(-\frac{(\mathbf{y} - m\mathbf{1}_n)^\top \mathbf{K}^{-1}(\mathbf{y} - m\mathbf{1}_n)}{2\sigma^2}\right).$$

Le principe du maximum de vraisemblance consiste à choisir les paramètres qui rendent les observations disponibles les plus probables selon le modèle, c'est à dire qui maximisent la vraisemblance $\mathcal{L}$. Pour simplifier les calculs analytiques, on cherche plutôt à minimiser le -log de cette fonction :

$$\ell(\mathbf{y}, m, \sigma^2, \theta) = \frac{1}{2}\log(|\mathbf{K}|) + \frac{n}{2}\log(2\,\pi\sigma^2) + \frac{(\mathbf{y} - m\mathbf{1}_n)^\top \mathbf{K}^{-1}(\mathbf{y} - m\mathbf{1}_n)}{2\sigma^2}$$

la minimisation par rapport à m et σ^2 conduit aux expressions analytiques :

$$\widehat{m}(\theta) = \frac{\mathbf{1}_n^\top \mathbf{K}^{-1}\mathbf{y}}{\mathbf{1}_n^\top \mathbf{K}^{-1}\mathbf{1}_n}$$

$$\widehat{\sigma}^2(\theta) = \frac{1}{n}(\mathbf{y} - \widehat{m}\mathbf{1}_n)^\top \mathbf{K}^{-1}(\mathbf{y} - \widehat{m}\mathbf{1}_n)$$

L'estimateur $\widehat{m}$ peut être interprété comme une moyenne généralisée des observations : contrairement à une moyenne arithmétique classique, il tient compte des corrélations entre les données à travers $\mathbf{K}^{-1}$. De manière analogue, $\widehat{\sigma}^2$ mesure la dispersion des observations autour de cette moyenne en tenant compte de leur structure de corrélation.

Ainsi, m et σ^2 n'ont pas besoin d'être déterminés par une optimisation numérique indépendante : pour chaque valeur de la portée θ, leurs estimateurs sont obtenus directement par les expressions précédentes. Il reste alors à estimer la valeur de θ en maximisant la vraisemblance dans laquelle m et σ^2 sont remplacés par $\widehat{m}(\theta)$ et $\widehat{\sigma}^2(\theta)$. Aucune solution analytique n'existe pour ce problème. Ainsi on procède par une optimisation numérique. Dans ce projet de stage, le calcul est fait automatiquement dans la commande `model.fit()` de `scikit.learn`. L'optimisation de la fonction log-vraisemblance se fait via un optimiseur (par défaut `scipy.optimize`. L'optimiseur est lancé depuis 10 initialisations différentes pour réduire le risque de rester piégé dans un minimum local.

C Analyse SHAP pour la sélection des variables

La méthode SHAP (*SHapley Additive exPlanations*) est utilisée afin de quantifier la contribution de chaque variable d'entrée à la prédiction d'un modèle. Elle repose sur les valeurs de Shapley issues de la théorie des jeux coopératifs.

Pour une prédiction donnée $f(\mathbf{x})$, l'idée consiste à décomposer la sortie du modèle sous la forme :

$$f(\mathbf{x}) = \phi_0 + \sum_{j=1}^{p} \phi_j,$$

où ϕ_0 représente la valeur moyenne de référence du modèle et ϕ_j la contribution associée à la j-ième variable d'entrée.

La valeur de Shapley d'une variable j peut s'écrire :

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} \left[f_{S\cup\{j\}}(\mathbf{x}) - f_S(\mathbf{x}) \right],$$

où F désigne l'ensemble complet des variables d'entrée et S un sous-ensemble ne contenant pas la variable j. Cette expression mesure l'apport moyen de la variable j lorsqu'elle est ajoutée à toutes les combinaisons possibles de variables.

Dans cette étude, les valeurs SHAP sont calculées séparément pour chaque modèle de régression associé à un coefficient modal. Une mesure globale d'importance est ensuite obtenue à partir de la moyenne des valeurs absolues :

$$I_j = \frac{1}{N} \sum_{i=1}^{N} \left| \phi_j^{(i)} \right|,$$

où N désigne le nombre d'observations analysées.

Cette analyse montre que l'importance des variables est fortement dépendante du champ physique et du mode considéré. Une variable peut ainsi être déterminante pour certains coefficients modaux tout en ayant une influence très faible sur d'autres.

Afin d'obtenir un classement global des variables, les importances sont ensuite agrégées entre les différents modes. Ce classement est utilisé pour construire progressivement plusieurs modèles en conservant les variables par ordre décroissant d'importance. La qualité de prédiction est alors évaluée en fonction du nombre de variables retenues.

Cette approche permet de combiner interprétabilité et modèle basé sur les données. Elle est complétée par une étude d'ablation, consistant à supprimer certaines variables afin d'évaluer directement leur influence sur la robustesse et la capacité de généralisation du modèle.

D Autoencodeurs pour la réduction de dimension

Un autoencodeur est un réseau de neurones conçu pour apprendre une représentation compacte de données de grande dimension. Il est constitué de deux parties principales : un encodeur et un décodeur.

L'encodeur transforme le champ physique initial $\mathbf{x}$ en un vecteur latent de faible dimension $\mathbf{z}$:

$$\mathbf{z} = f_{\text{enc}}(\mathbf{x}),$$

tandis que le décodeur reconstruit une approximation du champ à partir de cette représentation :

$$\hat{\mathbf{x}} = f_{\text{dec}}(\mathbf{z}).$$

L'entraînement consiste à minimiser l'écart entre le champ original et le champ reconstruit, par exemple à l'aide d'une erreur quadratique :

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^{N} \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_2^2 .$$

Contrairement à la POD, qui repose sur une représentation linéaire, l'autoencodeur peut apprendre une relation non linéaire entre le champ physique et ses coordonnées réduites. Il peut ainsi mieux représenter certaines structures complexes ou localisées.

Dans ce travail, l'autoencodeur est utilisé comme une alternative à la POD afin d'améliorer la compression des champs physiques. Les performances sont évaluées à partir des erreurs de reconstruction obtenues sur les ensembles d'apprentissage et de test.

E Mesh Morphing avec l'algorithme de Tutte.

L'algorithme de Tutte, ou *Tutte's barycentric mapping*, permet de transformer un maillage triangulaire connexe, de topologie équivalente à un disque, en un maillage plan contenu dans le disque unité. On considère un maillage à N noeuds qu'on indexe x_i, $i = 1, \dots, N$, où les noeds intérieursdu maillages sont indexés $1 \dots N_{int}$, et les noeuds de bords sont indexés $N_{int} + 1 \dots N$, qu'on note $x_{b_i} = x_{i+N_{int}}$, $i = 1, \dots N_b$, où N_b est le nombre total des noeuds de bord. Le principe consiste tout d'abord à imposer la position des sommets situés sur le bord du maillage en les projetant sur le cercle unité. Ensuite, les coordonnées des sommets intérieurs sont déterminées en imposant que chaque sommet soit placé au barycentre de ses sommets voisins. Ainsi, pour un sommet intérieur i, on

désigne par d_i le nombre de voisins du noeud x_i et par $\mathcal{N}_i$ l'ensemble de ses voisins, les nouvelles coordonnées $\mathbf{x}_i,\ i = 1, \dots N_{int}$ vérifient le système :

$$x_i - \frac{1}{d_i} \sum_{j \in \mathcal{N}_i \cap [\![1, N_{int}]\!]} x_j = -\frac{1}{d_i} \sum_{j \in \mathcal{N}_i \cap [\![N_{int}, N]\!]} x_{b_{j-N_{int}}}$$

L'ensemble de ces relations, combiné aux positions connues des sommets de frontière, conduit à la résolution d'un système linéaire creux dont les inconnues sont les coordonnées des sommets intérieurs. On note que cette transformation ne modifie pas la connectivité du maillage : seuls les emplacements des sommets sont déplacés afin d'obtenir une représentation commune dans le disque unité, ce qui facilite ensuite la comparaison ou le transfert de grandeurs entre des géométries différentes. Un point fort de cet algorithme, c'est qu'il ne nécessite aucune paramétrisation des maillages étudiés, mais uniquement les coordonnées des noeuds et leurs connectivités.

F Mesh Morphing par fonctions à base radiale (RBF)

Le Mesh Morphing par fonctions à base radiale (Radial Basis Functions, RBF) est une méthode permettant de déformer un maillage tout en conservant sa topologie et sa connectivité. Le principe consiste à imposer la transformation d'un ensemble de points de contrôle, généralement choisis sur la frontière du domaine, puis à propager cette déformation à l'ensemble des sommets intérieurs par interpolation. Contrairement à l'algorithme de Tutte, cette méthode ne repose pas sur les relations de voisinage entre les sommets. On considère sur le bord du maillage N_b points de contrôle, proprement répartis, de coordonnées initiales $\mathbf{x}_{b_j}$, dont les positions après morphing $\mathbf{y}_{b_j}$ sont connues. La position de la transformée d'un sommet intérieur $\mathbf{x}_i$ est alors obtenue à partir d'une combinaison de fonctions radiales centrées sur les points de contrôle :

$$\mathbf{y}_i = \sum_{j=1}^{N_b} \alpha_j \, \phi\left(\|\mathbf{x}_i - \mathbf{x}_{b_j}\|\right), \quad i = 1, \dots, N_{int}$$

où ϕ désigne une fonction à base radiale et α_j les coefficients d'interpolation associés aux points de contrôle. Ces coefficients sont déterminés de manière à reproduire exactement la transformation prescrite sur la frontière. Ainsi, ils sont obtenus en résolvant le système :

$$\mathbf{M}_{\text{RBF}}\, \boldsymbol{\alpha} = \mathbf{y}_b, \qquad (\mathbf{M}_{\text{RBF}})_{i,j} = \phi\left(\|\mathbf{x}_{b_i} - \mathbf{x}_{b_j}\|\right).$$

Dans la méthode utilisée dans ce projet de stage, la fonction radiale à support compact est la fonction linéaire

$$\phi(\xi) = \xi,$$

Une fois les coefficients $\boldsymbol{\alpha}_j$ calculés à partir des points de frontière, la nouvelle position de chaque sommet intérieur peut être évaluée indépendamment, ce qui rend la méthode facilement parallélisable. L'utilisation d'une fonction à support compact permet également de limiter l'influence d'un point de contrôle à son voisinage spatial et d'obtenir une déformation progressive du maillage. Dans le cadre du Mesh Morphing, cette approche est

particulièrement intéressante puisqu'elle permet de faire correspondre différentes géométries à une géométrie de référence tout en conservant la structure du maillage initial. Par ailleurs, le système linéaire à résoudre est de taille N_b, c'est-à-dire du nombre de points de contrôle, ce qui peut représenter un avantage lorsque le nombre de points de contrôle reste faible devant le nombre total de sommets du maillage.

Version du 29 septembre 2025

CENTRALE LYON

membre de : UNIVERSITÉ DE LYON

TFE

Année 2025-2026

Ce formulaire est à insérer après la page de garde de votre rapport. Il atteste que le rapport a été validé par l'entreprise et peut être communiqué en l'état au Service de la Scolarité de l'Ecole Centrale de Lyon.

VALIDATION DU RAPPORT DE TFE

PAR L'ENTREPRISE

Références du Travail de Fin d'Etudes

Nom de l'élève : Taha Zaoui

Titre du rapport : Machine Learning et modèles réduits appliqués aux processus de fabrication

Entreprise : Michelin

Nom du Tuteur entreprise : Amina Chorfi & Raphaël Meunier

Nom du Tuteur ECL : Céline Hartweg Helbert

L'entreprise reconnaît avoir pris connaissance du rapport mentionné ci-dessus et autorise sa transmission à l'Ecole Centrale de Lyon.

L'entreprise autorise la diffusion du rapport sur le catalogue de la bibliothèque de l'Ecole Centrale de Lyon :

- les informations sur le TFE (titre – auteur – mots-clés – résumé...) seront publiques.
- L'accès au rapport pdf, sur authentification, sera limité aux étudiants et personnels de l'Ecole Centrale de Lyon.

(rayer la mention inutile)

Le représentant de l'entreprise
Nom : MEUNIER Raphaël
Fonction : Expert mathématiques appliquées

Date : 15/09/26
Signature et cachet

MANUFACTURE FRANÇAISE DES PNEUMATIQUES MICHELIN CLERMONT-FERRAND